

ĐẠI HỌC QUỐC GIA TP HCM
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN



Dimensionality Reduction

Môn học: Nhập môn học máy

Sinh viên thực hiện:

Đỗ Tiến Đạt - 23120119

Lê Nhật Minh Tâm - 23120163

Triệu Tuấn Kiệt - 23120137

Nguyễn Đăng Khoa - 23120134

Huỳnh Mạnh Tường - 23120105

Giáo viên hướng dẫn:

Thầy Bùi Tiến Lên

Thầy Lê Nhựt Nam

Ngày 28 tháng 5 năm 2026

Mục lục

Chương 1	Giới thiệu	1
1.1	Bài toán và ký hiệu	2
1.2	Động lực thực hiện	2
1.3	Ví dụ Swiss roll	2
1.4	Đóng góp của báo cáo	3
Chương 2	Cơ sở lý thuyết	3
2.1	Ma trận dữ liệu và hiệp phương sai	3
2.2	Phân tích giá trị kỳ dị	4
2.3	Chiều trực giao và chuẩn Frobenius	4
2.4	Phương sai theo một hướng	4
2.5	Kernel và ma trận Gram	5
2.6	Đồ thị láng giềng và Laplacian	5
2.7	Đa tập và cấu trúc tô-pô	6
2.8	Phân kỳ KL và cross-entropy	6
2.9	Ước lượng mật độ: hàm phân hoạch, NCE, NEG	7
2.9.1	Bài toán ước lượng mật độ	7
2.9.2	Ước lượng tương phản nhiễu (NCE)	7
2.9.3	Lấy mẫu tiêu cực (NEG)	8
Chương 3	Phương pháp giảm chiều	8
3.1	Phân tích thành phần chính (PCA)	9
3.2	PCA trong không gian kernel (KPCA)	10
3.3	Học manifold qua KPCA	12
3.3.1	Isomap	13
3.3.2	Laplacian eigenmaps	15
3.3.3	Locally Linear Embedding (LLE)	15
3.4	Trực quan hóa phi tuyến: t-SNE và UMAP	16
3.4.1	t-Distributed Stochastic Neighbor Embedding (t-SNE)	16
3.4.2	Uniform Manifold Approximation and Projection (UMAP)	18

3.5	Bổ đề Johnson–Lindenstrauss	21
3.6	Mối liên hệ trong chương	23
Chương 4	Một số hướng nghiên cứu	24
4.1	Thống nhất t-SNE và UMAP qua học tương phản	24
4.1.1	Khung nhúng láng giềng tương phản	24
4.1.2	Bước 1 — t-SNE là MLE; NC-t-SNE xấp xỉ t-SNE bằng NCE	25
4.1.3	Bước 2 — Cố định Z : từ NCE đến NEG	25
4.1.4	Bước 3 — UMAP thực chất là NEG	26
4.1.5	Phổ nhúng: $\bar{Z}$ điều khiển tỷ lệ lực đẩy/hút	27
4.2	Cân bằng cục bộ—toàn cục trong trực quan hóa giảm chiều	30
4.2.1	Bài toán trực quan hóa	30
4.2.2	Rainbow figure và sáu nguyên tắc thiết kế loss	30
4.2.3	Bước 1 — Ba loại cặp điểm	31
4.2.4	Bước 2 — Hàm loss và lịch trọng số ba giai đoạn	31
4.2.5	Thí nghiệm baseline của nhóm	32
4.3	Nhận xét tổng quan: xu hướng, hạn chế và câu hỏi mở	33
Chương 5	Thực nghiệm và phân tích kết quả	34
5.1	Thiết lập thực nghiệm	34
5.2	PCA: phương sai và lỗi tái tạo	35
5.3	KPCA: cấu trúc phi tuyến của hai vòng tròn	36
5.4	Isomap: bảo toàn khoảng cách geodesic trên Swiss roll	37
5.5	Đối chiếu mở rộng: t-SNE và UMAP	39
5.6	Các đoạn cài đặt chính	39
Chương 6	Tổng kết	44
6.1	Tóm tắt nội dung	44
6.2	Các hướng phát triển	45
	Tài liệu tham khảo	46
A	Phụ lục	47

1.1	Chứng minh Bổ đề tập trung phân phối χ^2	47
1.2	Khai triển gradient UMAP	48
1.3	Khai triển gradient MLE, NCE, NEG cho nhúng láng giềng	49

Danh sách bảng

1	Các hướng giảm chiều trong chương	21
2	So sánh t-SNE, NC-t-SNE, Neg-t-SNE và UMAP qua khung NCE/NEG	29
3	Tóm tắt PaCMAP so với các thuật toán trực quan hóa được phân tích	32
4	Baseline trên MNIST (<code>baseline.ipynb</code> , <code>SEED = 42</code>)	33
5	Phiên bản môi trường dùng để tái lập thực nghiệm chính.	34
6	Thiết lập cho ba thực nghiệm minh họa.	35
7	Một số kết quả PCA trên Wine.	35
8	Silhouette theo nhãn tổng hợp cho PCA và RBF-KPCA.	37
9	Độ nhảy Isomap theo số láng giềng trên Swiss roll.	38
10	Baseline t-SNE và UMAP trên MNIST trong <code>baseline.ipynb</code>	39

Danh sách hình vẽ

1	Ý tưởng Swiss roll: mẫu nằm trên cấu trúc hai chiều được nhúng trong không gian cao chiều; sau giảm chiều, quan hệ láng giềng dễ quan sát hơn.	2
2	Dữ liệu hai chiều (điểm xanh) và hướng thành phần chính thứ nhất (đường đỏ). . .	5
3	Isomap: khoảng cách trên manifold được xấp xỉ bằng tổng độ dài cạnh trên đường đi ngắn nhất (nét liền xanh lá), không dùng trực tiếp đoạn thẳng Euclidean (nét đứt).	14
4	Chiều ngẫu nhiên Johnson–Lindenstrauss: giảm chiều với bảo đảm trên khoảng cách cặp.	23
5	Phổ Neg-t-SNE: $\overline{Z}$ nhỏ ($\approx 50n$, t-SNE) cho lực đẩy mạnh và cụm dàn trải; $\overline{Z}$ lớn ($\mathcal{O}(n^2)$, UMAP) cho lực đẩy yếu và cụm siêu co chặt.	29
6	Phương sai tích lũy và lỗi tái tạo PCA trên dữ liệu Wine đã chuẩn hóa.	35
7	Dữ liệu Circles quan sát ở hai chiều gốc và kết quả giảm từ 10 chiều xuống 2 chiều bằng PCA, KPCA.	36
8	Độ nhảy của RBF-KPCA theo γ khi giảm Circles mở rộng từ 10 chiều xuống 2 chiều.	37
9	Swiss roll ban đầu và hai biểu diễn hai chiều bằng PCA, Isomap.	38
10	Tương quan khoảng cách của Isomap thay đổi theo số láng giềng.	38

Chương 1 Giới thiệu

Khi số chiều đặc trưng rất lớn, nhiều thuật toán học máy tốn kém bộ nhớ và thời gian, đồng thời khó quan sát cấu trúc dữ liệu. *Giảm chiều* (dimensionality reduction) nhằm tìm một biểu diễn có số chiều nhỏ hơn nhưng vẫn giữ được phần thông tin hoặc quan hệ hình học quan trọng của tập mẫu gốc.

Quy ước ký hiệu.

- **Tập hợp và không gian:** $\mathcal{X}$ là không gian mẫu, $\mathcal{H}$ là không gian Hilbert, P_k là tập ma trận chiều hạng k , $\mathcal{N}_i$ là tập láng giềng của điểm i .
- **Mẫu và chiều:** $S = (x_1, \dots, x_m)$ gồm m mẫu; N là số chiều gốc, k là số chiều sau giảm chiều, d là số chiều trực quan hóa khi cần.
- **Vector:** chữ thường in đậm, ví dụ $\mathbf{x}_i = \Phi(x_i) \in \mathbb{R}^N$, $\mathbf{y}_i \in \mathbb{R}^k$, $\mathbf{1}$ là vector toàn 1.
- **Ma trận:** chữ hoa in đậm, ví dụ $\mathbf{X} \in \mathbb{R}^{N \times m}$ là ma trận dữ liệu, $\mathbf{Y} \in \mathbb{R}^{k \times m}$ là embedding, $\mathbf{I}_m$ là ma trận đơn vị.
- **Ma trận cốt lõi:** $\mathbf{C}$ là hiệp phương sai, $\mathbf{K}$ là Gram/kernel, $\tilde{\mathbf{K}}$ là kernel đã căn giữa, $\mathbf{H}$ là ma trận centering, Δ là ma trận khoảng cách bình phương.
- **Đồ thị và manifold:** $\mathbf{W}$ là ma trận trọng số, $\mathbf{D}$ là ma trận bậc, $\mathbf{L}$ là Laplacian, $\mathbf{M}$ là ma trận LLE, $\mathbf{K}_{\text{Iso}}$ là Gram matrix của Isomap.
- **Phổ và phân rã:** λ_i là trị riêng, σ_i là giá trị kỳ dị, $\mathbf{u}_i, \mathbf{v}_i$ là vector riêng hoặc vector kỳ dị tùy ngữ cảnh; $\mathbf{\Lambda}$ và $\mathbf{\Sigma}$ là các ma trận đường chéo tương ứng.
- **Phân phối và hàm mục tiêu:** p_{ij}, q_{ij} là xác suất cặp điểm trong t-SNE; B_{ij}, w_{ij} là trọng số mờ của UMAP; $\mathcal{L}$ là hàm loss, Z là hằng số chuẩn hóa hoặc hàm phân hoạch.
- **Toán tử:** $\|\cdot\|_F$ là chuẩn Frobenius, $\text{Tr}(\cdot)$ là trace, Φ là ánh xạ đặc trưng. Các ký hiệu đặc thù hơn được định nghĩa lại tại nơi xuất hiện.

1.1 Bài toán và ký hiệu

Cho tập mẫu $S = (x_1, \dots, x_m)$ với $x_i \in \mathcal{X}$, ánh xạ đặc trưng $\Phi : \mathcal{X} \rightarrow \mathbb{R}^N$ và ma trận dữ liệu

$$\mathbf{X} = [\Phi(x_1), \dots, \Phi(x_m)] \in \mathbb{R}^{N \times m},$$


cột thứ i là vector $\mathbf{x}_i = \Phi(x_i)$. Ta muốn tìm ma trận biểu diễn $\mathbf{Y} \in \mathbb{R}^{k \times m}$ với $k \ll N$ sao cho $\mathbf{Y}$ phản ánh $\mathbf{X}$ theo tiêu chí đã chọn (lỗi tái tạo, phương sai, khoảng cách, láng giềng, ...).

1.2 Động lực thực hiện

- **Tính toán:** nén dữ liệu trước khi huấn luyện hoặc truy vấn, giảm chi phí lưu trữ và phép toán.
- **Trực quan:** đưa mẫu về hai hoặc ba chiều để khám phá cụm, ngoại lệ, xu hướng.
- **Trích đặc trưng:** tạo tập chiều thấp hy vọng hữu ích hơn cho phân loại hoặc hồi quy phía sau.

1.3 Ví dụ Swiss roll

Swiss roll là dữ liệu mô phỏng ba chiều nằm gần một mặt hai chiều “cuộn” (Hình 1). Nếu “mở” mặt này ra phẳng, quan hệ láng giềng trở nên rõ. Trong thực tế, manifold lý tưởng hiếm khi khớp hoàn toàn; ví dụ này chủ yếu giúp hình dung vì sao cần phương pháp *phi tuyến*, chứ không phải bằng chứng cho mọi bộ dữ liệu thật.



Hình 1: Ý tưởng Swiss roll: mẫu nằm trên cấu trúc hai chiều được nhúng trong không gian cao chiều; sau giảm chiều, quan hệ láng giềng dễ quan sát hơn.

1.4 Đóng góp của báo cáo

1. Chương 2: cơ sở lý thuyết—đại số ma trận (hiệp phương sai, SVD, chiếu, kernel, Laplacian), hình học manifold, phân kỳ KL / cross-entropy, và khung ước lượng tương phản NCE / NEG.
2. Chương 3: các phương pháp giảm chiều theo [12]—PCA, KPCA, Isomap, Laplacian eigenmaps, LLE, Johnson–Lindenstrauss; kèm [MỞ RỘNG] t-SNE và UMAP [16, 9] (không có trong sách).
3. Chương 4: khảo sát bài báo gần đây—thống nhất t-SNE và UMAP qua học tương phản [5].
4. Chương 5: thực nghiệm chính cho PCA, KPCA và Isomap; kèm đối chiếu bổ sung từ notebook cho LLE, Laplacian Eigenmaps, t-SNE và UMAP.
5. Chương 6: tổng kết.
6. Phụ lục: các chứng minh kỹ thuật hỗ trợ (bổ đề tập trung χ^2 , khai triển gradient UMAP và NCE).

Nguồn tham khảo chính cho phần lý thuyết theo sách là *Foundations of Machine Learning* [12]; t-SNE và UMAP trích từ bài báo tương ứng.

Chương 2 Cơ sở lý thuyết

Chương này gom các khái niệm cần dùng xuyên suốt báo cáo: đại số ma trận (Mục 2.1–2.4), kernel và đồ thị (2.5–2.6), hình học manifold (2.7), các độ đo phân phối (2.8), và khung ước lượng tương phản (2.9). Mỗi khái niệm được định nghĩa *một lần* tại đây; các chương sau tham chiếu qua \ref.

2.1 Ma trận dữ liệu và hiệp phương sai

Với mẫu $x_1, \dots, x_m \in \mathcal{X}$, ma trận $\mathbf{X}$ như Chương 1. Khi nói dữ liệu *đã căn giữa theo cột*, ta có $\sum_{i=1}^m \mathbf{x}_i = \mathbf{0}$.

Định nghĩa 2.1 (Hiệp phương sai mẫu). Với dữ liệu đã căn giữa,

$$\mathbf{C} = \frac{1}{m} \mathbf{X} \mathbf{X}^\top \in \mathbb{R}^{N \times N}.$$

Phần tử $\mathbf{C}_{ij}$ đo mức đồng biến tuyến tính giữa hai đặc trưng sau khi trừ trung bình.

Nếu chưa căn giữa, dùng $\bar{\mathbf{x}} = \frac{1}{m} \sum_i \mathbf{x}_i$ và $\mathbf{C} = \frac{1}{m} \sum_i (\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{x}_i - \bar{\mathbf{x}})^\top$.

2.2 Phân tích giá trị kỳ dị

Định nghĩa 2.2 (SVD). Với $\mathbf{X} \in \mathbb{R}^{N \times m}$, tồn tại phân tích

$$\mathbf{X} = \mathbf{U} \mathbf{\Sigma} \mathbf{V}^\top,$$

$\mathbf{U}, \mathbf{V}$ có cột trực chuẩn, $\mathbf{\Sigma}$ đường chéo các giá trị kỳ dị không âm $\sigma_1 \geq \sigma_2 \geq \dots$.

Đặt $\mathbf{\Lambda} = \mathbf{\Sigma}^2 = \text{diag}(\sigma_1^2, \sigma_2^2, \dots)$. Khi đó

$$\mathbf{K} = \mathbf{X}^\top \mathbf{X} = \mathbf{V} \mathbf{\Lambda} \mathbf{V}^\top, \quad \mathbf{C} = \frac{1}{m} \mathbf{X} \mathbf{X}^\top = \mathbf{U} \frac{\mathbf{\Lambda}}{m} \mathbf{U}^\top.$$

Do đó, $\mathbf{K}$ có các trị riêng khác không là σ_i^2 , còn $\mathbf{C}$ có các trị riêng tương ứng là σ_i^2/m . Hai ma trận chia sẻ cùng phổ khác không tới hệ số $1/m$, nhưng vector riêng của $\mathbf{K}$ nằm trong không gian mẫu, còn vector riêng của $\mathbf{C}$ nằm trong không gian đặc trưng. Đây là cầu nối giữa PCA và KPCA.

2.3 Chiếu trực giao và chuẩn Frobenius

Định nghĩa 2.3 (Ma trận chiếu bậc k). P_k gồm các ma trận $\mathbf{P} = \mathbf{U} \mathbf{U}^\top$ với $\mathbf{U} \in \mathbb{R}^{N \times k}$ có cột trực chuẩn, $\text{rank}(\mathbf{P}) = k$. Khi đó $\mathbf{P}^2 = \mathbf{P}$, $\mathbf{P}^\top = \mathbf{P}$.


Chuẩn Frobenius: $\|\mathbf{M}\|_F^2 = \text{Tr}(\mathbf{M}^\top \mathbf{M})$. Tính hoán vị của trace ($\text{Tr}(\mathbf{ABC}) = \text{Tr}(\mathbf{BCA})$) dùng nhiều trong chứng minh PCA.

2.4 Phương sai theo một hướng

Với vector đơn vị $\mathbf{u}$, lượng $\mathbf{u}^\top \mathbf{C} \mathbf{u}$ là phương sai của chiếu một chiều lên $\mathbf{u}$. Bài toán $\max_{\|\mathbf{u}\|=1} \mathbf{u}^\top \mathbf{C} \mathbf{u}$ đạt tại vector riêng của $\mathbf{C}$ ứng với trị riêng lớn nhất. Các hướng tiếp theo tối đa hóa phương sai trong không gian vuông góc với các hướng đã chọn.

Ví dụ 2.1. Hai đặc trưng trên mặt phẳng tương quan mạnh (ví dụ cùng đo kích thước giày nhưng đơn vị khác nhau). Đám điểm kéo dài theo một đường chéo; chiếu lên đường đó giữ phần lớn biến

thiên, chiều vuông góc gần như mất thông tin—đó là động lực hình học của thành phần chính thứ nhất (Hình 2).



Hình 2: Dữ liệu hai chiều (điểm xanh) và hướng thành phần chính thứ nhất (đường đỏ).

2.5 Kernel và ma trận Gram

Định nghĩa 2.4 (Kernel xác định dương bán). Hàm $K : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ là kernel PDS nếu tồn tại $\mathcal{H}$ và $\Phi : \mathcal{X} \rightarrow \mathcal{H}$ sao cho $K(x, x') = \langle \Phi(x), \Phi(x') \rangle$.

Trên m điểm, ma trận $\mathbf{K}$ với $K_{ij} = K(x_i, x_j)$ luôn xác định dương bán. KPCA chỉ cần $\mathbf{K}$, không cần biết Φ tường minh.

2.6 Đồ thị láng giềng và Laplacian

Các thuật toán manifold thường:

1. Chọn t láng giềng gần nhất cho mỗi điểm (theo $\|\mathbf{x}_i - \mathbf{x}_j\|$).
2. Gán trọng số W_{ij} trên cạnh (Gaussian, hệ số tái tạo, ...).
3. Dùng ma trận Laplacian $\mathbf{L} = \mathbf{D} - \mathbf{W}$, với $D_{ii} = \sum_j W_{ij}$.

Ma trận căn giữa (centering) dùng trong Isomap:

$$\mathbf{H} = \mathbf{I}_m - \frac{1}{m} \mathbf{1} \mathbf{1}^\top,$$

với $\mathbf{1}$ là vector toàn 1. Nhân $\mathbf{H}$ hai bên một ma trận khoảng cách giúp chuyển sang dạng tương tự tích vô hướng trong không gian đã trừ trung bình.

2.7 Đa tạp và cấu trúc tô-pô

Định nghĩa 2.5 (Đa tạp (Manifold)). *Đa tạp* M chiều d là một “bề mặt” có thể cong, nhưng tại mỗi vùng nhỏ trông giống $\mathbb{R}^d$. Nói cách khác, dữ liệu tuy nằm trong không gian D chiều nhưng thực sự chỉ có $d \ll D$ bậc tự do.

Ví dụ: Mặt quả cầu là đa tạp 2 chiều nhúng trong $\mathbb{R}^3$ —mỗi điểm cần 3 tọa độ (x, y, z) , nhưng chỉ cần 2 tham số (kinh độ, vĩ độ) là xác định được vị trí. Swiss roll (Hình 1) là đa tạp 2 chiều “cuộn” trong $\mathbb{R}^3$.

Đa tạp Riemann (M, g) bổ sung thêm *metric* g : cho phép đo khoảng cách *trên bề mặt* (geodesic) thay vì khoảng cách “cắt thẳng” xuyên qua không gian bao.

Định nghĩa 2.6 (Cấu trúc tô-pô (Topology)). *Tô-pô* của một tập hợp mô tả “hình dạng” bản chất của nó—những tính chất không thay đổi khi ta bẻ cong, kéo giãn (nhưng không cắt, dán). Trong ngữ cảnh giảm chiều, “giữ cấu trúc tô-pô” nghĩa là giữ *quan hệ kết nối*: ai là láng giềng của ai, dữ liệu chia thành mấy cụm, cụm nào nối với cụm nào.

Giả định manifold—dữ liệu cao chiều nằm gần một đa tạp nhúng—là nền tảng chung cho Isomap, Laplacian eigenmaps, LLE (Chương 3, Mục 3.3) và UMAP (Mục 3.4.2).

2.8 Phân kỳ KL và cross-entropy

Định nghĩa 2.7 (Phân kỳ Kullback–Leibler). Cho hai phân phối xác suất p, q trên cùng không gian $\mathcal{X}$. Phân kỳ KL được định nghĩa bởi:

$$\text{KL}(p||q) = \int_{\mathcal{X}} p(x) \log \frac{p(x)}{q(x)} dx.$$

Định nghĩa 2.8 (Cross-entropy). Cho phân phối xác suất mục tiêu p (dữ liệu gốc) và phân phối dự báo q (mô hình nhúng) trên cùng không gian $\mathcal{X}$. Hàm loss cross-entropy tổng quát được định nghĩa là:

$$H(p, q) = - \int_{\mathcal{X}} p(x) \log q(x) dx.$$

Trong bài toán tối ưu hóa và học máy, hàm mất mát Cross-Entropy ($H(p, q)$) đo lường sự tương đồng giữa hai phân phối xác suất: phân phối thực tế của dữ liệu (p) và phân phối dự báo của mô hình (q).

2.9 Ước lượng mật độ: hàm phân hoạch, NCE, NEG

Mục này trình bày khung *ước lượng tương phản nhiễu* (NCE) [6] và biến thể *lấy mẫu tiêu cực* (NEG) [11]—hai công cụ sẽ dùng ở Chương 4 để phân tích mối quan hệ giữa t-SNE và UMAP.

2.9.1 Bài toán ước lượng mật độ

Cho N mẫu i.i.d. $s_1, \dots, s_N$ rút từ phân phối chưa biết p trên không gian hữu hạn $\mathcal{X}$. Mục tiêu: tìm θ sao cho mô hình q_θ xấp xỉ p .

Cách tiếp cận cổ điển—ước lượng hợp lý cực đại (MLE)—cần q_θ là phân phối hợp lệ. Thường ta chỉ có hàm chưa chuẩn hóa $\phi_\theta(x)$ và phải chia cho *hàm phân hoạch*:

$$Z(\theta) = \sum_{x \in \mathcal{X}} \phi_\theta(x), \quad q_\theta(x) = \frac{\phi_\theta(x)}{Z(\theta)}. \quad (1)$$

Tính $Z(\theta)$ đòi hỏi cộng trên toàn bộ $|\mathcal{X}|$ phần tử ở *mỗi* bước gradient—rất tốn kém khi $|\mathcal{X}|$ lớn.

2.9.2 Ước lượng tương phản nhiễu (NCE)

Gutmann & Hyvärinen [6] biến bài toán ước lượng mật độ thành bài toán *phân loại nhị phân*: phân biệt mẫu dữ liệu thực với mẫu rút từ phân phối nhiễu ξ đã biết.

- $\xi(x)$ là phân phối nhiễu (thường đồng đều: $\xi(x) = \frac{1}{|\mathcal{X}|}$); mẫu từ ξ gọi là *mẫu âm*.
- m là tỷ số mẫu nhiễu trên mẫu dữ liệu.

Ký hiệu $q_{\theta, Z}(x) := \frac{\phi_\theta(x)}{Z}$ với Z là tham số học được—thay thế cho $Z(\theta) = \sum_x \phi_\theta(x)$ tốn kém $\mathcal{O}(|\mathcal{X}|)$ mỗi bước gradient. Áp dụng Bayes cho hỗn hợp N mẫu dữ liệu và mN mẫu nhiễu, xác suất hậu

nghiệm:

$$P(\text{data} \mid x) = \frac{q_{\theta,Z}(x)}{q_{\theta,Z}(x) + m\xi(x)}, \quad P(\text{noise} \mid x) = \frac{m\xi(x)}{q_{\theta,Z}(x) + m\xi(x)}. \quad (2)$$

Tối thiểu hóa binary cross-entropy (BCE) giữa nhãn thực $D \in \{1, 0\}$ và hậu nghiệm trên:

$$\mathcal{L} = -\mathbb{E}_{x \sim p} [\log P(\text{data} \mid x)] - m \mathbb{E}_{x \sim \xi} [\log P(\text{noise} \mid x)].$$

Thay (2) vào ta thu được hàm loss NCE:

$$\mathcal{L}_{\text{NCE}}(\theta, Z) = -\mathbb{E}_{s \sim p} \log \frac{q_{\theta,Z}(s)}{q_{\theta,Z}(s) + m\xi(s)} - m \mathbb{E}_{t \sim \xi} \log \frac{m\xi(t)}{q_{\theta,Z}(t) + m\xi(t)}. \quad (3)$$

Định lý 2.1 (Gutmann & Hyvärinen, 2010). *Giả sử ξ có support đầy đủ trên $\mathcal{X}$ (tức $\xi(x) > 0 \forall x$) và tồn tại θ^* sao cho $q_{\theta^*} = p$. Khi đó θ^* là cực tiểu của $\mathcal{L}_{\text{NCE}}(\theta, Z)$, và mọi cực trị khác cũng thỏa $q_{\bar{\theta}} = p$.*

Ý nghĩa: NCE cho kết quả tương đương MLE nhưng *không cần tính* $Z(\theta)$ trực tiếp—tham số Z tự hội tụ về $Z(\theta)$ khi tối ưu.

2.9.3 Lấy mẫu tiêu cực (NEG)

NEG [11] là biến thể đơn giản hóa: bỏ tham số Z , dùng trực tiếp $\phi_{\theta}(x)$ chưa chuẩn hóa:

$$\mathcal{L}_{\text{NEG}}(\theta) = -\mathbb{E}_{x \sim p} \log \frac{\phi_{\theta}(x)}{\phi_{\theta}(x) + 1} - m \mathbb{E}_{x \sim \xi} \log \frac{1}{\phi_{\theta}(x) + 1}. \quad (4)$$

So sánh (3) và (4): NEG tương đương NCE khi chọn ξ đồng đều và *cố định* hằng số chuẩn hóa $\bar{Z} = \frac{|\mathcal{X}|}{m}$, thay vì để Z tự học. Hệ quả: mô hình NEG hội tụ về $q_{\theta^*} = \bar{Z}p$ (phân phối *phóng đại*), không phải p —sự khác biệt này sẽ là chìa khóa giải thích hành vi t-SNE so với UMAP ở Chương 4.

Chương 3 Phương pháp giảm chiều

Chương trình bày nội dung chương giảm chiều trong [12]: PCA, KPCA, học manifold (Isomap, Laplacian eigenmaps, LLE) và bổ đề Johnson–Lindenstrauss. Nhóm bổ sung thêm mục [MỞ

RỘNG] về trực quan hóa phi tuyến (t-SNE, UMAP) theo các bài báo gốc [16, 9]—hai phương pháp này *không* có trong sách.

3.1 Phân tích thành phần chính (PCA)

Cho $k \in \{1, \dots, N\}$ và $\mathbf{X}$ đã căn giữa. PCA tìm ma trận chiếu $\mathbf{P} \in P_k$ sao cho tái tạo sau chiếu gần $\mathbf{X}$ nhất theo chuẩn Frobenius:

$$\min_{\mathbf{P} \in P_k} \|\mathbf{P}\mathbf{X} - \mathbf{X}\|_F^2. \quad (5)$$

Định lý 3.1 (Nghịệm PCA). *Nghịệm $\mathbf{P}^*$ của (5) có dạng $\mathbf{P}^* = \mathbf{U}_k \mathbf{U}_k^\top$, trong đó $\mathbf{U}_k \in \mathbb{R}^{N \times k}$ gồm k vector riêng ứng với k trị riêng lớn nhất của $\mathbf{C} = \frac{1}{m} \mathbf{X}\mathbf{X}^\top$. Biểu diễn k chiều là $\mathbf{Y} = \mathbf{U}_k^\top \mathbf{X}$.*

Chứng minh. Vì $\mathbf{P}$ là phép chiếu trực giao nên $\mathbf{P}^\top = \mathbf{P}$ và $\mathbf{P}^2 = \mathbf{P}$. Khai triển norm và dùng tính tuyến tính của trace:

$$\|\mathbf{P}\mathbf{X} - \mathbf{X}\|_F^2 = \text{Tr}[\mathbf{X}^\top \mathbf{P}^\top \mathbf{P} \mathbf{X} - 2\mathbf{X}^\top \mathbf{P} \mathbf{X} + \mathbf{X}^\top \mathbf{X}] = -\text{Tr}(\mathbf{X}^\top \mathbf{P} \mathbf{X}) + \text{Tr}(\mathbf{X}^\top \mathbf{X}),$$

số hạng thứ hai không phụ thuộc $\mathbf{P}$. Vậy ta cần cực đại $\text{Tr}(\mathbf{X}^\top \mathbf{P} \mathbf{X})$ trên P_k .

Viết $\mathbf{P} = \mathbf{U}\mathbf{U}^\top$ với $\mathbf{U}$ có k cột trực chuẩn. Hoán vị trace cho

$$\text{Tr}(\mathbf{X}^\top \mathbf{P} \mathbf{X}) = \text{Tr}(\mathbf{U}^\top \mathbf{X}\mathbf{X}^\top \mathbf{U}) = \sum_{i=1}^k \mathbf{u}_i^\top \mathbf{X}\mathbf{X}^\top \mathbf{u}_i,$$

với $\mathbf{u}_i$ là cột thứ i của $\mathbf{U}$. Theo định lý Rayleigh–Ritz/Ky Fan, tổng trên đạt cực đại bằng tổng k trị riêng lớn nhất của $\mathbf{X}\mathbf{X}^\top$, khi các cột của $\mathbf{U}$ là k vector riêng tương ứng. Vì $\mathbf{C} = \frac{1}{m} \mathbf{X}\mathbf{X}^\top$ chỉ khác $\mathbf{X}\mathbf{X}^\top$ một hệ số dương $1/m$, các vector riêng tối ưu cũng chính là k vector riêng ứng với k trị riêng lớn nhất của $\mathbf{C}$. Suy ra

$$\mathbf{P}^* = \mathbf{U}_k \mathbf{U}_k^\top, \quad \mathbf{Y} = \mathbf{U}_k^\top \mathbf{X}.$$

□

Cách nhìn theo phương sai. Vector riêng của $\mathbf{C}$ trở theo hướng biến thiên mạnh nhất; trị riêng tương ứng bằng phương sai theo hướng đó. Thành phần chính thứ i là chiếu lên hướng phương sai lớn thứ i , vuông góc các hướng trước.

[MỞ RỘNG] Với $k = 1$, PCA chọn hướng đơn vị $\mathbf{u}$ tối đa $\mathbf{u}^\top \mathbf{C} \mathbf{u}$ —trùng vector riêng hàng đầu sau khi căn giữa dữ liệu.

Bổ đề 3.1 (Phương sai giữ lại và lỗi tái tạo). Gọi $\gamma_1 \geq \dots \geq \gamma_N \geq 0$ là các trị riêng của $\mathbf{C}$. PCA bậc k giữ tổng phương sai $\sum_{i=1}^k \gamma_i$ và đạt lỗi tối thiểu

$$\|\mathbf{P}^* \mathbf{X} - \mathbf{X}\|_F^2 = m \sum_{i=k+1}^N \gamma_i.$$

Tỷ lệ phương sai giải thích bởi k thành phần là $(\sum_{i=1}^k \gamma_i) / (\sum_{i=1}^N \gamma_i)$.

Chứng minh. Từ chứng minh Định lý 3.1, $\text{Tr}(\mathbf{X}^\top \mathbf{P}^* \mathbf{X}) = m \sum_{i=1}^k \gamma_i$. Mặt khác, $\text{Tr}(\mathbf{X}^\top \mathbf{X}) = m \text{Tr}(\mathbf{C}) = m \sum_{i=1}^N \gamma_i$. Thế vào (5) cho biểu thức lỗi. Phần phương sai được giữ chính là tổng trị riêng trên các hướng được chiếu. $\square$

[MỞ RỘNG] Nếu hai trị riêng liên tiếp thỏa $\gamma_k = \gamma_{k+1}$ thì không gian con tối ưu không duy nhất: có thể chọn bất kỳ cơ sở trực chuẩn phù hợp trong không gian riêng đồng trị. Tuy vậy, giá trị lỗi tối ưu trong Bổ đề 3.1 không đổi.

Ví dụ 3.1 (Hai đặc trưng tương quan). Đo cùng một đại lượng (ví dụ cỡ giày) bằng hai thang đơn vị khác nhau. Sau căn giữa, đám điểm gần một đường thẳng; chiếu lên thành phần chính thứ nhất cho một số gần đủ mô tả biến thiên (Hình 2, Chương 2).

Thuật toán PCA từ đầu. Trước hết trừ vector trung bình khỏi mỗi mẫu để tạo $\mathbf{X}$ đã căn giữa; tiếp theo tính $\mathbf{C} = \frac{1}{m} \mathbf{X} \mathbf{X}^\top$ hoặc thực hiện SVD trực tiếp trên $\mathbf{X}$; sau đó chọn k vector riêng lớn nhất làm các cột của $\mathbf{U}_k$; cuối cùng xuất embedding $\mathbf{Y} = \mathbf{U}_k^\top \mathbf{X}$. Dữ liệu xấp xỉ trong không gian gốc là $\hat{\mathbf{X}} = \mathbf{U}_k \mathbf{Y}$. Hiện thực của nhóm dùng thín SVD, do đó nhận $k \leq \min(m, N)$; giới hạn này phù hợp với bài toán giảm chiều đang xét.

3.2 PCA trong không gian kernel (KPCA)

PCA giả định vector đặc trưng nằm trong $\mathbb{R}^N$. Nhiều khi ta chỉ có thể tính tương tự trong không gian $\mathcal{H}$ cao (hoặc vô hạn) chiều qua kernel $K(x, x') = \langle \Phi(x), \Phi(x') \rangle$. KPCA làm PCA trên ma trận Gram $\mathbf{K}$ thay vì $\mathbf{X}$ trực tiếp.

Căn giữa trong không gian đặc trưng. Ngay cả khi các x_i đã căn giữa trong không gian đầu vào, ảnh $\Phi(x_i)$ nhìn chung chưa có trung bình bằng không. Đặt $\bar{\Phi} = \frac{1}{m} \sum_i \Phi(x_i)$, $\tilde{\Phi}(x_i) = \Phi(x_i) - \bar{\Phi}$ và $\mathbf{H} = \mathbf{I}_m - \frac{1}{m} \mathbf{1}\mathbf{1}^\top$. Ma trận Gram của các ảnh đã căn giữa là

$$\tilde{\mathbf{K}} = \mathbf{H}\mathbf{K}\mathbf{H}, \quad K_{ij} = K(x_i, x_j). \quad (6)$$

Với điểm mới x , đặt $\mathbf{k}_x = (K(x_1, x), \dots, K(x_m, x))^\top$. Vector tích vô hướng đã căn giữa giữa các điểm huấn luyện và x là

$$\tilde{\mathbf{k}}_x = \mathbf{k}_x - \frac{1}{m} \mathbf{K}\mathbf{1} - \frac{1}{m} \mathbf{1}\mathbf{1}^\top \mathbf{k}_x + \frac{1}{m^2} \mathbf{1}\mathbf{1}^\top \mathbf{K}\mathbf{1}. \quad (7)$$

Các bước thực hiện.

1. Lập $\mathbf{K}$, $K_{ij} = K(x_i, x_j)$.
2. Căn giữa kernel theo (6).
3. Lấy k cặp trị riêng/vector riêng lớn nhất của $\tilde{\mathbf{K}}$.
4. Với điểm mới x , căn giữa $\mathbf{k}_x$ theo (7). Tọa độ thứ j của x trên thành phần KPCA thứ j là

$$y_j(x) = \frac{\tilde{\mathbf{k}}_x^\top \mathbf{v}_j}{\sqrt{\lambda_j}}.$$

Định lý 3.2 (Tọa độ KPCA). Giả sử $\tilde{\mathbf{K}}\mathbf{v}_j = \lambda_j \mathbf{v}_j$, $\lambda_j > 0$ và $\|\mathbf{v}_j\| = 1$. Hướng thành phần chính đơn vị thứ j trong $\mathcal{H}$ có thể viết

$$\mathbf{w}_j = \frac{1}{\sqrt{\lambda_j}} \sum_{i=1}^m v_{ji} \tilde{\Phi}(x_i).$$

Tọa độ của điểm x lên hướng này bằng

$$y_j(x) = \langle \tilde{\Phi}(x), \mathbf{w}_j \rangle_{\mathcal{H}} = \frac{\tilde{\mathbf{k}}_x^\top \mathbf{v}_j}{\sqrt{\lambda_j}}.$$

Với tập huấn luyện, embedding k chiều có dạng

$$\mathbf{Y} = \mathbf{\Lambda}_k^{1/2} \mathbf{V}_k^\top,$$

trong đó $\mathbf{\Lambda}_k = \text{diag}(\lambda_1, \dots, \lambda_k)$.

Chứng minh. Chuẩn bình phương của hướng được đề xuất là

$$\|\mathbf{w}_j\|_{\mathcal{H}}^2 = \frac{1}{\lambda_j} \mathbf{v}_j^\top \tilde{\mathbf{K}} \mathbf{v}_j = 1.$$

Lấy tích vô hướng với $\tilde{\Phi}(x)$ cho công thức tọa độ. Riêng với $x = x_i$, ta có $\tilde{\mathbf{k}}_{x_i}^\top \mathbf{v}_j = (\tilde{\mathbf{K}} \mathbf{v}_j)_i = \lambda_j v_{ji}$; do đó $y_j(x_i) = \sqrt{\lambda_j} v_{ji}$. Ghép k hàng tọa độ cho toàn bộ mẫu thu được công thức ma trận. $\square$

PCA là trường hợp riêng của KPCA. Khi kernel tuyến tính trên dữ liệu đã căn giữa, $\mathbf{K} = \mathbf{X}^\top \mathbf{X}$. Từ SVD $\mathbf{X} = \mathbf{U} \mathbf{\Sigma} \mathbf{V}^\top$ suy ra

$$\mathbf{C} = \frac{1}{m} \mathbf{U} \mathbf{\Lambda} \mathbf{U}^\top, \quad \mathbf{K} = \mathbf{V} \mathbf{\Lambda} \mathbf{V}^\top, \quad \mathbf{\Lambda} = \mathbf{\Sigma}^2. \quad (8)$$

Nếu $\mathbf{K} \mathbf{v} = \lambda \mathbf{v}$ với $\lambda > 0$, thì $\mathbf{u} = \mathbf{X} \mathbf{v} / \sqrt{\lambda}$ là vector đơn vị và là vector riêng của $\mathbf{C}$ ứng với trị riêng λ/m . Chiếu một chiều lên $\mathbf{u}$ cho

$$\Phi(x)^\top \mathbf{u} = \frac{\mathbf{k}_x^\top \mathbf{v}}{\sqrt{\lambda}}. \quad (9)$$

Nếu $x = x_i$ trong mẫu thì tọa độ bằng $\sqrt{\lambda} v_i$. Toàn bộ KPCA chỉ cần eigendecomposition của $\mathbf{K}$ —PCA là trường hợp $\mathbf{K} = \mathbf{X}^\top \mathbf{X}$.

Ví dụ 3.2 (Kernel cho cấu trúc phi tuyến). Hai vòng tròn đồng tâm trong mặt phẳng không thể tách theo bán kính bởi một phép chiếu tuyến tính một chiều: mọi trục đều trộn lẫn các điểm của hai vòng. Với kernel Gaussian $K(x, x') = \exp(-\gamma \|x - x'\|^2)$, các điểm trên cùng vòng có độ tương tự khác với các điểm ở vòng còn lại. KPCA có thể biểu diễn quan hệ phi tuyến này trong vài thành phần đầu; tham số γ quyết định mức độ “cục bộ” của sự tương tự.

3.3 Học manifold qua KPCA

Giả định dữ liệu cao chiều nằm gần một manifold nhúng. Thay vì chọn kernel “có sẵn”, ta *thiết kế* ma trận tương tự kernel từ đồ thị láng giềng hoặc khoảng cách địa hình, rồi áp dụng cùng khung KPCA (trích vector riêng hàng đầu hoặc nhỏ nhất tùy bài toán).

3.3.1 Isomap

Ý tưởng: giữ khoảng cách “đi bộ” trên manifold, xấp xỉ bằng đường đi ngắn nhất trên đồ thị t -láng giềng [15, 12].

1. Dựng đồ thị vô hướng: nối mỗi điểm với t láng giềng gần nhất (khoảng cách Euclidean).
2. Trong hiện thực, nếu đồ thị bị rời thành nhiều thành phần, nối dần hai thành phần gần nhất bằng cạnh Euclidean ngắn nhất để có thể tính khoảng cách hữu hạn giữa mọi cặp điểm.
3. Tính khoảng cách ngắn nhất δ_{ij} giữa mọi cặp đỉnh (ví dụ Floyd–Warshall).
4. Từ ma trận khoảng cách bình phương Δ , đặt $\mathbf{K}_{\text{Iso}} = -\frac{1}{2}\mathbf{H}\Delta\mathbf{H}$.
5. Lấy k chiều từ k trị riêng dương lớn nhất của $\mathbf{K}_{\text{Iso}}$:

$$\mathbf{Y} = \Sigma_{\text{Iso},k}^{1/2} \mathbf{U}_{\text{Iso},k}^{\top}. \quad (10)$$

Bổ đề 3.2 (Double centering). Cho $\mathbf{Z} = [\mathbf{z}_1, \dots, \mathbf{z}_m]$ là ma trận điểm đã căn giữa, tức $\mathbf{Z}\mathbf{1} = \mathbf{0}$.

Đặt $\Delta_{ij} = \|\mathbf{z}_i - \mathbf{z}_j\|_2^2$ và

$$\mathbf{H} = \mathbf{I}_m - \frac{1}{m}\mathbf{1}\mathbf{1}^{\top}.$$

Khi đó

$$-\frac{1}{2}\mathbf{H}\Delta\mathbf{H} = \mathbf{Z}^{\top}\mathbf{Z}.$$

Chứng minh. Đặt $q_i = \|\mathbf{z}_i\|_2^2$ và $\mathbf{q} = (q_1, \dots, q_m)^{\top}$. Từ khai triển bình phương khoảng cách,

$$\Delta_{ij} = \|\mathbf{z}_i - \mathbf{z}_j\|_2^2 = q_i + q_j - 2\mathbf{z}_i^{\top}\mathbf{z}_j.$$

Dạng ma trận là

$$\Delta = \mathbf{q}\mathbf{1}^{\top} + \mathbf{1}\mathbf{q}^{\top} - 2\mathbf{Z}^{\top}\mathbf{Z}.$$

Vì $\mathbf{H}\mathbf{1} = \mathbf{0}$ nên hai hạng $\mathbf{q}\mathbf{1}^{\top}$ và $\mathbf{1}\mathbf{q}^{\top}$ biến mất khi nhân $\mathbf{H}$ hai phía. Ngoài ra, do $\mathbf{Z}\mathbf{1} = \mathbf{0}$ nên $\mathbf{Z}\mathbf{H} = \mathbf{Z}$. Suy ra

$$-\frac{1}{2}\mathbf{H}\Delta\mathbf{H} = \mathbf{H}\mathbf{Z}^{\top}\mathbf{Z}\mathbf{H} = \mathbf{Z}^{\top}\mathbf{Z}.$$

□

Bổ đề 3.2 giải thích vì sao Isomap xem $\mathbf{K}_{\text{Iso}} = -\frac{1}{2}\mathbf{H}\Delta\mathbf{H}$ như một ma trận Gram: nếu các δ_{ij} xấp xỉ khoảng cách Euclidean trong hệ tọa độ đã “trải phẳng”, phép biến đổi sẽ khôi phục Gram của hệ tọa độ đó. Trong Isomap, Δ_{ij} không lấy từ khoảng cách Euclidean trực tiếp mà từ bình phương khoảng cách đường đi ngắn nhất trên đồ thị láng giềng.


Bổ đề 3.3 (Embedding spectral của Isomap). *Nếu $\mathbf{K}_{\text{Iso}}$ xác định dương bán và có phân rã $\mathbf{K}_{\text{Iso}} = \mathbf{U}\Sigma\mathbf{U}^\top$ với các trị riêng giảm dần, thì ma trận tọa độ*

$$\mathbf{Y} = \Sigma_{\text{Iso},k}^{1/2} \mathbf{U}_{\text{Iso},k}^\top$$

thỏa $\mathbf{Y}^\top\mathbf{Y} = \mathbf{U}_{\text{Iso},k}\Sigma_{\text{Iso},k}\mathbf{U}_{\text{Iso},k}^\top$, là xấp xỉ Gram hạng k tốt nhất của $\mathbf{K}_{\text{Iso}}$ theo chuẩn Frobenius.

Chứng minh. Theo định lý xấp xỉ hạng thấp Eckart–Young, cắt phân rã phổ tại k trị riêng lớn nhất cho xấp xỉ hạng k tối ưu của ma trận đối xứng xác định dương bán. Ma trận $\mathbf{Y}$ ở trên có Gram đúng bằng xấp xỉ bị cắt đó. Kết hợp với Bổ đề 3.2, Gram gần đúng tương ứng với việc giữ gần các khoảng cách bình phương đã cung cấp cho bước MDS. $\square$

Trên mẫu hữu hạn, $\mathbf{K}_{\text{Iso}}$ đôi khi không xác định dương bán vì khoảng cách đồ thị không nhất thiết là khoảng cách Euclidean của một không gian phẳng. Isomap gần với scaling đa chiều cổ điển (MDS) nhưng dùng geodesic thay vì khoảng cách Euclidean trực tiếp. Số láng giềng t cần chọn thận trọng: t quá nhỏ có thể làm đồ thị đứt rời, buộc bước nối thành phần trong hiện thực thêm cạnh ngoài đồ thị láng giềng ban đầu; t quá lớn lại tạo các cạnh tắt xuyên qua manifold.



Hình 3: Isomap: khoảng cách trên manifold được xấp xỉ bằng tổng độ dài cạnh trên đường đi ngắn nhất (nét liền xanh lá), không dùng trực tiếp đoạn thẳng Euclidean (nét đứt).

Ví dụ 3.3 (Trải phẳng Swiss roll). Trên Swiss roll, hai điểm nằm ở hai lớp cuộn kế nhau có thể gần

theo khoảng cách Euclidean nhưng xa nếu đi dọc theo bề mặt. Đồ thị láng giềng loại bỏ phần lớn đường tắt này; khoảng cách đường đi ngắn nhất do đó bám theo mặt cuộn. Bước double centering và phân rã phổ sau đó tạo embedding hai chiều gần với tờ giấy trước khi bị cuộn.

[MỞ RỘNG] Chứng minh double centering ở Bổ đề 3.2 cũng cho thấy Isomap là KPCA với kernel được suy ra từ khoảng cách geodesic. Điểm khác biệt cốt lõi so với KPCA dùng Gaussian kernel là kernel này phụ thuộc vào toàn bộ đồ thị láng giềng và đường đi ngắn nhất, không chỉ vào từng cặp khoảng cách Euclidean ban đầu.

3.3.2 Laplacian eigenmaps

Ưu tiên láng giềng gần trong không gian đầu vẫn gần trong không gian thấp. Trọng số $W_{ij} = \exp\left(-\frac{\|\mathbf{x}_i - \mathbf{x}_j\|^2}{\sigma^2}\right)$ nếu i, j là láng giềng, ngược lại 0. Đặt $\mathbf{D}_{ii} = \sum_j W_{ij}$ và $\mathbf{L} = \mathbf{D} - \mathbf{W}$. Với quy ước $\mathbf{Y} = [\mathbf{y}_1, \dots, \mathbf{y}_m] \in \mathbb{R}^{k \times m}$, bài toán chuẩn hóa là

$$\min_{\mathbf{Y}} \frac{1}{2} \sum_{i,j} W_{ij} \|\mathbf{y}_i - \mathbf{y}_j\|^2 = \text{tr}(\mathbf{Y} \mathbf{L} \mathbf{Y}^\top), \quad \text{s.t. } \mathbf{Y} \mathbf{D} \mathbf{Y}^\top = \mathbf{I}_k, \quad \mathbf{Y} \mathbf{D} \mathbf{1} = \mathbf{0}, \quad (11)$$

Ràng buộc loại nghiệm suy biến trong đó mọi điểm cùng trùng nhau. Nghiệm tổng quát lấy các vector riêng không tầm thường nhỏ nhất của bài toán $\mathbf{L} \mathbf{u} = \lambda \mathbf{D} \mathbf{u}$. Cài đặt của nhóm sử dụng biến thể không chuẩn hóa, giải trực tiếp $\mathbf{L} \mathbf{u} = \lambda \mathbf{u}$ và lấy k vector riêng sau vector hằng ứng với trị riêng 0 khi đồ thị liên thông. Có thể hiểu là KPCA với kernel liên quan $\mathbf{K}_L = \mathbf{L}^\dagger$: phạt nặng khi hai điểm láng giềng bị đẩy xa trong không gian thấp [2].

3.3.3 Locally Linear Embedding (LLE)

Mỗi $\mathbf{x}_i$ được xấp xỉ tuyến tính bởi láng giềng:

$$\min_{\sum_j W_{ij}=1} \left\| \mathbf{x}_i - \sum_{j \in \mathcal{N}_i} W_{ij} \mathbf{x}_j \right\|^2.$$

Khai triển cho hệ số W_{ij} dẫn tới ma trận hiệp phương sai cục bộ $\mathbf{C}'$ và

$$W_{ij} = \frac{\sum_{k \in \mathcal{N}_i} (\mathbf{C}'^{-1})_{jk}}{\sum_{s,t \in \mathcal{N}_i} (\mathbf{C}'^{-1})_{st}}. \quad (12)$$

Sau khi cố định $\mathbf{W}$, tìm $\mathbf{y}_i$ sao cho quan hệ tái tạo tuyến tính được giữ:

$$\min \sum_i \left\| \mathbf{y}_i - \sum_j W_{ij} \mathbf{y}_j \right\|^2,$$

kèm các ràng buộc định tâm và chuẩn hóa để loại nghiệm suy biến. Theo quy ước mỗi hàng của $\mathbf{W}$ chứa trọng số tái tạo một mẫu như trong cài đặt, ta có

$$\mathbf{M} = (\mathbf{I} - \mathbf{W})^\top (\mathbf{I} - \mathbf{W}).$$

Embedding gồm k vector riêng ứng với các trị riêng nhỏ nhất khác 0 của $\mathbf{M}$. LLE cũng có dạng KPCA với kernel xây từ $\mathbf{W}$ [14].

3.4 Trục quan hóa phi tuyến: t-SNE và UMAP

[MỞ RỘNG] Phần sau không có trong [12]. Các phương pháp ở Mục 3.3 tìm $\mathbf{Y}$ bằng phân rã phổ trên đồ thị (tối ưu tuyến tính). Ở đây ta tối ưu trực tiếp từng tọa độ nhúng $\mathbf{y}_i \in \mathbb{R}^d$ với $d \ll D$ (thường $d = 2$) để vẽ trục quan [16, 9].

3.4.1 t-Distributed Stochastic Neighbor Embedding (t-SNE)

Cho $\mathcal{X} = \{\mathbf{x}_i\}_{i=1}^N \subset \mathbb{R}^D$. t-SNE [16] so khớp hai phân phối láng giềng: một trên $\mathcal{X}$, một trên $\{\mathbf{y}_i\}$.

Bước 1 — Láng giềng trong không gian gốc. Với mỗi i , xác suất “ j là láng giềng của i ” dùng nhân tử Gaussian; σ_i chọn sao cho *perplexity* (mức láng giềng hiệu dụng) cố định:

$$p_{j|i} = \frac{\exp\left(-\frac{\|\mathbf{x}_i - \mathbf{x}_j\|^2}{2\sigma_i^2}\right)}{\sum_{k \neq i} \exp\left(-\frac{\|\mathbf{x}_i - \mathbf{x}_k\|^2}{2\sigma_i^2}\right)}.$$

Về mặt thông tin, nếu P_i là phân phối có các xác suất $p_{j|i}$ thì

$$\text{Perp}(P_i) = 2^{H(P_i)}, \quad H(P_i) = - \sum_{j \neq i} p_{j|i} \log_2 p_{j|i}.$$

Perplexity có thể hiểu như số láng giềng hiệu dụng của điểm i . Trong thực hành, σ_i được tìm bằng tìm kiếm nhị phân sao cho entropy của P_i phù hợp với perplexity đã chọn: perplexity nhỏ nhấn mạnh cấu trúc rất cục bộ, còn perplexity lớn nhìn nhiều láng giềng hơn. Ma trận đối xứng $p_{ij} = \frac{p_{j|i} + p_{i|j}}{2N}$ dùng khi tính phân kỳ.

Bước 2 — Láng giềng trong không gian nhúng. Dùng Student- t (đuôi nặng) thay Gaussian để giảm *crowding* (điểm chen chúc khi d nhỏ):

$$q_{ij} = \frac{(1 + \|\mathbf{y}_i - \mathbf{y}_j\|^2)^{-1}}{\sum_{k \neq \ell} (1 + \|\mathbf{y}_k - \mathbf{y}_\ell\|^2)^{-1}}.$$

Khi giảm từ không gian cao chiều xuống hai chiều, không gian nhúng thường không đủ “diện tích” để giữ tất cả láng giềng gần nhau như ban đầu. Đuôi nặng của Student- t giúp các điểm tương đối xa trong không gian nhúng vẫn tạo lực đẩy đáng kể, nhờ đó các cụm ít bị nén chồng lên nhau.

Bước 3 — Tối ưu. Tìm $\{\mathbf{y}_i\}$ sao cho q_{ij} gần p_{ij} theo phân kỳ KL:

$$\min_{\{\mathbf{y}_i\}} \text{KL}(P\|Q) = \sum_{i \neq j} p_{ij} \log \frac{p_{ij}}{q_{ij}}.$$

Phân kỳ KL ở đây là bất đối xứng: nếu p_{ij} lớn nhưng q_{ij} nhỏ, tức là hai điểm gần trong không gian gốc bị đặt xa trong nhúng, chi phí tăng mạnh. Ngược lại, hai điểm xa trong không gian gốc bị đặt gần nhau thường bị phạt yếu hơn. Vì vậy t-SNE đặc biệt phù hợp để bảo toàn cấu trúc cục bộ và trực quan hóa cụm, nhưng khoảng cách giữa các cụm hoặc kích thước cụm trong hình 2D không nên được diễn giải như khoảng cách toàn cục thật.

Gradient của hàm mục tiêu có dạng lực hút–đẩy:

$$\frac{\partial \text{KL}(P\|Q)}{\partial \mathbf{y}_i} = 4 \sum_j (p_{ij} - q_{ij})(\mathbf{y}_i - \mathbf{y}_j) (1 + \|\mathbf{y}_i - \mathbf{y}_j\|^2)^{-1}.$$

Khi $p_{ij} > q_{ij}$, cặp điểm bị kéo lại gần nhau; khi $p_{ij} < q_{ij}$, cặp điểm bị đẩy ra xa. Cập nhật thường dùng gradient descent với momentum, early exaggeration ở giai đoạn đầu và learning rate thích hợp. Barnes–Hut xấp xỉ lực với độ phức tạp $O(N \log N)$; các cài đặt hiện đại còn có thể dùng FFT/interpolation để tăng tốc.

Algorithm 1 t-SNE (tóm tắt)

Require: Tập $\mathbf{X}$, số chiều nhúng d , perplexity, số vòng lặp

- 1: Tính ma trận p_{ij} (Gaussian có σ_i theo perplexity)
 - 2: Khởi tạo ngẫu nhiên $\mathbf{y}_i \in \mathbb{R}^d$
 - 3: **for** mỗi vòng lặp **do**
 - 4: Tính q_{ij} từ khoảng cách Student- t giữa các $\mathbf{y}_i$
 - 5: Cập nhật $\mathbf{y}_i \leftarrow \mathbf{y}_i - \eta \frac{\partial \text{KL}}{\partial \mathbf{y}_i}$
 - 6: **end for**
 - 7: **return** $\{\mathbf{y}_i\}$
-

Trong mã nguồn của đồ án, t-SNE được dùng như một baseline mở rộng thông qua wrapper TSNE quanh `sklearn.manifold.TSNE`, không phải phần cài đặt from-scratch. Các tham số chính được truyền từ notebook là `perplexity`, `max_iter`, `init` và `learning_rate`; kết quả thực nghiệm tương ứng được báo cáo ở Mục [Chương 5](#).

3.4.2 Uniform Manifold Approximation and Projection (UMAP)

Ý tưởng chính. UMAP [9] giải quyết bài toán: cho tập dữ liệu cao chiều (D chiều), tìm cách biểu diễn chúng trong không gian thấp chiều ($d = 2$ hoặc 3) để trực quan hóa, sao cho *những điểm gần nhau trong không gian gốc vẫn gần nhau, và những điểm xa nhau vẫn xa nhau* trong không gian mới.

Cách tiếp cận: (1) mô hình hóa quan hệ láng giềng bằng một *đồ thị có trọng số mờ* trong không gian gốc, (2) tìm tọa độ mới sao cho đồ thị mờ tương ứng trong không gian thấp giống đồ thị gốc nhất có thể.

Ý nghĩa.

- Giữ được cả cấu trúc *cục bộ* (láng giềng gần) lẫn *toàn cục* (quan hệ giữa các cụm) tốt hơn t-SNE.
- Nhanh hơn t-SNE trên dữ liệu lớn nhờ tối ưu SGD trên đồ thị thưa.
- Dùng để trực quan hóa dữ liệu cao chiều (giảm về 2D/3D).

Ba giả định. UMAP dựa trên giả định manifold (Định nghĩa 2.5) và cấu trúc tô-pô (Định nghĩa 2.6) đã trình bày ở Chương 2. UMAP giả định mẫu $\mathcal{X} = \{\mathbf{x}_i\}_{i=1}^N \subset \mathbb{R}^D$ nằm trên một đa tạp (M, g) chưa biết, với:

1. **Phân bố đều:** dữ liệu trải đều trên M (vùng nào cũng có mật độ tương đương).
2. **Metric gần hằng cục bộ:** trong vùng nhỏ, khoảng cách trên manifold $\approx$ khoảng cách Euclid (sau chuẩn hóa tỉ lệ).
3. **Liên thông cục bộ:** từ mỗi điểm luôn tồn tại đường đi trên M tới các láng giềng.

Khi dữ liệu thực tế không đều, UMAP tự điều chỉnh thước đo cục bộ (ρ_i, σ_i) quanh từng điểm để “cân bằng” vùng thưa và vùng dày.

Các bước thực hiện. Bước 1 — Xây đồ thị mờ cục bộ (“ai là láng giềng của ai, ở mức nào?”)

Với mỗi điểm $\mathbf{x}_i$, tìm n láng giềng gần nhất $\mathcal{N}_i$. Gọi $d_{ij} = \|\mathbf{x}_i - \mathbf{x}_j\|$. Tính:

$$\rho_i = \min\{d_{ij} : d_{ij} > 0, j \in \mathcal{N}_i\}, \quad (13)$$

$$v_{j|i} = \exp\left(\frac{-\max(0, d_{ij} - \rho_i)}{\sigma_i}\right), \quad (14)$$

trong đó σ_i được chọn bằng tìm kiếm nhị phân sao cho $\sum_{j \in \mathcal{N}_i} v_{j|i} = \log_2 n$.

Giải thích trực quan:

- ρ_i = khoảng cách tới láng giềng gần nhất. Trừ đi ρ_i để đảm bảo luôn có ít nhất một cạnh với trọng số = 1 (liên thông cục bộ).
- σ_i = “bán kính nhìn” của $\mathbf{x}_i$. Vùng thưa $\rightarrow \sigma_i$ lớn (nhìn xa hơn); vùng dày $\rightarrow \sigma_i$ nhỏ.
- $v_{j|i} \in [0, 1]$ = mức tin cậy rằng “ j là láng giềng thực sự của i ”. Gần $\rightarrow$ gần 1; xa $\rightarrow$ gần 0.

Bước 2 — Hợp thành đồ thị toàn cục (đối xứng hóa)

Vì $v_{j|i}$ và $v_{i|j}$ thường khác nhau (mỗi điểm có “góc nhìn” riêng), UMAP đối xứng hóa bằng phép hợp xác suất:

$$B_{ij} = v_{j|i} + v_{i|j} - v_{j|i} v_{i|j}. \quad (15)$$

Ý nghĩa: B_{ij} cao khi *ít nhất một trong hai* điểm coi điểm kia là láng giềng mạnh. Ma trận $\mathbf{B}$ mô tả toàn bộ cấu trúc tô-pô của dữ liệu gốc.

Bước 3 — Khởi tạo spectral (vị trí ban đầu trong 2D)

Dùng Laplacian chuẩn hóa $\mathbf{L} = \mathbf{D}^{-\frac{1}{2}}(\mathbf{D} - \mathbf{B})\mathbf{D}^{-\frac{1}{2}}$ (với $D_{ii} = \sum_j B_{ij}$); lấy d vector riêng ứng d trị riêng nhỏ nhất (bỏ trivial) làm tọa độ ban đầu $\mathbf{Y}$. Bước này cho layout ban đầu đã phản ánh sơ bộ cấu trúc toàn cục, giúp SGD hội tụ nhanh hơn.

Bước 4 — Tối ưu nhúng bằng SGD (“kéo gần, đẩy xa”)

Trong không gian nhúng, độ tương đồng giữa $\mathbf{y}_i$ và $\mathbf{y}_j$ được định nghĩa:

$$w_{ij} = \frac{1}{1 + a d_{ij}^{2b}}, \quad d_{ij} = \|\mathbf{y}_i - \mathbf{y}_j\|,$$

với $a, b > 0$ được chọn từ tham số `min_dist`. Hàm w_{ij} có dạng Student- t : gần $\rightarrow w_{ij} \approx 1$; xa $\rightarrow w_{ij} \approx 0$.

UMAP tối thiểu *fuzzy cross-entropy* giữa hai tập mờ cạnh: B_{ij} (không gian gốc) và w_{ij} (không gian nhúng):

$$C = - \sum_{i,j} (B_{ij} \log w_{ij} + (1 - B_{ij}) \log(1 - w_{ij})). \quad (16)$$

Tại sao cross-entropy? Với mỗi cạnh (i, j) , ta có hai “xác suất tồn tại”: B_{ij} (từ dữ liệu gốc) và w_{ij} (từ nhúng). Mỗi giá trị định nghĩa một phân phối Bernoulli (“cạnh tồn tại” hoặc “không”). Cross-entropy (16) đo *sự khác nhau* giữa 2 phân phối này:

- Số hạng $B_{ij} \log w_{ij}$: phạt khi cạnh mạnh trong không gian gốc (B_{ij} lớn) nhưng yếu trong không gian nhúng (w_{ij} nhỏ)—tức hai điểm *gần nhau bị đặt xa* $\rightarrow$ tạo **lực hút**.
- Số hạng $(1 - B_{ij}) \log(1 - w_{ij})$: phạt khi cạnh yếu trong không gian gốc (B_{ij} nhỏ) nhưng mạnh trong không gian nhúng (w_{ij} lớn)—tức hai điểm *xa nhau bị đặt gần* $\rightarrow$ tạo **lực đẩy**.

So sánh: t-SNE dùng $\text{KL}(P\|Q) = \sum p_{ij} \log \frac{p_{ij}}{q_{ij}}$, chỉ có số hạng dạng “hút”—chỉ phạt khi điểm gần bị đặt xa, nhưng *không trực tiếp* phạt khi điểm xa bị đặt gần (lực đẩy của t-SNE đến gián tiếp qua chuẩn hóa q_{ij}). UMAP cân bằng cả hai chiều nhờ cross-entropy, giúp giữ cấu trúc toàn cục tốt hơn [9].

Gradient của cross-entropy (16) tách thành lực hút (kéo lảng giềng gần nhau) và lực đẩy (tách các cặp không lảng giềng). Khai triển chi tiết gradient và cơ chế cập nhật SGD xem tại Phụ lục 1.2. Learning rate η giảm tuyến tính qua các epoch (simulated annealing).

Tóm tắt pipeline.

1. Tìm n láng giềng $\rightarrow$ tính $\rho_i, \sigma_i \rightarrow$ trọng số mờ $v_{j|i}$.
2. Hợp mờ $\rightarrow$ ma trận kề toàn cục $\mathbf{B}$.
3. Khởi tạo $\mathbf{Y}$ bằng spectral embedding trên $\mathbf{B}$.
4. SGD: lực hút giữ láng giềng gần, lực đẩy tách các cụm xa.

So sánh t-SNE và UMAP. Cùng mục tiêu trực quan hóa nhưng khác mô hình: t-SNE so khớp p_{ij} và q_{ij} bằng $\text{KL}(P\|Q)$; UMAP so khớp B_{ij} và w_{ij} bằng C trên fuzzy set. UMAP thường nhanh hơn trên dữ liệu lớn (SGD cạnh thừa) và thường giữ cấu trúc toàn cục tốt hơn; t-SNE thường tách cụm cục bộ rõ hơn [9, 16]. Bảng 1 tóm tắt toàn bộ các hướng giảm chiều trong chương.

Bảng 1: Các hướng giảm chiều trong chương

Phương pháp	Tính chất	Ma trận cốt lõi	Giữ gì
PCA	Tuyến tính	$\mathbf{K} = \mathbf{X}^\top \mathbf{X}$	Phương sai toàn cục
KPCA	Phi tuyến (kernel)	$\mathbf{K}$ tùy chọn	Cấu trúc kernel
Isomap	Manifold	$\mathbf{K}_{\text{Iso}}$ từ geodesic	Khoảng cách toàn cục (xấp xỉ)
Laplacian	Manifold	$\mathbf{L}, \mathbf{K}_L$	Láng giềng cục bộ
LLE	Manifold	$\mathbf{W}, \mathbf{M}$	Tái tạo tuyến tính cục bộ
t-SNE	Phi tuyến	p_{ij}, q_{ij} (KL)	Cụm cục bộ, trực quan
UMAP	Phi tuyến	B_{ij}, w_{ij} (CE)	Cục bộ + toàn cục (tương đối)
Chiều ngẫu nhiên	Ngẫu nhiên	$\frac{\mathbf{A}}{\sqrt{k}}$	Khoảng cách cặp (JL)

3.5 Bổ đề Johnson–Lindenstrauss

Khác với PCA (tối ưu phương sai), bổ đề Johnson–Lindenstrauss (JL) trả lời câu hỏi: với m điểm cố định trong $\mathbb{R}^N$, có thể chiếu tuyến tính xuống $\mathbb{R}^k$ với k nhỏ đến mức nào mà mọi khoảng cách cặp chỉ bị méo hệ số $(1 \pm \varepsilon)$?

Bổ đề 3.4 (Tập trung phân phối χ^2). Với $\varepsilon \in (0, 1)$ và $Z_1, \dots, Z_k$ i.i.d. $\mathcal{N}(0, 1)$, đặt $S = \sum_{i=1}^k Z_i^2$. Khi đó

$$\Pr\left(\left|\frac{S}{k} - 1\right| > \varepsilon\right) \leq 2e^{-\frac{\varepsilon^2 k}{4}}.$$

Chứng minh dùng bất đẳng thức Chernoff cho MGF của phân phối χ^2 ; xem chi tiết tại Phụ lục 1.1.

Định lý 3.3 (Johnson–Lindenstrauss). Cho $0 < \varepsilon < 1$ và tập hữu hạn $\mathcal{V} = \{\mathbf{v}_1, \dots, \mathbf{v}_m\} \subset \mathbb{R}^N$. Nếu $k > \frac{8 \log m}{\varepsilon^2}$, thì tồn tại ánh xạ $f: \mathbb{R}^N \rightarrow \mathbb{R}^k$ sao cho mọi $\mathbf{u}, \mathbf{v} \in \mathcal{V}$,

$$(1 - \varepsilon)\|\mathbf{u} - \mathbf{v}\|^2 \leq \|f(\mathbf{u}) - f(\mathbf{v})\|^2 \leq (1 + \varepsilon)\|\mathbf{u} - \mathbf{v}\|^2.$$

Chứng minh. Xét một ma trận ngẫu nhiên $\mathbf{R} \in \mathbb{R}^{k \times N}$ với $R_{ij} \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(0, 1)$. Các hàng $\mathbf{r}_i^\top$ của $\mathbf{R}$ là vector Gaussian độc lập trong $\mathbb{R}^N$. Đặt $f(\mathbf{x}) = \frac{1}{\sqrt{k}} \mathbf{R}\mathbf{x}$, ta sẽ chứng minh tồn tại ánh xạ f như vậy thỏa mãn bổ đề.

Với $\mathbf{x} \in \mathbb{R}^N$ bất kỳ, viết $\mathbf{R}\mathbf{x} = (\mathbf{r}_1^\top \mathbf{x}, \dots, \mathbf{r}_k^\top \mathbf{x})^\top$, nên

$$\|\mathbf{R}\mathbf{x}\|^2 = \sum_{i=1}^k (\mathbf{r}_i^\top \mathbf{x})^2.$$

Vì $\mathbf{r}_i^\top \sim \mathcal{N}(0, \mathbf{I}_N)$ nên $\mathbf{r}_i^\top \mathbf{x} \sim \mathcal{N}(0, \|\mathbf{x}\|^2)$, tức $\mathbf{r}_i^\top \mathbf{x} = \|\mathbf{x}\| Z_i$ với $Z_i \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(0, 1)$. Đặt $S = \sum_{i=1}^k Z_i^2 \sim \chi_k^2$, ta có

$$\frac{\|\mathbf{R}\mathbf{x}\|^2}{\|\mathbf{x}\|^2} = S \Rightarrow \|f(\mathbf{x})\|^2 = \frac{\|\mathbf{R}\mathbf{x}\|^2}{k} = \frac{S}{k} \|\mathbf{x}\|^2.$$

Áp dụng Bổ đề 3.4 với $S = \frac{1}{\|\mathbf{x}\|^2} \|\mathbf{R}\mathbf{x}\|^2$ suy ra

$$\Pr\left(\left|\frac{S}{k} - 1\right| > \varepsilon\right) \leq 2e^{-\frac{\varepsilon^2 k}{4}}.$$

Đặt $\mathbf{x} = \mathbf{u} - \mathbf{v}$. Vì f tuyến tính, $f(\mathbf{u}) - f(\mathbf{v}) = f(\mathbf{u} - \mathbf{v})$, nên

$$\Pr((1 - \varepsilon)\|\mathbf{u} - \mathbf{v}\|^2 \leq \|f(\mathbf{u}) - f(\mathbf{v})\|^2 \leq (1 + \varepsilon)\|\mathbf{u} - \mathbf{v}\|^2) \geq 1 - 2e^{-\frac{\varepsilon^2 k}{4}}.$$

Gọi $A_{\mathbf{u}, \mathbf{v}}$ là sự kiện khoảng cách cặp $(\mathbf{u}, \mathbf{v})$ được bảo toàn (bất đẳng thức trên), và $A = \bigcap_{\mathbf{u} \neq \mathbf{v}} A_{\mathbf{u}, \mathbf{v}}$.

Với $\binom{m}{2}$ cặp,

$$\Pr(A^c) = \Pr\left(\bigcup_{\mathbf{u} \neq \mathbf{v}} A_{\mathbf{u}, \mathbf{v}}^c\right) \leq \binom{m}{2} \cdot 2e^{-\frac{\varepsilon^2 k}{4}} < m^2 e^{-\frac{\varepsilon^2 k}{4}}.$$


Để $\Pr(A) > 0$ (tức tồn tại $\mathbf{R}$ thỏa mọi cặp), cần $m^2 e^{-\frac{\varepsilon^2 k}{4}} < 1$, tương đương

$$k > \frac{4 \cdot 2 \log m}{\varepsilon^2} = \frac{8 \log m}{\varepsilon^2}.$$

Vậy với k như giả thiết định lý, xác suất chọn được $\mathbf{R}$ phù hợp là dương, nên ánh xạ f như vậy tồn tại. $\square$

Ý nghĩa. JL cho phép giảm N xuống $k \approx \log m$ (bỏ qua hệ số $\frac{1}{\varepsilon^2}$) mà vẫn giữ hình học cặp điểm—cơ sở cho *random projection* làm tiền xử lý nhanh, không cần SVD. Trong sách [12] dùng hằng số 20 thay cho 8; điều kiện $k > \frac{8 \log m}{\varepsilon^2}$ ở trên là phiên bản tinh gọn từ lập luận union bound ở Bước 4.

Ví dụ 3.4. Với $m = 1000$, $\varepsilon = 0,1$, ngưỡng $k > \frac{8 \ln(1000)}{0,01} \approx 5,5 \times 10^3$. Trên thực nghiệm, random projection có thể được dùng như một baseline nhanh để so sánh với PCA. Tuy nhiên, trong báo cáo này phần thực nghiệm chính tập trung vào PCA, KPCA và Isomap; LLE, Laplacian Eigenmaps, t-SNE và UMAP được ghi nhận như các đối chiếu bổ sung trong notebook.



Hình 4: Chiếu ngẫu nhiên Johnson–Lindenstrauss: giảm chiều với bảo đảm trên khoảng cách cặp.

[MỞ RỘNG] Độ phức tạp (ước lượng). SVD đầy đủ $\mathbf{X}$: $O(\min(Nm^2, N^2m))$. Floyd–Warshall: $O(m^3)$. Eigendecomposition Laplacian thưa: gần tuyến tính theo số cạnh. Chiếu JL: nhân ma trận $O(kNm)$, không cần SVD—phù hợp tiền xử lý nhanh khi chỉ cần giữ khoảng cách cặp.

3.6 Mối liên hệ trong chương

PCA là nền tảng tuyến tính: tối ưu lỗi tái tạo hoặc phương sai. KPCA thay $\mathbf{X}$ bằng $\mathbf{K}$, mở đường cho kernel tùy biến. Isomap, Laplacian, LLE *thiết kế* $\mathbf{K}$ (hoặc ma trận liên hệ) từ geometry đồ thị rồi dùng cùng khung phân rã phổ. Phần **[MỞ RỘNG]** t-SNE và UMAP (Mục 3.4) chuyển sang tối ưu phi tuyến trực tiếp trên nhúng, phù hợp trực quan hóa. JL không tìm trực tiếp tối ưu mà chứng minh chiếu ngẫu nhiên đủ tốt—hữu ích khi ưu tiên tốc độ và bảo đảm đơn giản.

Các mảng kiến thức liên quan trong học máy: phương pháp kernel (ánh xạ ngầm Φ), đại số ma trận (SVD, trace, PSD), và học có giám sát có thể dùng $\mathbf{Y}$ làm đầu vào cho mô hình sau. Tài liệu gốc [12] trình bày đầy đủ hơn; báo cáo này tập trung diễn giải và chứng minh các mắt xích chính.

Chương 4 Một số hướng nghiên cứu

Chương này trình bày bài báo khoa học gần đây liên quan tới giảm chiều dữ liệu. Kiến thức nền về NCE và NEG đã trình bày ở Chương 2 (Mục 2.9); các phương pháp giảm chiều (PCA, KPCA, t-SNE, UMAP, ...) ở Chương 3 (Mục 3.4). Chương này *không* lặp lại các định nghĩa đó mà tham chiếu trực tiếp.

4.1 Thống nhất t-SNE và UMAP qua học tương phản

Bài báo *From t-SNE to UMAP with contrastive learning* của Damrich, Böhm, Hamprecht và Kobak [5] (ICLR 2023) đặt ra câu hỏi: **mối quan hệ toán học chính xác giữa t-SNE và UMAP là gì?** Hai phương pháp được xây dựng từ nền tảng đường như khác nhau—KL divergence (MLE) vs. fuzzy cross-entropy (negative sampling)—nhưng bài báo chỉ ra rằng chiếc cầu nối là *học tương phản* (contrastive learning).

4.1.1 Khung nhúng láng giềng tương phản

Thiết lập chung. Cho n điểm $\mathbf{x}_1, \dots, \mathbf{x}_n \in \mathbb{R}^D$ và tọa độ nhúng $\theta = \{\mathbf{y}_1, \dots, \mathbf{y}_n\} \subset \mathbb{R}^d$. Định nghĩa *không gian cặp*:

$$\mathcal{X} = \{(i, j) : 1 \leq i < j \leq n\}, \quad |\mathcal{X}| = \binom{n}{2}. \quad (17)$$

Từ đồ thị k -láng giềng đối xứng (skNN), xây dựng phân phối dữ liệu p trên $\mathcal{X}$: $p(ij) > 0$ trên các cạnh skNN (chuẩn hóa $\sum_{ij} p(ij) = 1$) và $p(ij) = 0$ với các cặp còn lại. Nhiễu ξ là phân phối đồng đều trên $\mathcal{X}$.

Kernel hạ chiều $\phi : \mathbb{R}_{\geq 0} \rightarrow (0, 1]$ biến khoảng cách $d_{ij} = \|\mathbf{y}_i - \mathbf{y}_j\|$ thành “xác suất tương đồng”.

Phân phối mô hình:

$$q_{\theta, Z}(ij) = \frac{\phi(d_{ij})}{Z}, \quad Z(\theta) = \sum_{(k, l) \in \mathcal{X}} \phi(d_{kl}). \quad (18)$$

Phương pháp	Kernel $\phi(d)$	Hằng số Z	Khung tối ưu	Nghiệm q^*
t-SNE	$\frac{1}{1+d^2}$	$Z(\theta)$ (tính đủ)	MLE	p
NC-t-SNE	$\frac{1}{1+d^2}$	Z (học được)	NCE	p
Neg-t-SNE	$\frac{1}{1+d^2}$	$\bar{Z}$ (tùy chọn)	NEG	$\bar{Z} p$
UMAP (hiệu dụng)	$\frac{1}{d^2}$	$\frac{\binom{n}{2}}{m}$ (cố định)	NEG	$\bar{Z} p$

4.1.2 Bước 1 — t-SNE là MLE; NC-t-SNE xấp xỉ t-SNE bằng NCE

t-SNE = MLE. Hàm loss t-SNE là cross-entropy (tương đương MLE) giữa p và $q_{\theta, Z(\theta)}$:

$$\mathcal{L}_{\text{t-SNE}}(\theta) = - \sum_{(i,j) \in \mathcal{X}} p(ij) \log q_{\theta, Z(\theta)}(ij) = - \sum_{ij} p(ij) \log \frac{\phi(d_{ij})}{Z(\theta)}. \quad (19)$$

Mỗi bước gradient đòi hỏi tính $Z(\theta) = \sum_{kl} \phi(d_{kl})$ trên toàn bộ $\binom{n}{2}$ cặp—chi phí $\mathcal{O}(n^2)$ mỗi epoch.

NC-t-SNE = NCE cho bài toán nhúng. Áp dụng NCE (Mục 2.9.2) với không gian $\mathcal{X}$, phân phối p , nhiễu ξ đồng đều, và mô hình $q_{\theta, Z}$ từ (18) (với Z là *tham số học được*). Thay vào loss NCE (3):

$$\mathcal{L}_{\text{NC-t-SNE}}(\theta, Z) = -\mathbb{E}_{ij \sim p} \log \frac{\frac{\phi(d_{ij})}{Z}}{\frac{\phi(d_{ij})}{Z} + m\xi(ij)} - m \mathbb{E}_{ij \sim \xi} \log \frac{m\xi(ij)}{\frac{\phi(d_{ij})}{Z} + m\xi(ij)}. \quad (20)$$

Theo Định lý 2.1, mọi cực tiểu (θ^*, Z^*) thỏa $q_{\theta^*, Z^*} = p$, tức Z^* hội tụ đúng về $Z(\theta^*)$. **Kết luận:** NC-t-SNE có cùng nghiệm tối ưu như t-SNE nhưng *không* phải tính $Z(\theta)$ trực tiếp.

4.1.3 Bước 2 — Cố định Z : từ NCE đến NEG

Bước từ NCE sang NEG—cố định $Z \leftarrow \bar{Z}$ thay vì để Z tự học—là bước *duy nhất* làm thay đổi nghiệm tối ưu, và là chìa khóa giải thích sự khác biệt hình thái giữa t-SNE và UMAP.

Định lý 4.1 (Hệ quả 2 — Damrich et al., 2023). Cho $\bar{Z}$, $m > 0$. Giả sử $\xi(x) > 0 \forall x \in \mathcal{X}$ và tồn

tại θ^* sao cho $q_{\theta^*} = \bar{Z} p$. Khi đó θ^* là cực tiểu (và mọi cực trị) của:

$$\mathcal{L}_{\bar{Z}}(\theta) = -\mathbb{E}_{x \sim p} \log \frac{q_{\theta}(x)}{q_{\theta}(x) + \bar{Z} m \xi(x)} - m \mathbb{E}_{x \sim \xi} \log \frac{\bar{Z} m \xi(x)}{q_{\theta}(x) + \bar{Z} m \xi(x)}. \quad (21)$$

Chứng minh. Đặt $\tilde{q}_{\theta}(x) := \frac{q_{\theta}(x)}{\bar{Z}}$. Chia cả tử và mẫu trong mỗi logarit của (21) cho $\bar{Z}$:

$$\begin{aligned} \frac{q_{\theta}(x)}{q_{\theta}(x) + \bar{Z} m \xi(x)} &= \frac{\frac{q_{\theta}(x)}{\bar{Z}}}{\frac{q_{\theta}(x)}{\bar{Z}} + m \xi(x)} = \frac{\tilde{q}_{\theta}(x)}{\tilde{q}_{\theta}(x) + m \xi(x)}, \\ \frac{\bar{Z} m \xi(x)}{q_{\theta}(x) + \bar{Z} m \xi(x)} &= \frac{m \xi(x)}{\frac{q_{\theta}(x)}{\bar{Z}} + m \xi(x)} = \frac{m \xi(x)}{\tilde{q}_{\theta}(x) + m \xi(x)}. \end{aligned}$$

Do đó $\mathcal{L}_{\bar{Z}}(\theta) \equiv \mathcal{L}_{\text{NCE}}[\tilde{q}_{\theta}]$ —đúng dạng loss NCE chuẩn (3) áp dụng cho mô hình $\tilde{q}_{\theta}$. Theo Định lý 2.1, cực tiểu đạt khi $\tilde{q}_{\theta^*} = p$, tức $q_{\theta^*} = \bar{Z} p$. $\square$

NEG là trường hợp riêng $\bar{Z} = \frac{|\mathcal{X}|}{m}$. Với ξ đồng đều ($\xi(x) = \frac{1}{|\mathcal{X}|}$), hệ số nhiễu trong (21) rút gọn:

$$\bar{Z} m \xi(x) = \frac{|\mathcal{X}|}{m} \cdot m \cdot \frac{1}{|\mathcal{X}|} = 1,$$

và mẫu số trở thành $q_{\theta}(x) + 1$ —đúng dạng loss NEG (4) (với $\phi_{\theta} \leftarrow q_{\theta}$). Theo Định lý 4.1, nghiệm NEG thỏa $q_{\theta^*} = \bar{Z} p$ với $\bar{Z} = \frac{|\mathcal{X}|}{m}$ rất lớn.

NCE (Z học được):	$q_{\theta^*} = p$	(phân phối đúng).
NEG ($\bar{Z} = \frac{ \mathcal{X} }{m}$ cố định):	$q_{\theta^*} = \bar{Z} p$	(phóng đại $\bar{Z}$ lần).

4.1.4 Bước 3 — UMAP thực chất là NEG

Bổ đề 4.1 (Bổ đề 3 — Damrich et al., 2023). *Loss hiệu dụng của UMAP (sau khi tính đến cơ chế lấy mẫu âm) chính là loss NEG (4) với kernel $\tilde{q}_{\theta}(ij) = \frac{1}{d_{ij}^2}$.*

Chứng minh. Böhm et al. [3] chỉ ra rằng loss hiệu dụng UMAP có dạng:

$$\mathcal{L}_{\text{UMAP}}(\theta) = -\mathbb{E}_{ij \sim p} \log \phi(d_{ij}) - m \mathbb{E}_{ij \sim \xi} \log(1 - \phi(d_{ij})), \quad (22)$$

với $\phi(d) = \frac{1}{1+d^2}$ và $m = 5$ (mặc định). Đặt $\tilde{q}(ij) := \frac{1}{d_{ij}^2}$. Khi đó:

$$\phi(d_{ij}) = \frac{1}{1+d_{ij}^2} = \frac{d_{ij}^{-2}}{1+d_{ij}^{-2}} = \frac{\tilde{q}(ij)}{\tilde{q}(ij)+1}, \quad 1 - \phi(d_{ij}) = \frac{1}{\tilde{q}(ij)+1}. \quad (23)$$

Thay vào (22):

$$\mathcal{L}_{\text{UMAP}}(\theta) = -\mathbb{E}_p \log \frac{\tilde{q}(ij)}{\tilde{q}(ij)+1} - m \mathbb{E}_\xi \log \frac{1}{\tilde{q}(ij)+1},$$


đúng bằng loss NEG (4) với $\phi_\theta \leftarrow \tilde{q}_\theta$. □

Áp dụng Định lý 4.1: UMAP dùng NEG với hằng số cố định

$$\bar{Z}_{\text{UMAP}} = \frac{|\mathcal{X}|}{m} = \frac{\binom{n}{2}}{m} = \frac{n(n-1)}{2m} = \mathcal{O}(n^2), \quad (24)$$

trong khi $Z(\theta)$ của t-SNE $\approx 50n-100n$ [3]—nhỏ hơn $\bar{Z}_{\text{UMAP}}$ bậc n .

Chuỗi liên kết t-SNE $\rightarrow$ UMAP.



Bước NCE $\rightarrow$ NEG (cố định $\bar{Z}$) là bước *duy nhất* thay đổi nghiệm tối ưu. UMAP khác Neg-t-SNE chỉ ở kernel ($\frac{1}{d^2}$ vs. Cauchy), nhưng với d_{ij} lớn cả hai xấp xỉ nhau ($\phi(d) \approx \frac{1}{d^2}$) nên sự khác biệt kernel gần như không ảnh hưởng hình thái nhúng.

4.1.5 Phổ nhúng: $\bar{Z}$ điều khiển tỷ lệ lực đẩy/hút

Cấu trúc gradient. Với Cauchy kernel $\phi(d) = \frac{1}{1+d^2}$ và $\mathbf{r}_{ij} = \mathbf{y}_i - \mathbf{y}_j$, ta có $\frac{\partial \phi(ij)}{\partial \mathbf{y}_i} = -2\phi(ij)^2 \mathbf{r}_{ij}$ (khai triển tường minh tại Phụ lục 1.3). Ba gradient của MLE, NCE, NEG có cấu trúc song song,

chỉ khác ở hệ số chuẩn hóa và hệ số *dampening*:

$$\frac{\partial \mathcal{L}_{\text{t-SNE}}}{\partial \mathbf{y}_i} = 2 \sum_{j \neq i} \left(\frac{p(ij)}{q_\theta(ij)} - 1 \right) \frac{1}{Z(\theta)} \cdot \frac{\partial \phi(ij)}{\partial \mathbf{y}_i}, \quad (25)$$

$$\frac{\partial \mathcal{L}_{\text{NC-t-SNE}}}{\partial \mathbf{y}_i} = 2 \sum_{j \neq i} \underbrace{\frac{m\xi(ij)}{\frac{\phi(ij)}{Z} + m\xi(ij)}}_{\xrightarrow{m \rightarrow \infty} 1} \left(\frac{p(ij)}{q_{\theta,Z}(ij)} - 1 \right) \frac{1}{Z} \cdot \frac{\partial \phi(ij)}{\partial \mathbf{y}_i}, \quad (26)$$

$$\frac{\partial \mathcal{L}_{\text{Neg-t-SNE}}}{\partial \mathbf{y}_i} = 2 \sum_{j \neq i} \underbrace{\frac{m\xi(ij)}{\frac{\phi(ij)}{\bar{Z}} + m\xi(ij)}}_{\in [0.5, 1]} \left(\frac{p(ij)}{\frac{\phi(ij)}{\bar{Z}}} - 1 \right) \frac{1}{\bar{Z}} \cdot \frac{\partial \phi(ij)}{\partial \mathbf{y}_i}. \quad (27)$$

Ba gradient chỉ khác ở: (i) hệ số chuẩn hóa ($Z(\theta)$, Z , hay $\bar{Z}$), và (ii) hệ số dampening (bằng 1 cho MLE; hội tụ về 1 khi $m \rightarrow \infty$ cho NCE; nằm trong $[0.5, 1]$ cho NEG).

Tách lực hút và lực đẩy. Xét gradient Neg-t-SNE (27). Tổng gồm hai loại cặp:

- **Cạnh skNN** ($p(ij) > 0$): số hạng $\frac{p(ij)}{\frac{\phi(ij)}{\bar{Z}}}$ chiếm ưu thế $\Rightarrow$ **lực hút**, kéo $\mathbf{y}_i$ về phía $\mathbf{y}_j$. Lực hút không phụ thuộc $\bar{Z}$: $\frac{p(ij)\bar{Z}}{\phi(ij)} \cdot \frac{1}{\bar{Z}} = \frac{p(ij)}{\phi(ij)}$.
- **Cặp nhiễu** ($p(ij) = 0$): còn lại $-\frac{\phi(ij)}{\bar{Z}} \Rightarrow$ **lực đẩy**, đẩy $\mathbf{y}_i$ ra xa $\mathbf{y}_j$. Lực đẩy tỷ lệ *ngược* với $\bar{Z}$:

$$F_{\text{rep}} \propto \frac{\phi(ij)^2}{\bar{Z}} \propto \frac{1}{\bar{Z}}. \quad (28)$$


(Chi tiết khai triển và chứng minh tại Phụ lục 1.3.)

Phổ nhúng từ t-SNE đến UMAP. Phương trình (28) giải thích trực tiếp sự khác biệt hình thái:

- $\bar{Z} = Z(\theta) \approx 50n-100n$ (**t-SNE**): lực đẩy mạnh, không gian nhúng dàn rộng, cụm phân tán rõ—mô hình ưu tiên bảo toàn *cấu trúc cục bộ chi tiết*.
- $\bar{Z} = \frac{\binom{n}{2}}{m} = \mathcal{O}(n^2)$ (**UMAP**): lực đẩy yếu hơn bậc n , lực hút thống trị $\Rightarrow$ *cụm siêu co chặt*.

- $\bar{Z} \gg \frac{\binom{n}{2}}{m}$: lực đẩy gần triệt tiêu, các cụm bắt đầu sáp nhập.

Ghi chú 4.1. $\bar{Z}$ là *tham số trượt* (slider) cho phép nội suy liên tục giữa hành vi t-SNE và UMAP. Bằng cách đặt $\bar{Z} = Z_{\text{lo}} \cdot \exp(s(\log Z_{\text{hi}} - \log Z_{\text{lo}}))$ với $s \in [0, 1]$, $Z_{\text{lo}} = Z_{\text{t-SNE}}$, $Z_{\text{hi}} = \frac{\binom{n}{2}}{m}$, ta thu được họ phương pháp gọi là **Neg-t-SNE spectrum**.



Hình 5: Phổ Neg-t-SNE: $\bar{Z}$ nhỏ ($\approx 50n$, t-SNE) cho lực đẩy mạnh và cụm dàn trải; $\bar{Z}$ lớn ($\mathcal{O}(n^2)$, UMAP) cho lực đẩy yếu và cụm siêu co chặt.

Ổn định số trị: Cauchy vs. nghịch bình phương. Neg-t-SNE dùng Cauchy kernel $\phi(d) = \frac{1}{1+d^2} \in (0, 1]$ (chặn trên), nên lực đẩy tối đa là $\log 2$ dù $d_{ij} \rightarrow 0$. Ngược lại, UMAP dùng $\tilde{q}(d) = \frac{1}{d^2} \rightarrow \infty$ khi $d \rightarrow 0$, gây hiệu ứng “catapult” và bất ổn gradient—lý do UMAP cần *learning rate annealing* trong thực hành. Đây là ưu điểm thực tiễn của Neg-t-SNE.

Bảng 2: So sánh t-SNE, NC-t-SNE, Neg-t-SNE và UMAP qua khung NCE/NEG

	t-SNE	NC-t-SNE	Neg-t-SNE	UMAP
Khung tối ưu	MLE	NCE	NEG	NEG
Hằng số Z	$Z(\theta)$ (tính)	Z (học)	$\bar{Z}$ (chọn)	$\frac{\binom{n}{2}}{m}$
Kernel ϕ	Cauchy	Cauchy	Cauchy	$\frac{1}{d^2}$
Nghiệm q^*	p	p	$\bar{Z}p$	$\bar{Z}p$
Lực đẩy F_{rep}	$\propto \frac{1}{Z(\theta)}$	$\propto \frac{1}{Z}$	$\propto \frac{1}{\bar{Z}}$	$\propto \frac{m}{\binom{n}{2}}$
Hình thái cụm	Dàn trải	Dàn trải	Linh hoạt	Siêu co chặt
Ổn định số	Ổn định	Ổn định	Ổn định	Cần annealing

Tóm tắt so sánh.

4.2 Cân bằng cục bộ–toàn cục trong trực quan hóa giảm chiều

Bài báo *Understanding How Dimension Reduction Tools Work: An Empirical Approach to Deciphering t-SNE, UMAP, TriMap, and PaCMAP for Data Visualization* của Wang, Huang, Rudin và Shaposhnik [18] (JMLR 2021) đặt ra câu hỏi: **khi nhúng dữ liệu chiều cao xuống hai chiều, thành phần nào của hàm mất mát quyết định việc giữ cấu trúc cục bộ hay toàn cục?** Bài báo phân tích thực nghiệm lực hút–lực đẩy trên t-SNE, UMAP và TriMap, rồi đề xuất PaCMAP (*Pairwise Controlled Manifold Approximation Projection*)—thuật toán thiết kế trực tiếp ba loại cặp điểm và lịch trọng số theo giai đoạn thay vì chỉ tinh chỉnh siêu tham số trên đồ thị kNN.

4.2.1 Bài toán trực quan hóa

Cho n điểm $\mathbf{x}_1, \dots, \mathbf{x}_n \in \mathbb{R}^D$ và embedding $\theta = \{\mathbf{y}_1, \dots, \mathbf{y}_n\} \subset \mathbb{R}^2$. Khi $D \gg 2$, không thể bảo toàn đồng thời mọi khoảng cách; scatter plot hai chiều dễ bị diễn giải sai nếu người xem coi khoảng cách giữa cụm hay kích thước cụm như cấu trúc thật của dữ liệu gốc. t-SNE và UMAP thường làm nổi bật láng giềng cục bộ nhưng có thể biến dạng bố cục toàn cục; ngược lại, phương pháp quá ưu tiên cấu trúc toàn cục có thể làm mờ các cụm nhỏ. Wang et al. [18] muốn hiểu thành phần nào của loss, đồ thị và khởi tạo gây ra sự khác biệt đó, rồi thiết kế thuật toán cân bằng hai mục tiêu tốt hơn.

4.2.2 Rainbow figure và sáu nguyên tắc thiết kế loss

Các thuật toán nhúng láng giềng có thể diễn giải qua lực hút trên cặp cần gần nhau và lực đẩy trên cặp không nên chồng lên nhau. Wang et al. [18] vẽ *rainbow figure*—biểu diễn độ lớn gradient theo khoảng cách trong không gian gốc và không gian nhúng—để so sánh t-SNE, UMAP và TriMap thay vì chỉ đối chiếu công thức. Từ phân tích này, tác giả rút ra sáu nguyên tắc cho hàm mất mát giữ cục bộ tốt:

1. Láng giềng bị đặt xa trong embedding phải chịu lực hút *đủ mạnh*.
2. Điểm không lân cận đã ở xa không nên tiếp tục chi phối quá mức quá trình tối ưu.
3. Lực đẩy giữa điểm xa phải đủ để tránh chồng lấn, nhưng không được triệt tiêu lực hút cục bộ.
4. Chỉ thu hút láng giềng gần nhất và đẩy điểm xa *chưa đủ* để phục hồi cấu trúc toàn cục.

5. Cặp ở khoảng cách trung gian mang thông tin quan trọng về bố cục tổng thể.
6. Kết quả embedding phụ thuộc cả hàm mất mát *và* phép khởi tạo (TriMap nhạy cảm với khởi tạo PCA).

Phương pháp	Thông tin ưu tiên	Nhận xét trong bài báo
t-SNE	Láng giềng cục bộ	Cụm rõ; bố cục toàn cục không nên diễn giải trực tiếp.
UMAP	Đồ thị lân cận mờ	Lực đẩy yếu hơn t-SNE; cụm co chặt hơn.
TriMap	Quan hệ bộ ba	Giữ toàn cục tốt hơn nếu khởi tạo PCA phù hợp.
PaCMAP	Ba loại cặp + lịch trọng số	Cân bằng chủ động cục bộ–toàn cục.

4.2.3 Bước 1 — Ba loại cặp điểm

PaCMAP xây dựng ba tập cặp trên không gian gốc $\mathbb{R}^D$:

- **Neighbor pairs** $\mathcal{N}$: mỗi điểm i nối với n_{NB} láng giềng gần nhất (mặc định $n_{\text{NB}} = 10$), dùng khoảng cách chuẩn hóa theo độ lệch chuẩn địa phương.
- **Mid-near pairs** $\mathcal{M}$: với mỗi i , lấy mẫu sáu điểm ngẫu nhiên và ghép i với điểm *gần thứ hai* trong sáu điểm đó; $|\mathcal{M}| = n_{\text{MN}} = \text{MN_ratio} \cdot n_{\text{NB}}$ (mặc định $\text{MN_ratio} = 0.5$).
- **Further pairs** $\mathcal{F}$: ghép i với điểm lấy mẫu ngẫu nhiên *không* thuộc láng giềng; $|\mathcal{F}| = n_{\text{FP}} = \text{FP_ratio} \cdot n_{\text{NB}}$ (mặc định $\text{FP_ratio} = 2$).

Thay vì tăng số láng giềng để giữ toàn cục, PaCMAP dùng cặp trung gian $\mathcal{M}$ với lực hút *yếu*: kéo các cụm gần nhau về phía nhau mà không phá cấu trúc cục bộ do $\mathcal{N}$ duy trì.

4.2.4 Bước 2 — Hàm loss và lịch trọng số ba giai đoạn

Khoảng cách bình phương trong không gian nhúng (có dịch chuyển +1 để tránh chia cho không):

$$\tilde{d}_{ab} = \|\mathbf{y}_a - \mathbf{y}_b\|^2 + 1, \quad a, b \in \{1, \dots, n\}. \quad (29)$$


Hàm loss PaCMAP [18]:

$$\mathcal{L}_{\text{PaCMAP}}(\theta) = w_{\text{NB}} \sum_{(i,j) \in \mathcal{N}} \frac{\tilde{d}_{ij}}{C_{\text{Med}} + \tilde{d}_{ij}} + w_{\text{MN}} \sum_{(i,k) \in \mathcal{M}} \frac{\tilde{d}_{ik}}{C_{\text{Lg}} + \tilde{d}_{ik}} + w_{\text{FP}} \sum_{(i,l) \in \mathcal{F}} \frac{1}{1 + \tilde{d}_{il}}, \quad (30)$$

với $C_{\text{Med}} = 10$ (lực hút mạnh trên $\mathcal{N}$) và $C_{\text{Lg}} = 10\,000$ (lực hút yếu trên $\mathcal{M}$). Số hạng thứ ba là lực đẩy trên $\mathcal{F}$. Hệ số $C_{\text{Lg}} \gg C_{\text{Med}}$ đảm bảo mid-near chỉ tác động nhẹ so với neighbor.

PaCMAP tối ưu (30) theo ba giai đoạn (Adam, mặc định 450 iteration):

1. **Giai đoạn 1** (100 iter): $w_{\text{NB}} = 2$, $w_{\text{FP}} = 1$, $w_{\text{MN}}(t)$ giảm tuyến tính từ 1000 xuống 3—định bố cục toàn cục trước.
2. **Giai đoạn 2** (250 iter): w_{MN} tiếp tục giảm, cân bằng dần ba loại cặp.
3. **Giai đoạn 3** (100 iter): giảm vai trò mid-near, tinh chỉnh quan hệ láng giềng cục bộ.



Theo thí nghiệm trên dữ liệu ảnh, văn bản, sinh học và tổng hợp, PaCMAP đạt cân bằng tốt giữa đánh giá cục bộ (trustworthiness, KNN) và toàn cục (triplet accuracy), đồng thời có thời gian chạy cạnh tranh với t-SNE và UMAP [18].

Bảng 3: Tóm tắt PaCMAP so với các thuật toán trực quan hóa được phân tích

	t-SNE / UMAP	TriMap	PaCMAP
Cặp điểm	Láng giềng + mẫu âm	Bộ ba	$\mathcal{N}, \mathcal{M}, \mathcal{F}$
Toàn cục	Yếu (chỉ qua k NN)	Khởi tạo PCA	Mid-near + lịch w_{MN}
Khởi tạo	Ít nhảy	Nhảy PCA	Ổn định hơn

4.2.5 Thí nghiệm baseline của nhóm

[MỞ RỘNG] Đồ án khảo sát ý tưởng PaCMAP nhưng *không cài đặt* thuật toán này; bảng 4 chỉ báo cáo baseline t-SNE, UMAP, LLE và Laplacian Eigenmaps trên MNIST.

Notebook `baseline.ipynb` chạy trên 10 000 ảnh MNIST (`SEED = 42`) với wrapper TSNE, UMAP và cài đặt nhóm LLE, LaplacianEigenmaps. Nhân chỉ dùng đánh giá sau nhúng; hai chỉ số báo cáo là `trustworthiness@12` và độ chính xác KNN@5.

Bảng 4: Baseline trên MNIST (`baseline.ipynb`, `SEED = 42`)

Phương pháp	Trust.@12	KNN acc.@5
t-SNE (perplexity = 30)	0.9842	0.9454
UMAP	0.9602	0.9429
Laplacian Eigenmaps	0.8443	0.7414
LLE	0.8286	0.7069

t-SNE và UMAP giữ láng giềng cục bộ tốt trên hai chỉ số trên, phù hợp nhận xét định tính của Wang et al. Hai chỉ số này không đo cấu trúc toàn cục (triplet accuracy), nên chưa thể kết luận về lợi thế PaCMAP khi thuật toán chưa được chạy trên cùng dữ liệu.

4.3 Nhận xét tổng quan: xu hướng, hạn chế và câu hỏi mở

Xu hướng 1: Thống nhất dưới khung toán học chung. Damrich et al. [5] chứng minh t-SNE, NC-t-SNE, Neg-t-SNE và UMAP là các trường hợp của NCE/NEG trên đồ thị skNN; trước đó Böhm et al. [3] đã mô tả phổ hút–đẩy trong t-SNE. Xu hướng này giúp cộng đồng *hiểu* thay vì chỉ *dùng* các thuật toán DR.

Xu hướng 2: Thiết kế mục tiêu lai cho trực quan hóa. Wang et al. [18] cho thấy nghiên cứu DR trực quan hóa chuyển từ tiêu chuẩn đơn (phương sai PCA, geodesic Isomap) sang thiết kế lai: cụm cục bộ phải rõ nhưng bố cục toàn cục không được tùy tiện. PaCMAP minh họa bằng cặp trung gian và lịch trọng số thay vì chỉ tinh chỉnh perplexity hay k .

Xu hướng 3: Liên hệ với học biểu diễn tự giám sát. NC-t-SNE, Neg-t-SNE và UMAP gần với SimCLR [5]: khác biệt chính là cách xây dựng cặp tương đồng (đồ thị kNN cố định vs. data augmentation), mở khả năng chuyển giao kỹ thuật giữa hai lĩnh vực.

Hạn chế và câu hỏi mở.

- **Giả định mô hình:** Định lý 2.1 và Định lý 4.1 giả định mô hình khớp được p ; trong thực tế phân phối trên skNN có nhiều vị trí bằng 0 mà kernel luôn dương không khớp hoàn hảo.

- **Chọn $\bar{Z}$ hay lịch trọng số:** Neg-t-SNE cần đặt $\bar{Z}$ thủ công; PaCMAP dùng lịch w_{MN} cố định—câu hỏi mở là liệu có thể *học* các hệ số này từ dữ liệu.
- **Đánh giá đa thước đo:** Trustworthiness và KNN chỉ đo cục bộ; cần thêm triplet accuracy hay continuity để đánh giá toàn cục như Wang et al.
- **DR trực tuyến:** Cả hai khung đều giả định toàn bộ dữ liệu có sẵn; mở rộng cho streaming là hướng tiềm năng.
- **Đảm bảo lý thuyết:** So với JL (Mục 3.5), các phương pháp phi tuyến (t-SNE, UMAP, PaCMAP) vẫn thiếu chặn toán học tương đương về chất lượng nhúng.

Chương 5 Thực nghiệm và phân tích kết quả

Phần này kiểm chứng ba phương pháp trọng tâm đã cài đặt là PCA, KPCA và Isomap. Toàn bộ hình và số liệu được tạo bởi tệp `code/experiments/report_pca_kpca_isomap.py` với `SEED = 42`. Lỗi ba thuật toán dùng các lớp trong `code/models/`; thư viện ngoài chỉ hỗ trợ nạp dữ liệu, chuẩn hóa đặc trưng và tính chỉ số đánh giá.

5.1 Thiết lập thực nghiệm

Các thí nghiệm chính được tái lập trong môi trường phần mềm ở Bảng 5. PCA, KPCA và Isomap không phụ thuộc vào PyTorch hay `contrastive-ne`; hai gói này chỉ liên quan đến phần khảo sát Neg-t-SNE bổ sung, tách khỏi các kết quả chính bên dưới.

Bảng 5: Phiên bản môi trường dùng để tái lập thực nghiệm chính.

Thành phần	Phiên bản	Vai trò
Python	3.13.3	Môi trường thực thi
NumPy	2.4.4	Đại số tuyến tính và cài đặt thuật toán
SciPy	1.17.1	Hàm hỗ trợ tính toán số
scikit-learn	1.8.0	Dữ liệu, chuẩn hóa và chỉ số đánh giá
Matplotlib	3.10.9	Sinh hình trực quan hóa
umap-learn	0.5.12	Đối chiếu UMAP ở phần khảo sát bổ sung

Bảng 6: Thiết lập cho ba thực nghiệm minh họa.


Dữ liệu	Mục tiêu	Thiết lập
Wine	Kiểm chứng phương sai giữ lại và lỗi tái tạo của PCA	178 mẫu, 13 thuộc tính được chuẩn hóa; $k = 1, \dots, 13$
Circles mở rộng	Kiểm chứng giảm chiều và độ nhạy kernel của KPCA	1000 điểm; thêm 8 chiều nhiễu chuẩn độ lệch 0.03; giảm $10D \rightarrow 2D$
Swiss roll	Đánh giá bảo toàn khoảng cách geodesic của Isomap	700 điểm, nhiễu 0.05; khảo sát $t \in \{4, 8, 12, 20, 40\}$

5.2 PCA: phương sai và lỗi tái tạo

Theo Bổ đề 3.1, nghiệm PCA tối ưu phải làm lỗi tái tạo không tăng khi số chiều giữ lại k tăng. Hình 6 kiểm chứng trực tiếp tính chất này trên dữ liệu Wine sau khi chuẩn hóa. Trong bảng và hình dưới đây, code báo cáo lỗi trung bình trên mỗi mẫu,

$$E_{\text{rec}} = \frac{1}{m} \|\hat{\mathbf{X}} - \mathbf{X}\|_F^2,$$

là phiên bản chuẩn hóa của lỗi tổng trong Bổ đề 3.1.



Hình 6: Phương sai tích lũy và lỗi tái tạo PCA trên dữ liệu Wine đã chuẩn hóa.


Bảng 7: Một số kết quả PCA trên Wine.

Số thành phần k	Phương sai tích lũy	Lỗi tái tạo trung bình
1	0.3620	8.2941
2	0.5541	5.7972
13	1.0000	≈ 0

Hai thành phần đầu giữ khoảng 55.41% tổng phương sai. Khi giữ toàn bộ 13 thành phần, lỗi tái tạo chỉ còn 1.17×10^{-29} , là sai số số học và phù hợp với việc phép đổi cơ sở trực chuẩn không làm mất thông tin. Trong phần lý thuyết, ma trận hiệp phương sai dùng hệ số $1/m$ để công thức gọn hơn; cài đặt dùng quy ước ước lượng phương sai mẫu $1/(m-1)$ cho thuộc tính `explained_variance_`. Hai quy ước chỉ nhân toàn bộ trị riêng với cùng một hằng số, nên không đổi các hướng chính, tỉ lệ phương sai tích lũy hay kết luận về lỗi tái tạo.


5.3 KPCA: cấu trúc phi tuyến của hai vòng tròn

Dữ liệu hai vòng tròn đồng tâm ban đầu có hai chiều; thí nghiệm nổi thêm tám chiều nhiễu Gaussian nhỏ để tạo đầu vào 10 chiều, sau đó giảm về hai chiều. Cách thiết kế này vừa giữ cấu trúc phi tuyến cần quan sát, vừa kiểm tra đúng một bài toán giảm chiều. Khi dùng kernel tuyến tính, khoảng cách cặp điểm trong embedding KPCA và PCA chỉ lệch tối đa 2.22×10^{-15} , phù hợp với quan hệ PCA là trường hợp riêng của KPCA. Với RBF và $\gamma = 32$, hai trị riêng lớn nhất của ma trận kernel đã căn giữa lần lượt là 28.6625 và 28.1265.



Hình 7: Dữ liệu Circles quan sát ở hai chiều gốc và kết quả giảm từ 10 chiều xuống 2 chiều bằng PCA, KPCA.

Trong Hình 7, PCA giữ hình học tuyến tính chính, còn RBF-KPCA tái biểu diễn hai vòng theo độ tương tự kernel. Để lượng hóa ảnh hưởng của γ , ta dùng hệ số silhouette với nhãn đã biết của dữ liệu tổng hợp; nhãn này chỉ dùng để đánh giá sau khi nhúng, không tham gia huấn luyện KPCA.



Hình 8: Độ nhạy của RBF-KPCA theo γ khi giảm Circles mở rộng từ 10 chiều xuống 2 chiều.


Bảng 8: Silhouette theo nhãn tổng hợp cho PCA và RBF-KPCA.

Phương pháp	PCA	RBF-KPCA, γ				
γ	–	0.5	2	8	32	128
Silhouette	0.1125	0.0496	0.0037	0.2359	0.3775	0.2411

Giá trị $\gamma = 32$ được chọn cho hình biểu diễn vì cho silhouette cao nhất trong năm giá trị khảo sát. Kết quả này chỉ khẳng định sự phù hợp của kernel trong ví dụ tổng hợp đang xét, không khẳng định một tham số tối ưu chung cho dữ liệu khác.

5.4 Isomap: bảo toàn khoảng cách geodesic trên Swiss roll


Đối với Swiss roll, khoảng cách Euclid trong không gian ba chiều có thể đưa hai điểm ở các lớp cuộn khác nhau đến gần nhau không đúng với cấu trúc mặt cong. Vì vậy, chỉ số đánh giá sử dụng ở đây là hệ số tương quan Pearson giữa khoảng cách geodesic trên đồ thị láng giềng của Isomap và khoảng cách Euclid giữa các cặp điểm sau khi nhúng xuống hai chiều.



Hình 9: Swiss roll ban đầu và hai biểu diễn hai chiều bằng PCA, Isomap.

Bảng 9: Độ nhảy Isomap theo số láng giềng trên Swiss roll.

Phương pháp	PCA	Isomap, số láng giềng t				
		4	8	12	20	40
Tương quan Pearson	0.2806	0.9964	0.9990	0.9996	0.8267	0.8671



Hình 10: Tương quan khoảng cách của Isomap thay đổi theo số láng giềng.

Kết quả trong Bảng 9 cho thấy Isomap với $t = 12$ gần như duy trì khoảng cách geodesic trên dữ liệu tổng hợp này, trong khi PCA chỉ mô hình hóa phương sai tuyến tính. Khi t tăng lên 20 hoặc 40, tương quan giảm rõ, phù hợp với nguy cơ cạnh tắt qua các lớp cuộn đã nêu ở phần lý thuyết. Chỉ số ở đây đo mức khớp với khoảng cách đồ thị tương ứng của mỗi thiết lập, tức là kiểm chứng

trực tiếp mục tiêu nội tại của Isomap. Cài đặt còn có bước nối các thành phần liên thông bằng cạnh Euclidean ngắn nhất nếu đồ thị t -láng giềng bị rời; trong thí nghiệm này, đồ thị đã liên thông ở cả năm giá trị t nên bước đó không thay đổi các khoảng cách hoặc kết quả báo cáo.

5.5 Đối chiếu mở rộng: t-SNE và UMAP

t-SNE và UMAP không thuộc nội dung bắt buộc của Chương 12 trong [12]; báo cáo dùng hai phương pháp này như các baseline trực quan hóa phi tuyến để liên hệ với các bài báo hiện đại về DR. Trong mã nguồn, lớp TSNE là wrapper cho `sklearn.manifold.TSNE`, còn lớp UMAP là wrapper cho gói `umap-learn`; cả hai không phải cài đặt from-scratch. Thực nghiệm bổ sung trong `code/experiments/baseline.ipynb` dùng `SEED = 42`. Cấu hình t-SNE là perplexity 30, khởi tạo PCA, 750 vòng lặp và learning rate tự động; cấu hình UMAP là $n_{\text{neighbors}} = 15$, `min_dist = 0.1` và metric Euclid. Hai wrapper này chỉ được dùng để tạo embedding cho dữ liệu huấn luyện trong notebook; báo cáo không xem chúng là ba thực nghiệm chính của đề án.

Bảng 10: Baseline t-SNE và UMAP trên MNIST trong `baseline.ipynb`.

Phương pháp	Số mẫu	Trustworthiness@12	KNN accuracy@5	Thời gian fit (s)
t-SNE, perplexity = 30	10 000	0.9842	0.9454	14.7364
UMAP, $n_{\text{neighbors}} = 15$	10 000	0.9602	0.9429	24.7753

Kết quả ở Bảng 10 cho thấy cả t-SNE và UMAP đều bảo toàn láng giềng cục bộ tốt trên MNIST. t-SNE đạt trustworthiness cao hơn và nhỉnh hơn nhẹ về KNN accuracy trong lần chạy này, phù hợp với nhận xét của Wang et al. [18] rằng t-SNE thường tạo cụm cục bộ rõ. UMAP cho kết quả KNN gần tương đương, nhưng chất lượng và bố cục phụ thuộc vào tham số `n_neighbors` và `min_dist`. Theo phân tích của Wang et al., khoảng cách giữa các cụm và bố cục toàn cục của các phương pháp trực quan hóa như t-SNE/UMAP không nên được diễn giải trực tiếp nếu không có thước đo toàn cục bổ sung. Vì vậy, hai kết quả này chỉ được dùng để đối chiếu phần mở rộng, không thay thế ba thực nghiệm chính ở trên.

5.6 Các đoạn cài đặt chính

Trong phần lý thuyết, mỗi mẫu là một cột của $\mathbf{X} \in \mathbb{R}^{N \times m}$ và $\mathbf{Y} \in \mathbb{R}^{k \times m}$. Trong code Python, theo quy ước NumPy, mỗi mẫu là một hàng: `X.shape = (m, N)` và `Y.shape = (m, k)`. Do đó các phép

nhân trong listing là chuyển vị tương đương của công thức lý thuyết.

Cài đặt PCA dưới đây sử dụng SVD trên dữ liệu đã trừ trung bình và cung cấp trực tiếp hàm tính lỗi tái tạo dùng trong Hình 6.

```

1  def _fit(self, X: np.ndarray) -> None:
2      max_components = min(X.shape)
3      if self.n_components > max_components:
4          raise ValueError(
5              f"n_components ({self.n_components}) must be <= min(n_samples,
n_features) "
6              f"({max_components})."
7          )
8
9      _, singular_values, components = np.linalg.svd(X, full_matrices=False)
10     denominator = max(X.shape[0] - 1, 1)
11     all_variance = (singular_values ** 2) / denominator
12     total_variance = float(np.sum(all_variance))
13
14     self.components_ = components[: self.n_components]
15     self.singular_values_ = singular_values[: self.n_components]
16     self.explained_variance_ = all_variance[: self.n_components]
17     if total_variance > 0.0:
18         self.explained_variance_ratio_ = self.explained_variance_ / total_variance
19     else:
20         self.explained_variance_ratio_ = np.zeros(self.n_components, dtype=float)
21
22 def _transform(self, X: np.ndarray) -> np.ndarray:
23     if self.components_ is None:
24         raise RuntimeError("PCA has not been fitted.")
25     return X @ self.components_.T
26
27 def _inverse_transform(self, Y: np.ndarray) -> np.ndarray:
28     if self.components_ is None:
29         raise RuntimeError("PCA has not been fitted.")
30     return Y @ self.components_
31
32 def reconstruction_error(self, X: np.ndarray) -> float:

```

```

33     """Return mean squared reconstruction error per sample."""
34     X = np.asarray(X, dtype=float)
35     reconstructed = self.inverse_transform(self.transform(X))
36     return float(np.mean(np.sum((X - reconstructed) ** 2, axis=1)))
    
```

Listing 1: Cài đặt lõi PCA và lỗi tái tạo.

```

1     def _fit(self, X: np.ndarray) -> None:
2         if self.kernel == "precomputed":
3             if X.shape[0] != X.shape[1]:
4                 raise ValueError("For kernel='precomputed', X must be a square
5 Gram matrix.")
6                 K = np.asarray(X, dtype=float)
7                 self.X_fit_ = None
8             else:
9                 self.X_fit_ = X.copy()
10                K = self._kernel(X, X)
11
12            Kc = self._center_fit_kernel(K)
13            eigenvalues, eigenvectors = np.linalg.eigh(Kc)
14            order = np.argsort(eigenvalues)[::-1]
15            eigenvalues = eigenvalues[order]
16            eigenvectors = eigenvectors[:, order]
17
18            positive = eigenvalues > self.eigen_tol
19            if int(np.sum(positive)) < self.n_components:
20                raise ValueError(
21                    f"KPCA found only {int(np.sum(positive))} positive eigenvalues;
22                    "
23                    f"need {self.n_components}."
24                )
25            eigenvalues = eigenvalues[positive][: self.n_components]
26            eigenvectors = eigenvectors[:, positive][:, : self.n_components]
27
28            self.eigenvalues_ = eigenvalues
29            self.eigenvectors_ = eigenvectors
30            self.alphas_ = eigenvectors / np.sqrt(eigenvalues)
    
```

```
self.embedding_ = eigenvectors * np.sqrt(eigenvalues)
```

Listing 2: KPCA: phân rã phổ trên Gram matrix đã căn giữa.

```
def _center_fit_kernel(self, K: np.ndarray) -> np.ndarray:
    self.K_fit_rows_mean_ = K.mean(axis=0)
    self.K_fit_all_mean_ = float(K.mean())
    return K - K.mean(axis=1, keepdims=True) - self.K_fit_rows_mean_[None,
:] + self.K_fit_all_mean_

def _center_transform_kernel(self, K: np.ndarray) -> np.ndarray:
    if self.K_fit_rows_mean_ is None or self.K_fit_all_mean_ is None:
        raise RuntimeError("Missing fitted kernel centering statistics.")
    return K - K.mean(axis=1, keepdims=True) - self.K_fit_rows_mean_[None,
:] + self.K_fit_all_mean_
```

Listing 3: KPCA: căn giữa kernel cho tập huấn luyện và điểm mới.

```
distances = cdist(X, X, metric="euclidean")
graph = self._build_neighbor_graph(distances)
graph = self._connect_components(graph, distances)
geodesic = shortest_path(graph, directed=False, unweighted=False)
if not np.isfinite(geodesic).all():
    raise ValueError(
        "The Isomap neighbor graph is disconnected. Increase n_neighbors
"
        "or use a smaller/cleaner sample."
    )

K = self._double_center(geodesic ** 2)
eigenvalues, eigenvectors = np.linalg.eigh(K)
order = np.argsort(eigenvalues)[::-1]
eigenvalues = eigenvalues[order]
eigenvectors = eigenvectors[:, order]

positive = eigenvalues > self.eigen_tol
if int(np.sum(positive)) < self.n_components:
    raise ValueError(
```



```

20         f"Isomap found only {int(np.sum(positive))} positive eigenvalues
; "
21         f"need {self.n_components}."
22     )
23
24     self.eigenvalues_ = eigenvalues[positive][: self.n_components]
25     self.eigenvectors_ = eigenvectors[:, positive][:, : self.n_components]
26     self.embedding_ = self.eigenvectors_ * np.sqrt(self.eigenvalues_)
27     self.geodesic_distances_ = geodesic
28     self.kernel_ = K
    
```

Listing 4: Isomap: khoảng cách geodesic và phân rã phổ.

```

1     @staticmethod
2     def _connect_components(graph: sparse.csr_matrix, distances: np.ndarray) ->
sparse.csr_matrix:
3         n_components, labels = connected_components(graph, directed=False)
4         if n_components <= 1:
5             return graph
6
7         graph = graph.tolil(copy=True)
8         connected = {0}
9         remaining = set(range(1, n_components))
10
11         while remaining:
12             best: tuple[float, int, int, int] | None = None
13             connected_mask = np.isin(labels, list(connected))
14             connected_idx = np.flatnonzero(connected_mask)
15             for comp in remaining:
16                 comp_idx = np.flatnonzero(labels == comp)
17                 block = distances[np.ix_(connected_idx, comp_idx)]
18                 local = int(np.argmin(block))
19                 row, col = np.unravel_index(local, block.shape)
20                 d = float(block[row, col])
21                 if best is None or d < best[0]:
22                     best = (d, int(connected_idx[row]), int(comp_idx[col]), comp)
23
24             if best is None:
    
```

```

24         break
25     d, i, j, comp = best
26     graph[i, j] = d
27     graph[j, i] = d
28     connected.add(comp)
29     remaining.remove(comp)
30
31     return graph.tocsr()
    
```

Listing 5: Isomap: nối các thành phần của đồ thị k-NN nếu cần.

```

1     @staticmethod
2     def _double_center(D2: np.ndarray) -> np.ndarray:
3         row_mean = D2.mean(axis=1, keepdims=True)
4         col_mean = D2.mean(axis=0, keepdims=True)
5         all_mean = D2.mean()
6         return -0.5 * (D2 - row_mean - col_mean + all_mean)
    
```

Listing 6: Isomap: phép double centering từ khoảng cách bình phương.

Tái tạo kết quả. Các hình và bảng trong phần này được sinh lại bằng lệnh:

```

1 uv run python code/experiments/report_pca_kpca_isomap.py
    
```

Các kiểm chứng mở rộng ngoài phạm vi ba thực nghiệm trọng tâm được lưu trong notebook `baseline.ipynb` ở thư mục `code/experiments`. Notebook này đánh giá thêm LLE và Laplacian Eigenmaps do nhóm cài đặt, cùng các wrapper t-SNE và UMAP, trên bốn tập dữ liệu; Bảng 10 tóm tắt riêng kết quả MNIST của hai phương pháp này vì chúng liên quan trực tiếp đến phần nghiên cứu tiên tiến. Các kết quả chi tiết còn lại được lưu trực tiếp trong notebook. Đánh giá thực nghiệm cho Johnson–Lindenstrauss chưa được dùng làm căn cứ cho các kết luận trong phần này.

Chương 6 Tổng kết

6.1 Tóm tắt nội dung

- PCA tìm chiều tuyến tính bậc k nhỏ nhất lỗi tái tạo Frobenius; nghiệm gắn với các vector riêng của ma trận hiệp phương sai $\mathbf{C}$ (Định lý 3.1).

- **KPCA** làm việc với ma trận Gram $\mathbf{K}$, cho phép phi tuyến mà không cần Φ tường minh.
- **Isomap, Laplacian eigenmaps, LLE** xây kernel hoặc ma trận Laplacian từ đồ thị láng giềng; Bảng 1 so sánh mức “toàn cục” hay “cục bộ” mà mỗi phương pháp ưu tiên giữ.
- **Johnson–Lindenstrauss** cho thấy chiều $k = O\left(\frac{\log m}{\epsilon^2}\right)$ đủ để bảo toàn khoảng cách cặp dưới chiều ngẫu nhiên.
- **[MỞ RỘNG] t-SNE và UMAP** (Mục 3.4): tối ưu nhúng phi tuyến qua KL (Định nghĩa 2.7) hoặc cross-entropy (Định nghĩa 2.8) trên đồ thị láng giềng.
- **Bài báo [5]** (Chương 4): thống nhất t-SNE và UMAP dưới khung NCE/NEG (Mục 2.9); tham số $\bar{Z}$ điều khiển phổ nhúng liên tục từ t-SNE sang UMAP (Định lý 4.1).

Hạn chế cần nhớ khi áp dụng. Manifold lý tưởng (kiểu Swiss roll) hiếm khớp dữ liệu thật; $\mathbf{K}_{\text{Iso}}$ có thể không xác định dương bán trên mẫu hữu hạn; Laplacian và LLE nhạy với số láng giềng t , tham số σ và cách nối cạnh; PCA/KPCA tuyến tính (kernel đơn giản) không tự khắc phục cấu trúc cong phức tạp nếu không chọn kernel hoặc thuật toán phù hợp.

6.2 Các hướng phát triển

Khảo sát chi tiết bài báo sau năm 2021 nằm ở Chương 4 (Mục 4.1). Các hướng mở bao gồm: chọn $\bar{Z}$ tự động từ dữ liệu, mở rộng khung tương phản cho giảm chiều trực tuyến (online DR), và xây dựng đảm bảo lý thuyết cho các phương pháp phi tuyến tương tự bỏ đề Johnson–Lindenstrauss (Mục 3.5).

Tài liệu

- [1] Aleksandr Artemenkov and Maxim Panov. NCVis: Noise contrastive approach for scalable visualization. In *Proceedings of The Web Conference 2020*, pages 2941–2947, 2020.
- [2] Mikhail Belkin and Partha Niyogi. Laplacian eigenmaps for dimensionality reduction and data representation. *Neural Computation*, 15(6):1373–1396, 2003.
- [3] Jan Niklas Böhm, Philipp Berens, and Dmitry Kobak. Attraction-repulsion spectrum in neighbor embeddings. *Journal of Machine Learning Research*, 23(95):1–32, 2022.
- [4] T. F. Cox and M. A. A. Cox. *Multidimensional Scaling*. Chapman and Hall, 2nd edition, 2000.
- [5] Sebastian Damrich, Jan Niklas Böhm, Fred A. Hamprecht, and Dmitry Kobak. From t-SNE to UMAP with contrastive learning. In *International Conference on Learning Representations (ICLR)*, 2023.
- [6] Michael U. Gutmann and Aapo Hyvärinen. Noise-contrastive estimation: A new estimation principle for unnormalized statistical models. In *Proceedings of the Thirteenth International Conference on Artificial Intelligence and Statistics*, pages 297–304, 2010.
- [7] Jihun Ham, Daniel D. Lee, and Lawrence K. Saul. Semisupervised alignment of manifolds. *Advances in Neural Information Processing Systems*, 17, 2004.
- [8] William B. Johnson and Joram Lindenstrauss. Extensions of lipschitz mappings into a hilbert space. *Contemporary Mathematics*, 26:189–206, 1984.
- [9] Leland McInnes, John Healy, and James Melville. UMAP: Uniform manifold approximation and projection for dimension reduction. *arXiv preprint arXiv:1802.03426*, 2018. Published in Journal of Open Source Software, 2020.
- [10] Sebastian Mika, Bernhard Schölkopf, Alexander J. Smola, Klaus-Robert Müller, Robert Fisher, and Gunnar Ratsch. Kernel PCA and de-noising in feature spaces. *Advances in Neural Information Processing Systems*, 12, 1999.

- [11] Tomas Mikolov, Ilya Sutskever, Kai Chen, Greg S. Corrado, and Jeff Dean. Distributed representations of words and phrases and their compositionality. In *Advances in Neural Information Processing Systems*, volume 26, pages 3111–3119, 2013.
- [12] Mehryar Mohri, Afshin Rostamizadeh, and Ameet Talwalkar. *Foundations of Machine Learning*. MIT Press, 2nd edition, 2018.
- [13] Karl Pearson. On lines and planes of closest fit to systems of points in space. *The London, Edinburgh, and Dublin Philosophical Magazine and Journal of Science*, 2(11):559–572, 1901.
- [14] Sam T. Roweis and Lawrence K. Saul. Nonlinear dimensionality reduction by locally linear embedding. *Science*, 290(5500):2323–2326, 2000.
- [15] Joshua B. Tenenbaum, Vin de Silva, and John C. Langford. A global geometric framework for nonlinear dimensionality reduction. *Science*, 290(5500):2319–2323, 2000.
- [16] Laurens van der Maaten and Geoffrey Hinton. Visualizing data using t-SNE. *Journal of Machine Learning Research*, 9:2579–2605, 2008.
- [17] Santosh Vempala. The random projection method, 2004. Lecture notes; simplified proof of Johnson–Lindenstrauss lemma.
- [18] Yingfan Wang, Haiyang Huang, Cynthia Rudin, and Yaron Shaposhnik. Understanding how dimension reduction tools work: An empirical approach to deciphering t-SNE, UMAP, TriMap, and PaCMAP for data visualization. *Journal of Machine Learning Research*, 22(201):1–73, 2021.

A Phụ lục

1.1 Chứng minh Bổ đề tập trung phân phối χ^2

Bổ đề 3.4 được dùng trong chứng minh bổ đề Johnson–Lindenstrauss (Mục 3.5). Dưới đây là chứng minh đầy đủ bằng kỹ thuật Chernoff bound.

Chứng minh Bổ đề 3.4. Dùng bất đẳng thức Chernoff (Markov trên e^{tS}). Với $t < \frac{1}{2}$, MGF của Z_i^2 là $\mathbb{E}[e^{tZ_i^2}] = (1 - 2t)^{-\frac{1}{2}}$, nên $\mathbb{E}[e^{tS}] = (1 - 2t)^{-\frac{k}{2}}$.

Đuôi trên ($S > (1 + \varepsilon)k$): với $t \in (0, \frac{1}{2})$,

$$\Pr(S > (1 + \varepsilon)k) \leq \frac{(1 - 2t)^{-k/2}}{e^{t(1+\varepsilon)k}}.$$

Chọn $t = \frac{\varepsilon}{2(1+\varepsilon)}$ và dùng $\ln(1 + \varepsilon) \leq \varepsilon - \frac{\varepsilon^2}{4}$ (với $\varepsilon \in (0, 1)$) suy ra $\Pr(S > (1 + \varepsilon)k) \leq e^{-\frac{\varepsilon^2 k}{8}} \leq e^{-\frac{\varepsilon^2 k}{4}}$.

Đuôi dưới ($S < (1 - \varepsilon)k$): với $t \in (-\frac{1}{2}, 0)$, chọn $t = -\frac{\varepsilon}{2(1-\varepsilon)}$ và $\ln(1 - \varepsilon) \leq -\varepsilon - \frac{\varepsilon^2}{2}$ cho $\Pr(S < (1 - \varepsilon)k) \leq e^{-\frac{\varepsilon^2 k}{4}}$.

Union bound trên hai đuôi: $\Pr\left(\left|\frac{S}{k} - 1\right| > \varepsilon\right) \leq 2e^{-\frac{\varepsilon^2 k}{4}}$. $\square$

1.2 Khai triển gradient UMAP

Phần này trình bày chi tiết gradient của fuzzy cross-entropy (16) dùng trong UMAP (Mục 3.4.2).

Đặt $\mathbf{r}_{ij} = \mathbf{y}_i - \mathbf{y}_j$. Trước tiên tính đạo hàm của w_{ij} theo $\mathbf{y}_i$:

$$\frac{\partial w_{ij}}{\partial \mathbf{y}_i} = \frac{\partial w_{ij}}{\partial d_{ij}} \cdot \frac{\partial d_{ij}}{\partial \mathbf{y}_i} = \frac{-2ab d_{ij}^{2b-1}}{(1 + a d_{ij}^{2b})^2} \cdot \frac{\mathbf{r}_{ij}}{d_{ij}} = \frac{-2ab d_{ij}^{2b-2}}{(1 + a d_{ij}^{2b})^2} \mathbf{r}_{ij}.$$

Gradient của C theo $\mathbf{y}_i$ trên cạnh (i, j) :

$$\frac{\partial C_{ij}}{\partial \mathbf{y}_i} = -\frac{B_{ij}}{w_{ij}} \frac{\partial w_{ij}}{\partial \mathbf{y}_i} + \frac{1 - B_{ij}}{1 - w_{ij}} \frac{\partial w_{ij}}{\partial \mathbf{y}_i} = \underbrace{\frac{2ab B_{ij} d_{ij}^{2b-2}}{1 + a d_{ij}^{2b}} \mathbf{r}_{ij}}_{\text{hút}} - \underbrace{\frac{2ab (1 - B_{ij}) d_{ij}^{2b-2}}{(1 - w_{ij})(1 + a d_{ij}^{2b})^2} \mathbf{r}_{ij}}_{\text{đẩy}}.$$

Cập nhật $\mathbf{y}_i \leftarrow \mathbf{y}_i - \eta \frac{\partial C_{ij}}{\partial \mathbf{y}_i}$, nên *lực* (hướng cập nhật) là $\mathbf{f}_{ij} = -\frac{\partial C_{ij}}{\partial \mathbf{y}_i}$:

- **Lực hút** (cặp láng giềng, B_{ij} lớn)—kéo $\mathbf{y}_i$ về phía $\mathbf{y}_j$:

$$\mathbf{f}_{ij}^{\text{attr}} = \frac{-2ab B_{ij} d_{ij}^{2b-2}}{1 + a d_{ij}^{2b}} \mathbf{r}_{ij}.$$

- **Lực đẩy** (cặp không láng giềng, $B_{ik} \approx 0$)—đẩy $\mathbf{y}_i$ ra xa $\mathbf{y}_k$:

$$\mathbf{f}_{ik}^{\text{rep}} = \frac{2ab d_{ik}^{2b-2}}{(1 - w_{ik})(1 + a d_{ik}^{2b})^2} \mathbf{r}_{ik}.$$

Cập nhật SGD mỗi epoch. Duyệt qua tất cả các cạnh (i, j) trong đồ thị thưa (chỉ những cặp mà $B_{ij} > 0$). Với mỗi cạnh:

1. Tung đồng xu với xác suất mặt ngửa = B_{ij} . Nếu ngửa: cập nhật $\mathbf{y}_i \leftarrow \mathbf{y}_i + \eta \mathbf{f}_{ij}^{\text{attr}}$ (kéo $\mathbf{y}_i$ về phía $\mathbf{y}_j$). Cạnh có B_{ij} lớn được chọn thường xuyên hơn $\rightarrow$ lực hút mạnh hơn.
2. Chọn ngẫu nhiên $\mathbf{n_neg_samples}$ điểm k (lấy mẫu âm—giả định các cặp ngẫu nhiên không phải láng giềng). Với mỗi k : cập nhật $\mathbf{y}_i \leftarrow \mathbf{y}_i + \eta \mathbf{f}_{ik}^{\text{rep}}$ (đẩy $\mathbf{y}_i$ ra xa $\mathbf{y}_k$).

1.3 Khai triển gradient MLE, NCE, NEG cho nhúng láng giềng

Phần này khai triển tường minh ba gradient trong khung nhúng láng giềng (Mục 4.1), đồng thời chứng minh $F_{\text{rep}} \propto \frac{1}{Z}$ từ (28). Ký hiệu chung: $d_{ij} = \|\mathbf{y}_i - \mathbf{y}_j\|$, $\mathbf{r}_{ij} = \mathbf{y}_i - \mathbf{y}_j$, $\phi(ij) := \frac{1}{1+d_{ij}^2}$.

A. Đạo hàm kernel Cauchy. Bằng chain rule:

$$\frac{\partial \phi(ij)}{\partial \mathbf{y}_i} = \frac{d\phi}{dd_{ij}} \cdot \frac{\partial d_{ij}}{\partial \mathbf{y}_i} = \frac{-2d_{ij}}{(1+d_{ij}^2)^2} \cdot \frac{\mathbf{r}_{ij}}{d_{ij}} = -\frac{2}{(1+d_{ij}^2)^2} \mathbf{r}_{ij} = -2\phi(ij)^2 \mathbf{r}_{ij}.$$

B. Gradient MLE (t-SNE). Khai triển $\mathcal{L}_{\text{t-SNE}} = -\sum_{ij} p(ij) \log \phi(ij) + \log Z(\theta)$ (dùng $\sum_{ij} p(ij) = 1$):

$$\begin{aligned} \frac{\partial}{\partial \mathbf{y}_i} (-\log \phi(ij)) &= -\frac{1}{\phi(ij)} \cdot (-2\phi(ij)^2 \mathbf{r}_{ij}) = 2\phi(ij) \mathbf{r}_{ij}, \\ \frac{\partial \log Z(\theta)}{\partial \mathbf{y}_i} &= \frac{1}{Z(\theta)} \sum_{j' \neq i} \frac{\partial \phi(ij')}{\partial \mathbf{y}_i} = \frac{-2}{Z(\theta)} \sum_{j' \neq i} \phi(ij')^2 \mathbf{r}_{ij'}. \end{aligned}$$

Kết hợp, với $q_\theta(ij) = \frac{\phi(ij)}{Z(\theta)}$:

$$\frac{\partial \mathcal{L}_{\text{t-SNE}}}{\partial \mathbf{y}_i} = 2 \sum_{j \neq i} \left(\frac{p(ij)}{q_\theta(ij)} - 1 \right) \frac{1}{Z(\theta)} \cdot \frac{\partial \phi(ij)}{\partial \mathbf{y}_i}. \quad (31)$$

C. Gradient NCE tổng quát và NC-t-SNE. Với $f = q_{\theta, Z}(x) = \frac{\phi_\theta(x)}{Z}$ và $c = m\xi(x)$, tính đạo hàm từng số hạng của (3):

$$\frac{d}{d\theta} \log \frac{f}{f+c} = \frac{c}{f(f+c)} \frac{df}{d\theta}, \quad \frac{d}{d\theta} \log \frac{c}{f+c} = \frac{-1}{f+c} \frac{df}{d\theta}.$$

Lấy kỳ vọng và kết hợp (với $\frac{df}{d\theta} = \frac{1}{Z} \frac{d\phi_\theta}{d\theta}$):

$$\frac{d\mathcal{L}_{\text{NCE}}}{d\theta} = - \sum_x \frac{m\xi(x)}{q_{\theta,Z}(x) + m\xi(x)} \left(\frac{p(x)}{q_{\theta,Z}(x)} - 1 \right) \frac{1}{Z} \frac{d\phi_\theta(x)}{d\theta}. \quad (32)$$

Cụ thể hóa theo $\mathbf{y}_i$ cho nhúng láng giềng:

$$\frac{\partial \mathcal{L}_{\text{NC-t-SNE}}}{\partial \mathbf{y}_i} = 2 \sum_{j \neq i} \underbrace{\frac{\frac{m\xi(ij)}{\frac{\phi(ij)}{Z} + m\xi(ij)}}{m \rightarrow \infty} \rightarrow 1}_{\frac{\phi(ij)}{Z} + m\xi(ij)} \left(\frac{p(ij)}{q_{\theta,Z}(ij)} - 1 \right) \frac{1}{Z} \cdot \frac{\partial \phi(ij)}{\partial \mathbf{y}_i}, \quad (33)$$

và gradient Neg-t-SNE thu được khi thay $Z \rightarrow \bar{Z}$ (cố định):

$$\frac{\partial \mathcal{L}_{\text{Neg-t-SNE}}}{\partial \mathbf{y}_i} = 2 \sum_{j \neq i} \underbrace{\frac{m\xi(ij)}{\frac{\phi(ij)}{\bar{Z}} + m\xi(ij)}}_{\in [0.5, 1]} \left(\frac{p(ij)}{\frac{\phi(ij)}{\bar{Z}}} - 1 \right) \frac{1}{\bar{Z}} \cdot \frac{\partial \phi(ij)}{\partial \mathbf{y}_i}. \quad (34)$$

D. Phân tách lực hút/đẩy và chứng minh $F_{\text{rep}} \propto \frac{1}{\bar{Z}}$. Xấp xỉ hệ số dampening bằng 1 (hợp lệ khi $\bar{Z}$ lớn) và tách tổng (34) theo hai nhóm:

$$\begin{aligned} \frac{\partial \mathcal{L}_{\text{Neg-t-SNE}}}{\partial \mathbf{y}_i} &\approx 2 \sum_{j \neq i} \left(\frac{p(ij)}{\frac{\phi(ij)}{\bar{Z}}} - 1 \right) \frac{1}{\bar{Z}} \cdot \frac{\partial \phi(ij)}{\partial \mathbf{y}_i} \\ &= 2 \underbrace{\sum_{j: p(ij) > 0} \left(\frac{\bar{Z} p(ij)}{\phi(ij)} - 1 \right) \frac{1}{\bar{Z}} \cdot \frac{\partial \phi}{\partial \mathbf{y}_i}}_{\text{lực hút}} + 2 \underbrace{\sum_{j: p(ij) = 0} (-1) \frac{1}{\bar{Z}} \cdot \frac{\partial \phi}{\partial \mathbf{y}_i}}_{\text{lực đẩy}}. \end{aligned}$$

Lực hút: $\frac{\bar{Z} p(ij)}{\phi(ij)} \cdot \frac{1}{\bar{Z}} = \frac{p(ij)}{\phi(ij)}$ —không phụ thuộc $\bar{Z}$.

Lực đẩy: thay $\frac{\partial \phi}{\partial \mathbf{y}_i} = -2\phi(ij)^2 \mathbf{r}_{ij}$:

$$\mathbf{f}_{ij}^{\text{rep}} = 2 \cdot (-1) \cdot \frac{1}{\bar{Z}} \cdot (-2\phi(ij)^2 \mathbf{r}_{ij}) = \frac{4\phi(ij)^2}{\bar{Z}} \mathbf{r}_{ij}, \quad F_{\text{rep}} \propto \frac{\phi(ij)^2}{\bar{Z}} \propto \frac{1}{\bar{Z}}.$$

Khi $\bar{Z}$ tăng (UMAP: $\mathcal{O}(n^2)$), lực đẩy suy yếu trong khi lực hút giữ nguyên—điểm tương đồng bị kéo sát nhau tạo cụm siêu co chặt, đúng hành vi quan sát được ở UMAP so với t-SNE.