

ĐẠI HỌC QUỐC GIA TP HCM
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN



Dimensionality Reduction

Môn học: Nhập môn học máy

Sinh viên thực hiện:

Đỗ Tiến Đạt - 23120119

Lê Nhật Minh Tâm - 23120163

Triệu Tuấn Kiệt - 23120137

Nguyễn Đăng Khoa - 23120134

Huỳnh Mạnh Tường - 23120105

Giáo viên hướng dẫn:

Thầy Bùi Tiến Lên

Thầy Lê Nhựt Nam

Ngày 27 tháng 5 năm 2026

Mục lục

Chương 1	Giới thiệu	1
1.1	Bài toán và ký hiệu	1
1.2	Động lực thực hiện	1
1.3	Ví dụ Swiss roll	2
1.4	Đóng góp của báo cáo	2
Chương 2	Cơ sở lý thuyết	2
2.1	Ma trận dữ liệu và hiệp phương sai	3
2.2	Phân tích giá trị kỳ dị	3
2.3	Chiều trực giao và chuẩn Frobenius	3
2.4	Phương sai theo một hướng	4
2.5	Kernel và ma trận Gram	4
2.6	Đồ thị láng giềng và Laplacian	5
Chương 3	Phương pháp giảm chiều	5
3.1	Phân tích thành phần chính (PCA)	5
3.2	PCA trong không gian kernel (KPCA)	7
3.3	Học manifold qua KPCA	9
3.3.1	Isomap	9
3.3.2	Laplacian eigenmaps	11
3.3.3	Locally Linear Embedding (LLE)	12
3.4	Bổ đề Johnson–Lindenstrauss	13
3.5	Mối liên hệ trong chương	15
Chương 4	Thực nghiệm và phân tích kết quả	15
4.1	Thiết lập thực nghiệm	16
4.2	PCA: phương sai và lỗi tái tạo	16
4.3	KPCA: cấu trúc phi tuyến của hai vòng tròn	17
4.4	Isomap: bảo toàn khoảng cách geodesic trên Swiss roll	19
4.5	Các đoạn cài đặt chính	20

Chương 5	Nghiên cứu tiên tiến liên quan	25
5.1	Bài báo được khảo sát	25
5.2	Bài toán nghiên cứu	26
5.3	Đóng góp chính của bài báo	26
5.4	Liên hệ với lý thuyết giảm chiều đã trình bày	28
5.5	[MỞ RỘNG] Đối chiếu với cài đặt của nhóm	28
5.6	Xu hướng, hạn chế và câu hỏi mở	29
Chương 6	Tổng kết	30
6.1	Tổng kết	30
	Tài liệu tham khảo	31

Danh sách bảng

1	Các hướng giảm chiều trong chương	12
2	Phiên bản môi trường dùng để tái lập thực nghiệm chính.	16
3	Thiết lập cho ba thực nghiệm minh họa.	16
4	Một số kết quả PCA trên Wine.	17
5	Silhouette theo nhãn tổng hợp cho PCA và RBF-KPCA.	18
6	Độ nhạy Isomap theo số láng giềng trên Swiss roll.	19
7	Góc nhìn của Wang et al. về các thuật toán trực quan hóa giảm chiều.	27
8	Quan hệ giữa bài báo khảo sát và nội dung lý thuyết của báo cáo.	28
9	Thực nghiệm mở rộng trên 10 000 mẫu MNIST trong <code>baseline.ipynb</code> (<code>SEED = 42</code>).	29

Danh sách hình vẽ

1	Ý tưởng Swiss roll: mẫu nằm trên cấu trúc hai chiều được nhúng trong không gian cao chiều; sau giảm chiều, quan hệ láng giềng dễ quan sát hơn.	2
2	Dữ liệu hai chiều (điểm xanh) và hướng thành phần chính thứ nhất (đường đỏ). . .	4
3	Isomap: khoảng cách trên manifold được xấp xỉ bằng tổng độ dài cạnh trên đường đi ngắn nhất (nét liền xanh lá), không dùng trực tiếp đoạn thẳng Euclidean (nét đứt).	11
4	Chiều ngẫu nhiên Johnson–Lindenstrauss: giảm chiều với bảo đảm trên khoảng cách cặp.	15
5	Phương sai tích lũy và lỗi tái tạo PCA trên dữ liệu Wine đã chuẩn hóa.	17
6	Dữ liệu Circles quan sát ở hai chiều gốc và kết quả giảm từ 10 chiều xuống 2 chiều bằng PCA, KPCA.	18
7	Độ nhạy của RBF-KPCA theo γ khi giảm Circles mở rộng từ 10 chiều xuống 2 chiều.	18
8	Swiss roll ban đầu và hai biểu diễn hai chiều bằng PCA, Isomap.	19
9	Tương quan khoảng cách của Isomap thay đổi theo số láng giềng.	20

Chương 1 Giới thiệu

Khi số chiều đặc trưng rất lớn, nhiều thuật toán học máy tốn kém bộ nhớ và thời gian, đồng thời khó quan sát cấu trúc dữ liệu. *Giảm chiều* (dimensionality reduction) nhằm tìm một biểu diễn có số chiều nhỏ hơn nhưng vẫn giữ được phần thông tin hoặc quan hệ hình học quan trọng của tập mẫu gốc.

Quy tắc ký hiệu trong báo cáo

- **Tập hợp:** $\mathcal{X}$ (không gian mẫu), $\mathcal{H}$ (không gian Hilbert), P_k (tập ma trận chiều).
- **Vector:** chữ thường in đậm, ví dụ $\mathbf{x}_i \in \mathbb{R}^N$.
- **Ma trận:** chữ hoa in đậm, ví dụ $\mathbf{X} \in \mathbb{R}^{N \times m}$.
- **Vô hướng (scalar):** chữ nghiêng thường, ví dụ $N, m, k, \varepsilon, \lambda$.

1.1 Bài toán và ký hiệu

Cho tập mẫu $S = (x_1, \dots, x_m)$ với $x_i \in \mathcal{X}$, ánh xạ đặc trưng $\Phi : \mathcal{X} \rightarrow \mathbb{R}^N$ và ma trận dữ liệu

$$\mathbf{X} = [\Phi(x_1), \dots, \Phi(x_m)] \in \mathbb{R}^{N \times m},$$


cột thứ i là vector $\mathbf{x}_i = \Phi(x_i)$. Ta muốn tìm ma trận biểu diễn $\mathbf{Y} \in \mathbb{R}^{k \times m}$ với $k \ll N$ sao cho $\mathbf{Y}$ phản ánh $\mathbf{X}$ theo tiêu chí đã chọn (lỗi tái tạo, phương sai, khoảng cách, lằng giềng, ...).

1.2 Động lực thực hiện

- **Tính toán:** nén dữ liệu trước khi huấn luyện hoặc truy vấn, giảm chi phí lưu trữ và phép toán.
- **Trực quan:** đưa mẫu về hai hoặc ba chiều để khám phá cụm, ngoại lệ, xu hướng.
- **Trích đặc trưng:** tạo tập chiều thấp hy vọng hữu ích hơn cho phân loại hoặc hồi quy phía sau.

1.3 Ví dụ Swiss roll

Swiss roll là dữ liệu mô phỏng ba chiều nằm gần một mặt hai chiều “cuộn” (Hình 1). Nếu “mở” mặt này ra phẳng, quan hệ láng giềng trở nên rõ. Trong thực tế, manifold lý tưởng hiếm khi khớp hoàn toàn; ví dụ này chủ yếu giúp hình dung vì sao cần phương pháp *phi tuyến*, chứ không phải bằng chứng cho mọi bộ dữ liệu thật.



Hình 1: Ý tưởng Swiss roll: mẫu nằm trên cấu trúc hai chiều được nhúng trong không gian cao chiều; sau giảm chiều, quan hệ láng giềng dễ quan sát hơn.

1.4 Đóng góp của báo cáo

1. Chương 2: kiến thức nền (hiệp phương sai, SVD, kernel, đồ thị).
2. Chương 3: PCA, KPCA, Isomap, Laplacian eigenmaps, LLE, định lý Johnson–Lindenstrauss.
3. Chương 4: thực nghiệm và phân tích kết quả cho PCA, KPCA và Isomap.
4. Chương 5: tổng kết và hướng nghiên cứu gần đây.

Nguồn tham khảo chính cho phần lý thuyết là *Foundations of Machine Learning* [3].

Chương 2 Cơ sở lý thuyết

Chương này gom các khái niệm cần dùng khi đọc PCA, KPCA và các phương pháp học manifold. Phần lớn là đại số ma trận quen thuộc; ta chỉ nhắc lại đủ để các chứng minh ở Chương 3 mạch lạc.

2.1 Ma trận dữ liệu và hiệp phương sai

Với mẫu $x_1, \dots, x_m \in \mathcal{X}$, ma trận $\mathbf{X}$ như Chương 1. Khi nói dữ liệu *đã căn giữa theo cột*, ta có $\sum_{i=1}^m \mathbf{x}_i = \mathbf{0}$.

Định nghĩa 2.1 (Hiệp phương sai mẫu). Với dữ liệu đã căn giữa,

$$\mathbf{C} = \frac{1}{m} \mathbf{X} \mathbf{X}^\top \in \mathbb{R}^{N \times N}.$$

Phần tử $\mathbf{C}_{ij}$ đo mức đồng biến tuyến tính giữa hai đặc trưng sau khi trừ trung bình.

Nếu chưa căn giữa, dùng $\bar{\mathbf{x}} = \frac{1}{m} \sum_i \mathbf{x}_i$ và $\mathbf{C} = \frac{1}{m} \sum_i (\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{x}_i - \bar{\mathbf{x}})^\top$.

2.2 Phân tích giá trị kỳ dị

Định nghĩa 2.2 (SVD). Với $\mathbf{X} \in \mathbb{R}^{N \times m}$, tồn tại phân tích

$$\mathbf{X} = \mathbf{U} \mathbf{\Sigma} \mathbf{V}^\top,$$

$\mathbf{U}, \mathbf{V}$ có cột trực chuẩn, $\mathbf{\Sigma}$ đường chéo các giá trị kỳ dị không âm $\sigma_1 \geq \sigma_2 \geq \dots$.

Đặt $\mathbf{\Lambda} = \mathbf{\Sigma}^2 = \text{diag}(\sigma_1^2, \sigma_2^2, \dots)$. Khi đó

$$\mathbf{C} = \frac{1}{m} \mathbf{U} \mathbf{\Lambda} \mathbf{U}^\top, \quad \mathbf{K} = \mathbf{X}^\top \mathbf{X} = \mathbf{V} \mathbf{\Lambda} \mathbf{V}^\top,$$

với $\mathbf{K}$ là ma trận Gram (kernel tuyến tính trên các cột $\mathbf{x}_i$). Do đó, nếu $\lambda_i = \sigma_i^2$ là trị riêng khác không của $\mathbf{K}$, thì trị riêng tương ứng của $\mathbf{C}$ là λ_i/m . Hai ma trận chia sẻ thông tin phổ đến một hệ số tỉ lệ, nhưng dùng hai hệ vector riêng khác nhau; đây là cầu nối giữa PCA và KPCA.

2.3 Chiếu trực giao và chuẩn Frobenius


Định nghĩa 2.3 (Ma trận chiếu bậc k). P_k gồm các ma trận $\mathbf{P} = \mathbf{U} \mathbf{U}^\top$ với $\mathbf{U} \in \mathbb{R}^{N \times k}$ có cột trực chuẩn, $\text{rank}(\mathbf{P}) = k$. Khi đó $\mathbf{P}^2 = \mathbf{P}$, $\mathbf{P}^\top = \mathbf{P}$.

Chuẩn Frobenius: $\|\mathbf{M}\|_F^2 = \text{Tr}(\mathbf{M}^\top \mathbf{M})$. Tính hoán vị của trace ($\text{Tr}(\mathbf{ABC}) = \text{Tr}(\mathbf{BCA})$) dùng nhiều trong chứng minh PCA.

2.4 Phương sai theo một hướng

Với vector đơn vị $\mathbf{u}$, lượng $\mathbf{u}^\top \mathbf{C} \mathbf{u}$ là phương sai của chiếu một chiều lên $\mathbf{u}$. Bài toán $\max_{\|\mathbf{u}\|=1} \mathbf{u}^\top \mathbf{C} \mathbf{u}$ đạt tại vector riêng của $\mathbf{C}$ ứng với trị riêng lớn nhất (thương số Rayleigh). Các hướng tiếp theo tối đa hóa phương sai trong không gian vuông góc với các hướng đã chọn.

Ví dụ 2.1. Hai đặc trưng trên mặt phẳng tương quan mạnh (ví dụ cùng đo kích thước giày nhưng đơn vị khác nhau). Đám điểm kéo dài theo một đường chéo; chiếu lên đường đó giữ phần lớn biến thiên, chiếu vuông góc gần như mất thông tin—đó là động lực hình học của thành phần chính thứ nhất (Hình 2).



Hình 2: Dữ liệu hai chiều (điểm xanh) và hướng thành phần chính thứ nhất (đường đỏ).

2.5 Kernel và ma trận Gram

Định nghĩa 2.4 (Kernel xác định dương bán). Hàm $K : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ là kernel PDS nếu tồn tại $\mathcal{H}$ và $\Phi : \mathcal{X} \rightarrow \mathcal{H}$ sao cho $K(x, x') = \langle \Phi(x), \Phi(x') \rangle$.

Trên m điểm, ma trận $\mathbf{K}$ với $K_{ij} = K(x_i, x_j)$ luôn xác định dương bán. KPCA chỉ cần $\mathbf{K}$, không cần biết Φ tường minh.

2.6 Đồ thị láng giềng và Laplacian

Các thuật toán manifold thường:

1. Chọn t láng giềng gần nhất cho mỗi điểm (theo $\|\mathbf{x}_i - \mathbf{x}_j\|$).
2. Gán trọng số W_{ij} trên cạnh (Gaussian, hệ số tái tạo, ...).
3. Dùng ma trận Laplacian $\mathbf{L} = \mathbf{D} - \mathbf{W}$, với $D_{ii} = \sum_j W_{ij}$.

Ma trận căn giữa (centering) dùng trong Isomap:

$$\mathbf{H} = \mathbf{I}_m - \frac{1}{m} \mathbf{1}\mathbf{1}^\top,$$

với $\mathbf{1}$ là vector toàn 1. Nhân $\mathbf{H}$ hai bên một ma trận khoảng cách giúp chuyển sang dạng tương tự tích vô hướng trong không gian đã trừ trung bình.

Chương 3 Phương pháp giảm chiều

Chương trình bày các phương pháp cổ điển: từ chiếu tuyến tính tối ưu lỗi tái tạo (PCA), mở rộng qua kernel (KPCA), rồi tới học manifold và chiếu ngẫu nhiên có bảo đảm lý thuyết (Johnson–Lindenstrauss).

3.1 Phân tích thành phần chính (PCA)

Cho $k \in \{1, \dots, N\}$ và $\mathbf{X}$ đã căn giữa. PCA tìm ma trận chiếu $\mathbf{P} \in P_k$ sao cho tái tạo sau chiếu gần $\mathbf{X}$ nhất theo chuẩn Frobenius [4, 3]:

$$\min_{\mathbf{P} \in P_k} \|\mathbf{P}\mathbf{X} - \mathbf{X}\|_F^2. \quad (1)$$

Định lý 3.1 (Nghiệm PCA). *Nghiệm $\mathbf{P}^*$ của (1) có dạng $\mathbf{P}^* = \mathbf{U}_k \mathbf{U}_k^\top$, trong đó $\mathbf{U}_k \in \mathbb{R}^{N \times k}$ gồm k vector riêng ứng với k trị riêng lớn nhất của $\mathbf{C} = \frac{1}{m} \mathbf{X}\mathbf{X}^\top$. Biểu diễn k chiều là $\mathbf{Y} = \mathbf{U}_k^\top \mathbf{X}$.*

Chứng minh. Vì $\mathbf{P}$ là phép chiếu trực giao nên $\mathbf{P}^\top = \mathbf{P}$ và $\mathbf{P}^2 = \mathbf{P}$. Khai triển norm và dùng tính tuyến tính của trace:

$$\|\mathbf{P}\mathbf{X} - \mathbf{X}\|_F^2 = \text{Tr}(\mathbf{X}^\top \mathbf{P}^\top \mathbf{P} \mathbf{X} - 2\mathbf{X}^\top \mathbf{P} \mathbf{X} + \mathbf{X}^\top \mathbf{X}) = -\text{Tr}(\mathbf{X}^\top \mathbf{P} \mathbf{X}) + \text{Tr}(\mathbf{X}^\top \mathbf{X}),$$

số hạng thứ hai không phụ thuộc $\mathbf{P}$. Vậy ta cần cực đại $\text{Tr}(\mathbf{X}^\top \mathbf{P} \mathbf{X})$ trên P_k .

Viết $\mathbf{P} = \mathbf{U} \mathbf{U}^\top$ với $\mathbf{U}$ có k cột trực chuẩn. Hoán vị trace cho

$$\text{Tr}(\mathbf{X}^\top \mathbf{P} \mathbf{X}) = \text{Tr}(\mathbf{U}^\top \mathbf{X} \mathbf{X}^\top \mathbf{U}) = \sum_{i=1}^k \mathbf{u}_i^\top \mathbf{X} \mathbf{X}^\top \mathbf{u}_i,$$

với $\mathbf{u}_i$ là cột thứ i của $\mathbf{U}$. Theo nguyên lý Rayleigh–Ritz, tổng trên đạt lớn nhất bằng tổng k trị riêng lớn nhất của $\mathbf{X} \mathbf{X}^\top$, khi các $\mathbf{u}_i$ là các vector riêng tương ứng. Các vector này cũng là vector riêng của $\mathbf{C} = \frac{1}{m} \mathbf{X} \mathbf{X}^\top$, nên suy ra $\mathbf{P}^*$ và $\mathbf{Y} = \mathbf{U}_k^\top \mathbf{X}$. $\square$

Cách nhìn theo phương sai. Vector riêng của $\mathbf{C}$ trở theo hướng biến thiên mạnh nhất; trị riêng bằng phương sai của dữ liệu chiếu lên hướng đó. Thành phần chính thứ i là chiếu lên hướng phương sai lớn thứ i , vuông góc các hướng trước.

Bổ đề 3.1 (Phương sai giữ lại và lỗi tái tạo). Gọi $\gamma_1 \geq \dots \geq \gamma_N \geq 0$ là các trị riêng của $\mathbf{C}$. PCA bậc k giữ tổng phương sai $\sum_{i=1}^k \gamma_i$ và đạt lỗi tối thiểu

$$\|\mathbf{P}^* \mathbf{X} - \mathbf{X}\|_F^2 = m \sum_{i=k+1}^N \gamma_i.$$

Tỉ lệ phương sai giải thích bởi k thành phần là $(\sum_{i=1}^k \gamma_i) / (\sum_{i=1}^N \gamma_i)$.

Chứng minh. Từ chứng minh Định lý 3.1, $\text{Tr}(\mathbf{X}^\top \mathbf{P}^* \mathbf{X}) = m \sum_{i=1}^k \gamma_i$. Mặt khác, $\text{Tr}(\mathbf{X}^\top \mathbf{X}) = m \text{Tr}(\mathbf{C}) = m \sum_{i=1}^N \gamma_i$. Thế vào (1) cho biểu thức lỗi. Phần phương sai được giữ chính là tổng trị riêng trên các hướng được chiếu. $\square$

[MỞ RỘNG]

Nếu hai trị riêng liên tiếp thỏa $\gamma_k = \gamma_{k+1}$ thì không gian con tối ưu không duy nhất: có thể chọn bất kỳ cơ sở trực chuẩn phù hợp trong không gian riêng đồng trị. Tuy vậy, giá trị lỗi tối ưu trong Bổ đề 3.1 không đổi.

Ví dụ 3.1 (Hai đặc trưng tương quan). Đo cùng một đại lượng (ví dụ cỡ giày) bằng hai thang đơn vị khác nhau. Sau căn giữa, đám điểm gần một đường thẳng; chiếu lên thành phần chính thứ nhất cho một số gần đủ mô tả biến thiên (Hình 2, Chương 2).

Thuật toán PCA từ đầu. Trước hết trừ vector trung bình khỏi mỗi mẫu để tạo $\mathbf{X}$ đã căn giữa; tiếp theo tính $\mathbf{C} = \frac{1}{m}\mathbf{X}\mathbf{X}^\top$ hoặc thực hiện SVD trực tiếp trên $\mathbf{X}$; sau đó chọn k vector riêng lớn nhất làm các cột của $\mathbf{U}_k$; cuối cùng xuất embedding $\mathbf{Y} = \mathbf{U}_k^\top \mathbf{X}$. Dữ liệu xấp xỉ trong không gian gốc là $\hat{\mathbf{X}} = \mathbf{U}_k \mathbf{Y}$. Hiện thực của nhóm dùng thin SVD, do đó nhận $k \leq \min(m, N)$; giới hạn này phù hợp với bài toán giảm chiều đang xét.

3.2 PCA trong không gian kernel (KPCA)

PCA giả định vector đặc trưng nằm trong $\mathbb{R}^N$. Nhiều khi ta chỉ có thể tính tích vô hướng trong một không gian Hilbert tái sinh $\mathcal{H}$ cao (hoặc vô hạn) chiều qua kernel $K(x, x') = \langle \Phi(x), \Phi(x') \rangle_{\mathcal{H}}$. KPCA thực hiện PCA trên các vector $\Phi(x_i)$ mà không cần xây chúng tường minh [2, 3].

Căn giữa trong không gian đặc trưng. Ngay cả khi các x_i đã căn giữa trong không gian đầu vào, ảnh $\Phi(x_i)$ nhìn chung chưa có trung bình bằng không. Đặt $\bar{\Phi} = \frac{1}{m} \sum_i \Phi(x_i)$, $\tilde{\Phi}(x_i) = \Phi(x_i) - \bar{\Phi}$ và $\mathbf{H} = \mathbf{I}_m - \frac{1}{m}\mathbf{1}\mathbf{1}^\top$. Ma trận Gram của các ảnh đã căn giữa là

$$\tilde{\mathbf{K}} = \mathbf{H}\mathbf{K}\mathbf{H}, \quad K_{ij} = K(x_i, x_j). \quad (2)$$

Với điểm mới x , đặt $\mathbf{k}_x = (K(x_1, x), \dots, K(x_m, x))^\top$. Vector tích vô hướng đã căn giữa giữa các điểm huấn luyện và x là

$$\tilde{\mathbf{k}}_x = \mathbf{k}_x - \frac{1}{m}\mathbf{K}\mathbf{1} - \frac{1}{m}\mathbf{1}\mathbf{1}^\top \mathbf{k}_x + \frac{1}{m^2}\mathbf{1}\mathbf{1}^\top \mathbf{K}\mathbf{1}. \quad (3)$$

Các bước thực hiện.

1. Lập $\mathbf{K}$, $K_{ij} = K(x_i, x_j)$.
2. Căn giữa kernel theo (2).
3. Lấy k cặp trị riêng/vector riêng lớn nhất $(\lambda_j, \mathbf{v}_j)$ của $\tilde{\mathbf{K}}$ với $\lambda_j > 0$ và $\|\mathbf{v}_j\| = 1$.
4. Với điểm mới x , căn giữa $\mathbf{k}_x$ theo (3); tọa độ thứ j là $\tilde{\mathbf{k}}_x^\top \mathbf{v}_j / \sqrt{\lambda_j}$.

Định lý 3.2 (Tọa độ KPCA). *Giả sử $\tilde{\mathbf{K}}\mathbf{v}_j = \lambda_j\mathbf{v}_j$, $\lambda_j > 0$ và $\|\mathbf{v}_j\| = 1$. Hướng thành phần chính đơn vị thứ j trong $\mathcal{H}$ có thể viết*

$$\mathbf{w}_j = \frac{1}{\sqrt{\lambda_j}} \sum_{i=1}^m v_{ji} \tilde{\Phi}(x_i).$$

Tọa độ của điểm x lên hướng này bằng

$$y_j(x) = \langle \tilde{\Phi}(x), \mathbf{w}_j \rangle_{\mathcal{H}} = \frac{\tilde{\mathbf{k}}_x^\top \mathbf{v}_j}{\sqrt{\lambda_j}}.$$

Với tập huấn luyện, embedding k chiều có dạng

$$\mathbf{Y} = \mathbf{\Lambda}_k^{1/2} \mathbf{V}_k^\top,$$

trong đó $\mathbf{\Lambda}_k = \text{diag}(\lambda_1, \dots, \lambda_k)$.

Chứng minh. Chuẩn bình phương của hướng được đề xuất là

$$\|\mathbf{w}_j\|_{\mathcal{H}}^2 = \frac{1}{\lambda_j} \mathbf{v}_j^\top \tilde{\mathbf{K}} \mathbf{v}_j = 1.$$

Lấy tích vô hướng với $\tilde{\Phi}(x)$ cho công thức tọa độ. Riêng với $x = x_i$, ta có $\tilde{\mathbf{k}}_{x_i}^\top \mathbf{v}_j = (\tilde{\mathbf{K}} \mathbf{v}_j)_i = \lambda_j v_{ji}$; do đó $y_j(x_i) = \sqrt{\lambda_j} v_{ji}$. Ghép k hàng tọa độ cho toàn bộ mẫu thu được công thức ma trận. $\square$

PCA là trường hợp riêng của KPCA. Khi kernel tuyến tính trên dữ liệu đã căn giữa, $\mathbf{K} = \mathbf{X}^\top \mathbf{X}$. Từ SVD $\mathbf{X} = \mathbf{U} \mathbf{\Sigma} \mathbf{V}^\top$ suy ra

$$\mathbf{C} = \frac{1}{m} \mathbf{U} \mathbf{\Lambda} \mathbf{U}^\top, \quad \mathbf{K} = \mathbf{V} \mathbf{\Lambda} \mathbf{V}^\top, \quad \mathbf{\Lambda} = \mathbf{\Sigma}^2. \quad (4)$$

Nếu $\mathbf{K}\mathbf{v} = \lambda\mathbf{v}$ với $\lambda > 0$, thì $\mathbf{u} = \mathbf{X}\mathbf{v}/\sqrt{\lambda}$ là vector đơn vị và là vector riêng của $\mathbf{C}$ ứng với trị riêng λ/m . Chiếu một chiều lên $\mathbf{u}$ cho

$$\Phi(x)^\top \mathbf{u} = \frac{\mathbf{k}_x^\top \mathbf{v}}{\sqrt{\lambda}}. \quad (5)$$

Nếu $x = x_i$ trong mẫu thì tọa độ bằng $\sqrt{\lambda} v_i$. Toàn bộ KPCA chỉ cần eigendecomposition của $\mathbf{K}$ —PCA là trường hợp $\mathbf{K} = \mathbf{X}^\top \mathbf{X}$.

Ví dụ 3.2 (Kernel cho cấu trúc phi tuyến). Hai vòng tròn đồng tâm trong mặt phẳng không thể

được tách theo bán kính bởi một phép chiếu tuyến tính một chiều: mọi trục đều trộn lẫn các điểm của hai vòng. Với kernel Gaussian $K(x, x') = \exp(-\gamma\|x - x'\|_2^2)$, các điểm trên cùng vòng có quan hệ tương tự khác với các điểm ở vòng còn lại. KPCA có thể biểu diễn quan hệ phi tuyến này trong vài thành phần đầu; tham số γ quyết định mức độ “cục bộ” của sự tương tự.

3.3 Học manifold qua KPCA

Giả định dữ liệu cao chiều nằm gần một manifold nhúng. Thay vì chọn kernel “có sẵn”, ta *thiết kế* ma trận tương tự kernel từ đồ thị láng giềng hoặc khoảng cách địa hình, rồi áp dụng cùng khung phân rã phổ (trích các vector riêng thích hợp tùy bài toán).

3.3.1 Isomap

Ý tưởng: giữ khoảng cách “đi bộ” trên manifold, xấp xỉ bằng đường đi ngắn nhất trên đồ thị t -láng giềng [6, 3].

1. Dựng đồ thị vô hướng: nối mỗi điểm với t láng giềng gần nhất (khoảng cách Euclidean).
2. Trong hiện thực, nếu đồ thị bị rời thành nhiều thành phần, nối dần hai thành phần gần nhất bằng cạnh Euclidean ngắn nhất để có thể tính khoảng cách hữu hạn giữa mọi cặp điểm.
3. Tính khoảng cách ngắn nhất δ_{ij} giữa mọi cặp đỉnh (ví dụ Floyd–Warshall).
4. Từ ma trận khoảng cách bình phương Δ , đặt $\mathbf{K}_{\text{Iso}} = -\frac{1}{2}\mathbf{H}\Delta\mathbf{H}$.
5. Lấy k chiều từ k trị riêng dương lớn nhất của $\mathbf{K}_{\text{Iso}}$:

$$\mathbf{Y} = \Sigma_{\text{Iso},k}^{1/2} \mathbf{U}_{\text{Iso},k}^\top. \quad (6)$$

Bổ đề 3.2 (Double centering). Cho $\mathbf{Z} = [\mathbf{z}_1, \dots, \mathbf{z}_m]$ là ma trận điểm đã căn giữa, $\mathbf{Z}\mathbf{1} = \mathbf{0}$, và $\Delta_{ij} = \|\mathbf{z}_i - \mathbf{z}_j\|_2^2$. Khi đó

$$-\frac{1}{2}\mathbf{H}\Delta\mathbf{H} = \mathbf{Z}^\top \mathbf{Z}.$$

Chứng minh. Đặt $q_i = \|\mathbf{z}_i\|_2^2$ và $\mathbf{q} = (q_1, \dots, q_m)^\top$. Từ khai triển bình phương khoảng cách,

$$\Delta = \mathbf{q}\mathbf{1}^\top + \mathbf{1}\mathbf{q}^\top - 2\mathbf{Z}^\top \mathbf{Z}.$$

Vì $\mathbf{H}\mathbf{1} = \mathbf{0}$, hai số hạng đầu biến mất khi nhân $\mathbf{H}$ ở hai phía. Hơn nữa, $\mathbf{ZH} = \mathbf{Z}$ do dữ liệu đã căn giữa. Suy ra

$$-\frac{1}{2}\mathbf{H}\Delta\mathbf{H} = \mathbf{HZ}^\top\mathbf{ZH} = \mathbf{Z}^\top\mathbf{Z}.$$

□

Trong Isomap, δ_{ij} là khoảng cách đường đi ngắn nhất thay vì khoảng cách Euclidean thực sự. Bổ đề 3.2 giải thích vì sao thuật toán xem $\mathbf{K}_{\text{Iso}} = -\frac{1}{2}\mathbf{H}\Delta\mathbf{H}$ như một ma trận Gram: nếu các geodesic xấp xỉ khoảng cách Euclidean trong hệ tọa độ đã “trải phẳng”, phép biến đổi sẽ khôi phục Gram của hệ tọa độ đó.


Bổ đề 3.3 (Embedding spectral của Isomap). *Nếu $\mathbf{K}_{\text{Iso}}$ xác định dương bán và có phân rã $\mathbf{K}_{\text{Iso}} = \mathbf{U}\Sigma\mathbf{U}^\top$ với các trị riêng giảm dần, thì ma trận tọa độ*

$$\mathbf{Y} = \Sigma_{\text{Iso},k}^{1/2} \mathbf{U}_{\text{Iso},k}^\top$$

thỏa $\mathbf{Y}^\top\mathbf{Y} = \mathbf{U}_{\text{Iso},k}\Sigma_{\text{Iso},k}\mathbf{U}_{\text{Iso},k}^\top$, là xấp xỉ Gram hạng k tốt nhất của $\mathbf{K}_{\text{Iso}}$ theo chuẩn Frobenius.

Chứng minh. Theo định lý xấp xỉ hạng thấp Eckart–Young, cắt phân rã phổ tại k trị riêng lớn nhất cho xấp xỉ hạng k tối ưu của ma trận đối xứng xác định dương bán. Ma trận $\mathbf{Y}$ ở trên có Gram đúng bằng xấp xỉ bị cắt đó. Kết hợp với Bổ đề 3.2, Gram gần đúng tương ứng với việc giữ gần các khoảng cách bình phương đã cung cấp cho bước MDS. □

Trên mẫu hữu hạn, $\mathbf{K}_{\text{Iso}}$ đôi khi không xác định dương bán vì khoảng cách đồ thị không nhất thiết là khoảng cách Euclidean của một không gian phẳng. Isomap gần với scaling đa chiều cổ điển (MDS) nhưng dùng geodesic thay vì khoảng cách Euclidean trực tiếp. Số láng giềng t cần chọn thận trọng: t quá nhỏ có thể làm đồ thị đứt rời, buộc bước nối thành phần trong hiện thực thêm cạnh ngoài đồ thị láng giềng ban đầu; t quá lớn lại tạo các cạnh tắt xuyên qua manifold.



Hình 3: Isomap: khoảng cách trên manifold được xấp xỉ bằng tổng độ dài cạnh trên đường đi ngắn nhất (nét liền xanh lá), không dùng trực tiếp đoạn thẳng Euclidean (nét đứt).

Ví dụ 3.3 (Trải phẳng Swiss roll). Trên Swiss roll, hai điểm nằm ở hai lớp cuộn kế nhau có thể gần theo khoảng cách Euclidean nhưng xa nếu đi dọc theo bề mặt. Đồ thị láng giềng loại bỏ phần lớn đường tắt này; khoảng cách đường đi ngắn nhất do đó bám theo mặt cuộn. Bước double centering và phân rã phổ sau đó tạo embedding hai chiều gần với tờ giấy trước khi bị cuộn.

[MỞ RỘNG]

Chứng minh double centering ở Bổ đề 3.2 cũng cho thấy Isomap là KPCA với kernel được suy ra từ khoảng cách geodesic. Điểm khác biệt cốt lõi so với KPCA dùng Gaussian kernel là kernel này phụ thuộc vào toàn bộ đồ thị láng giềng và đường đi ngắn nhất, không chỉ vào từng cặp khoảng cách Euclidean ban đầu.

3.3.2 Laplacian eigenmaps

Ưu tiên láng giềng gần trong không gian đầu vẫn gần trong không gian thấp. Trọng số $W_{ij} = \exp(-\|\mathbf{x}_i - \mathbf{x}_j\|^2/\sigma^2)$ nếu i, j là láng giềng, ngược lại 0. Đặt $\mathbf{D}_{ii} = \sum_j W_{ij}$ và $\mathbf{L} = \mathbf{D} - \mathbf{W}$. Với quy ước $\mathbf{Y} = [\mathbf{y}_1, \dots, \mathbf{y}_m] \in \mathbb{R}^{k \times m}$, bài toán chuẩn hóa là

$$\min_{\mathbf{Y}} \frac{1}{2} \sum_{i,j} W_{ij} \|\mathbf{y}_i - \mathbf{y}_j\|^2 = \text{tr}(\mathbf{Y}\mathbf{L}\mathbf{Y}^\top), \quad \text{s.t. } \mathbf{Y}\mathbf{D}\mathbf{Y}^\top = \mathbf{I}_k, \quad \mathbf{Y}\mathbf{D}\mathbf{1} = \mathbf{0}. \quad (7)$$

Ràng buộc loại nghiệm suy biến trong đó mọi điểm cùng trùng nhau. Nghiệm tổng quát lấy các vector riêng không tầm thường nhỏ nhất của bài toán $\mathbf{L}\mathbf{u} = \lambda\mathbf{D}\mathbf{u}$. Cài đặt của nhóm sử dụng biến thể không chuẩn hóa, giải trực tiếp $\mathbf{L}\mathbf{u} = \lambda\mathbf{u}$ và lấy k vector riêng sau vector hằng ứng với trị riêng

0 khi đồ thị liên thông. Có thể hiểu là KPCA với kernel liên quan $\mathbf{K}_L = \mathbf{L}^\dagger$: phạt nặng khi hai điểm láng giềng bị đẩy xa trong không gian thấp [1].

3.3.3 Locally Linear Embedding (LLE)

Mỗi $\mathbf{x}_i$ được xấp xỉ tuyến tính bởi láng giềng:

$$\min_{\sum_j W_{ij}=1} \left\| \mathbf{x}_i - \sum_{j \in \mathcal{N}_i} W_{ij} \mathbf{x}_j \right\|^2.$$

Khai triển cho hệ số W_{ij} dẫn tới ma trận hiệp phương sai cục bộ $\mathbf{C}'$ và

$$W_{ij} = \frac{\sum_{k \in \mathcal{N}_i} (\mathbf{C}'^{-1})_{jk}}{\sum_{s, t \in \mathcal{N}_i} (\mathbf{C}'^{-1})_{st}}. \quad (8)$$

Sau khi cố định $\mathbf{W}$, tìm $\mathbf{y}_i$ sao cho quan hệ tái tạo tuyến tính được giữ:

$$\min_i \sum_j \left\| \mathbf{y}_i - \sum_j W_{ij} \mathbf{y}_j \right\|^2,$$

kèm các ràng buộc định tâm và chuẩn hóa để loại nghiệm suy biến. Theo quy ước mỗi hàng của $\mathbf{W}$ chứa trọng số tái tạo một mẫu như trong cài đặt, ta có

$$\mathbf{M} = (\mathbf{I} - \mathbf{W})^\top (\mathbf{I} - \mathbf{W}).$$

Embedding gồm k vector riêng ứng với các trị riêng nhỏ nhất khác 0 của $\mathbf{M}$. LLE cũng có dạng KPCA với kernel xây từ $\mathbf{W}$ [5].

Bảng 1: Các hướng giảm chiều trong chương

Phương pháp	Tính chất	Ma trận cốt lõi	Giữ gì
PCA	Tuyến tính	$\mathbf{K} = \mathbf{X}^\top \mathbf{X}$	Phương sai toàn cục
KPCA	Phi tuyến (kernel)	$\mathbf{K}$ tùy chọn	Cấu trúc kernel
Isomap	Manifold	$\mathbf{K}_{\text{Iso}}$ từ geodesic	Khoảng cách toàn cục (xấp xỉ)
Laplacian	Manifold	$\mathbf{L}, \mathbf{K}_L$	Láng giềng cục bộ
LLE	Manifold	$\mathbf{W}, \mathbf{M}$	Tái tạo tuyến tính cục bộ
Chiều ngẫu nhiên	Ngẫu nhiên	$\mathbf{A}/\sqrt{k}$	Khoảng cách cặp (JL)

So sánh nhanh.

3.4 Bổ đề Johnson–Lindenstrauss

Khác với PCA (tối ưu phương sai), bổ đề Johnson–Lindenstrauss (JL) trả lời câu hỏi: với m điểm cố định trong $\mathbb{R}^N$, có thể chiếu tuyến tính xuống $\mathbb{R}^k$ với k nhỏ đến mức nào mà *mọi* khoảng cách cặp chỉ bị méo hệ số $(1 \pm \varepsilon)$?

Bổ đề 3.4 (Tập trung phân phối χ^2). Với $\varepsilon \in (0, 1)$ và $Z_1, \dots, Z_k$ i.i.d. $\mathcal{N}(0, 1)$, đặt $S = \sum_{i=1}^k Z_i^2$. Khi đó

$$\Pr\left(\left|\frac{S}{k} - 1\right| > \varepsilon\right) \leq 2e^{-\varepsilon^2 k/8}.$$

Chứng minh. Dùng bất đẳng thức Chernoff (Markov trên e^{tS}). Với $t < 1/2$, MGF của Z_i^2 là $\mathbb{E}[e^{tZ_i^2}] = (1 - 2t)^{-1/2}$, nên $\mathbb{E}[e^{tS}] = (1 - 2t)^{-k/2}$.

Đuôi trên ($S > (1 + \varepsilon)k$): với $t \in (0, 1/2)$,

$$\Pr(S > (1 + \varepsilon)k) \leq \frac{(1 - 2t)^{-k/2}}{e^{t(1+\varepsilon)k}}.$$

Chọn $t = \varepsilon/(2(1 + \varepsilon))$ và dùng $\ln(1 + \varepsilon) \leq \varepsilon - \varepsilon^2/4$ (với $\varepsilon \in (0, 1)$) suy ra $\Pr(S > (1 + \varepsilon)k) \leq e^{-\varepsilon^2 k/8}$.

Đuôi dưới ($S < (1 - \varepsilon)k$): với $t \in (-1/2, 0)$, chọn $t = -\varepsilon/(2(1 - \varepsilon))$ và $\ln(1 - \varepsilon) \leq -\varepsilon - \varepsilon^2/2$ cho $\Pr(S < (1 - \varepsilon)k) \leq e^{-\varepsilon^2 k/4}$.

Vì $e^{-\varepsilon^2 k/4} \leq e^{-\varepsilon^2 k/8}$, union bound trên hai đuôi cho $\Pr(|\frac{S}{k} - 1| > \varepsilon) \leq 2e^{-\varepsilon^2 k/8}$. $\square$

Định lý 3.3 (Johnson–Lindenstrauss). Cho $0 < \varepsilon < 1$ và tập hữu hạn $\mathcal{V} = \{\mathbf{v}_1, \dots, \mathbf{v}_m\} \subset \mathbb{R}^N$. Nếu $k > \frac{16 \log m}{\varepsilon^2}$, thì tồn tại ánh xạ $f: \mathbb{R}^N \rightarrow \mathbb{R}^k$ sao cho mọi $\mathbf{u}, \mathbf{v} \in \mathcal{V}$,

$$(1 - \varepsilon)\|\mathbf{u} - \mathbf{v}\|^2 \leq \|f(\mathbf{u}) - f(\mathbf{v})\|^2 \leq (1 + \varepsilon)\|\mathbf{u} - \mathbf{v}\|^2.$$

Chứng minh. Xét một ma trận ngẫu nhiên $\mathbf{R} \in \mathbb{R}^{k \times N}$ với $R_{ij} \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(0, 1)$. Các hàng $\mathbf{r}_i^\top$ của $\mathbf{R}$ là vector Gaussian độc lập trong $\mathbb{R}^N$. Đặt $f(\mathbf{x}) = \frac{1}{\sqrt{k}} \mathbf{R}\mathbf{x}$, ta sẽ chứng minh tồn tại ánh xạ f như vậy thỏa mãn bổ đề.

Với $\mathbf{x} \in \mathbb{R}^N$ bất kỳ, viết $\mathbf{R}\mathbf{x} = (\mathbf{r}_1^\top \mathbf{x}, \dots, \mathbf{r}_k^\top \mathbf{x})^\top$, nên

$$\|\mathbf{R}\mathbf{x}\|^2 = \sum_{i=1}^k (\mathbf{r}_i^\top \mathbf{x})^2.$$

Vì $\mathbf{r}_i^\top \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_N)$ nên $\mathbf{r}_i^\top \mathbf{x} \sim \mathcal{N}(0, \|\mathbf{x}\|^2)$, tức $\mathbf{r}_i^\top \mathbf{x} = \|\mathbf{x}\| Z_i$ với $Z_i \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(0, 1)$. Đặt $S = \sum_{i=1}^k Z_i^2 \sim \chi_k^2$, ta có

$$\frac{\|\mathbf{R}\mathbf{x}\|^2}{\|\mathbf{x}\|^2} = S \Rightarrow \|f(\mathbf{x})\|^2 = \frac{\|\mathbf{R}\mathbf{x}\|^2}{k} = \frac{S}{k} \|\mathbf{x}\|^2.$$

Áp dụng Bổ đề 3.4 với $S = \frac{1}{\|\mathbf{x}\|^2} \|\mathbf{R}\mathbf{x}\|^2$ suy ra

$$\Pr\left(\left|\frac{S}{k} - 1\right| > \varepsilon\right) \leq 2e^{-\varepsilon^2 k/8}.$$

Đặt $\mathbf{x} = \mathbf{u} - \mathbf{v}$. Vì f tuyến tính, $f(\mathbf{u}) - f(\mathbf{v}) = f(\mathbf{u} - \mathbf{v})$, nên

$$\Pr((1 - \varepsilon)\|\mathbf{u} - \mathbf{v}\|^2 \leq \|f(\mathbf{u}) - f(\mathbf{v})\|^2 \leq (1 + \varepsilon)\|\mathbf{u} - \mathbf{v}\|^2) \geq 1 - 2e^{-\varepsilon^2 k/8}.$$

Gọi $A_{\mathbf{u}, \mathbf{v}}$ là sự kiện khoảng cách cặp $(\mathbf{u}, \mathbf{v})$ được bảo toàn (bất đẳng thức trên), và $A = \bigcap_{\mathbf{u} \neq \mathbf{v}} A_{\mathbf{u}, \mathbf{v}}$. Với $\binom{m}{2}$ cặp,

$$\Pr(A^c) = \Pr\left(\bigcup_{\mathbf{u} \neq \mathbf{v}} A_{\mathbf{u}, \mathbf{v}}^c\right) \leq \binom{m}{2} \cdot 2e^{-\varepsilon^2 k/8} < m^2 e^{-\varepsilon^2 k/8}.$$


Để $\Pr(A) > 0$ (tức tồn tại $\mathbf{R}$ thỏa mọi cặp), cần $m^2 e^{-\varepsilon^2 k/8} < 1$, tương đương

$$k > \frac{8 \cdot 2 \log m}{\varepsilon^2} = \frac{16 \log m}{\varepsilon^2}.$$

Vậy với k như giả thiết định lý, xác suất chọn được $\mathbf{R}$ phù hợp là dương, nên ánh xạ f như vậy tồn tại. $\square$

Ý nghĩa. JL cho phép giảm N xuống $k \approx \log m$ (bỏ qua hệ số $1/\varepsilon^2$) mà vẫn giữ hình học cặp điểm—cơ sở cho *random projection* làm tiền xử lý nhanh, không cần SVD. Trong sách [3] dùng hằng số 20; chứng minh Chernoff và union bound ở trên cho hằng số 16, cùng bậc tiệm cận.

Ví dụ 3.4. Với $m = 1000$, $\varepsilon = 0,1$, ngưỡng $k > 16 \ln(1000)/0,01 \approx 1,1 \times 10^4$. Trên thực nghiệm thường chọn k nhỏ hơn nhiều vẫn chấp nhận được; bảo đảm JL là chặn đủ cho trường hợp xấu nhất chứ không phải lựa chọn tối thiểu trong mọi dữ liệu.



Hình 4: Chiều ngẫu nhiên Johnson–Lindenstrauss: giảm chiều với bảo đảm trên khoảng cách cặp.

[MỞ RỘNG]

Độ phức tạp (ước lượng). SVD đầy đủ $\mathbf{X}$: $O(\min(Nm^2, N^2m))$. Floyd–Warshall: $O(m^3)$. Eigendecomposition Laplacian thưa: gần tuyến tính theo số cạnh. Chiều JL: nhân ma trận $O(kNm)$, không cần SVD—phù hợp tiền xử lý nhanh khi chỉ cần giữ khoảng cách cặp.

3.5 Mối liên hệ trong chương

PCA là nền tảng tuyến tính: tối ưu lỗi tái tạo hoặc phương sai. KPCA thay $\mathbf{X}$ bằng $\mathbf{K}$, mở đường cho kernel tùy biến. Isomap, Laplacian, LLE *thiết kế* $\mathbf{K}$ (hoặc ma trận liên hệ) từ geometry đồ thị rồi dùng cùng khung phân tích kỳ dị. JL không tìm trực tiếp tối ưu mà chứng minh chiều ngẫu nhiên đủ tốt—hữu ích khi ưu tiên tốc độ và bảo đảm đơn giản.

Các mảng kiến thức liên quan trong học máy: phương pháp kernel (ánh xạ ngầm Φ), đại số ma trận (SVD, trace, PSD), và học có giám sát có thể dùng $\mathbf{Y}$ làm đầu vào cho mô hình sau. Tài liệu gốc [3] trình bày đầy đủ hơn; báo cáo này tập trung diễn giải và chứng minh các mất xích chính.

Chương 4 Thực nghiệm và phân tích kết quả

Phần này kiểm chứng ba phương pháp trọng tâm đã cài đặt là PCA, KPCA và Isomap. Toàn bộ hình và số liệu được tạo bởi tệp `code/experiments/report_pca_kpca_isomap.py` với `SEED = 42`. Lỗi ba thuật toán dùng các lớp trong `code/models/`; thư viện ngoài chỉ hỗ trợ nạp dữ liệu, chuẩn hóa đặc trưng và tính chỉ số đánh giá.

4.1 Thiết lập thực nghiệm

Các thí nghiệm chính được tái lập trong môi trường phần mềm ở Bảng 2. PCA, KPCA và Isomap không phụ thuộc vào PyTorch hay `contrastive-ne`; hai gói này chỉ liên quan đến phân khảo sát Neg-t-SNE bổ sung, tách khỏi các kết quả chính bên dưới.

Bảng 2: Phiên bản môi trường dùng để tái lập thực nghiệm chính.

Thành phần	Phiên bản	Vai trò
Python	3.13.3	Môi trường thực thi
NumPy	2.4.4	Đại số tuyến tính và cài đặt thuật toán
SciPy	1.17.1	Hàm hỗ trợ tính toán số
scikit-learn	1.8.0	Dữ liệu, chuẩn hóa và chỉ số đánh giá
Matplotlib	3.10.9	Sinh hình trực quan hóa
umap-learn	0.5.12	Đối chiếu UMAP ở phân khảo sát bổ sung

Bảng 3: Thiết lập cho ba thực nghiệm minh họa.


Dữ liệu	Mục tiêu	Thiết lập
Wine	Kiểm chứng phương sai giữ lại và lỗi tái tạo của PCA	178 mẫu, 13 thuộc tính được chuẩn hóa; $k = 1, \dots, 13$
Circles mở rộng	Kiểm chứng giảm chiều và độ nhạy kernel của KPCA	1000 điểm; thêm 8 chiều nhiễu chuẩn độ lệch 0.03; giảm $10D \rightarrow 2D$
Swiss roll	Đánh giá bảo toàn khoảng cách geodesic của Isomap	700 điểm, nhiễu 0.05; khảo sát $t \in \{4, 8, 12, 20, 40\}$

4.2 PCA: phương sai và lỗi tái tạo

Theo Bổ đề 3.1, nghiệm PCA tối ưu phải làm lỗi tái tạo không tăng khi số chiều giữ lại k tăng. Hình 5 kiểm chứng trực tiếp tính chất này trên dữ liệu Wine sau khi chuẩn hóa. Trong bảng và hình dưới đây, code báo cáo lỗi trung bình trên mỗi mẫu,

$$E_{\text{rec}} = \frac{1}{m} \|\hat{\mathbf{X}} - \mathbf{X}\|_F^2,$$

là phiên bản chuẩn hóa của lỗi tổng trong Bổ đề 3.1.



Hình 5: Phương sai tích lũy và lỗi tái tạo PCA trên dữ liệu Wine đã chuẩn hóa.


Bảng 4: Một số kết quả PCA trên Wine.

Số thành phần k	Phương sai tích lũy	Lỗi tái tạo trung bình
1	0.3620	8.2941
2	0.5541	5.7972
13	1.0000	≈ 0

Hai thành phần đầu giữ khoảng 55.41% tổng phương sai. Khi giữ toàn bộ 13 thành phần, lỗi tái tạo chỉ còn 1.17×10^{-29} , là sai số số học và phù hợp với việc phép đổi cơ sở trực chuẩn không làm mất thông tin. Trong phần lý thuyết, ma trận hiệp phương sai dùng hệ số $1/m$ để công thức gọn hơn; cài đặt dùng quy ước ước lượng phương sai mẫu $1/(m-1)$ cho thuộc tính `explained_variance_`. Hai quy ước chỉ nhân toàn bộ trị riêng với cùng một hằng số, nên không đổi các hướng chính, tỉ lệ phương sai tích lũy hay kết luận về lỗi tái tạo.


4.3 KPCA: cấu trúc phi tuyến của hai vòng tròn

Dữ liệu hai vòng tròn đồng tâm ban đầu có hai chiều; thí nghiệm nối thêm tám chiều nhiễu Gaussian nhỏ để tạo đầu vào 10 chiều, sau đó giảm về hai chiều. Cách thiết kế này vừa giữ cấu trúc phi tuyến cần quan sát, vừa kiểm tra đúng một bài toán giảm chiều. Khi dùng kernel tuyến tính, khoảng cách cặp điểm trong embedding KPCA và PCA chỉ lệch tối đa 2.22×10^{-15} , phù hợp với quan hệ PCA là trường hợp riêng của KPCA. Với RBF và $\gamma = 32$, hai trị riêng lớn nhất của ma trận kernel đã căn giữa lần lượt là 28.6625 và 28.1265.



Hình 6: Dữ liệu Circles quan sát ở hai chiều gốc và kết quả giảm từ 10 chiều xuống 2 chiều bằng PCA, KPCA.

Trong Hình 6, PCA giữ hình học tuyến tính chính, còn RBF-KPCA tái biểu diễn hai vòng theo độ tương tự kernel. Để lượng hóa ảnh hưởng của γ , ta dùng hệ số silhouette với nhãn đã biết của dữ liệu tổng hợp; nhãn này chỉ dùng để đánh giá sau khi nhúng, không tham gia huấn luyện KPCA.



Hình 7: Độ nhạy của RBF-KPCA theo γ khi giảm Circles mở rộng từ 10 chiều xuống 2 chiều.

Bảng 5: Silhouette theo nhãn tổng hợp cho PCA và RBF-KPCA.


Phương pháp	PCA	RBF-KPCA, γ				
γ	—	0.5	2	8	32	128
Silhouette	0.1125	0.0496	0.0037	0.2359	0.3775	0.2411

Giá trị $\gamma = 32$ được chọn cho hình biểu diễn vì cho silhouette cao nhất trong năm giá trị khảo sát.

Kết quả này chỉ khẳng định sự phù hợp của kernel trong ví dụ tổng hợp đang xét, không khẳng định một tham số tối ưu chung cho dữ liệu khác.

4.4 Isomap: bảo toàn khoảng cách geodesic trên Swiss roll


Đối với Swiss roll, khoảng cách Euclid trong không gian ba chiều có thể đưa hai điểm ở các lớp cuộn khác nhau đến gần nhau không đúng với cấu trúc mặt cong. Vì vậy, chỉ số đánh giá sử dụng ở đây là hệ số tương quan Pearson giữa khoảng cách geodesic trên đồ thị láng giềng của Isomap và khoảng cách Euclid giữa các cặp điểm sau khi nhúng xuống hai chiều.



Hình 8: Swiss roll ban đầu và hai biểu diễn hai chiều bằng PCA, Isomap.

Bảng 6: Độ nhạy Isomap theo số láng giềng trên Swiss roll.

Phương pháp	PCA	Isomap, số láng giềng t				
		4	8	12	20	40
Tương quan Pearson	0.2806	0.9964	0.9990	0.9996	0.8267	0.8671



Hình 9: Tương quan khoảng cách của Isomap thay đổi theo số láng giềng.

Kết quả trong Bảng 6 cho thấy Isomap với $t = 12$ gần như duy trì khoảng cách geodesic trên dữ liệu tổng hợp này, trong khi PCA chỉ mô hình hóa phương sai tuyến tính. Khi t tăng lên 20 hoặc 40, tương quan giảm rõ, phù hợp với nguy cơ cạnh tắt qua các lớp cuộn đã nêu ở phần lý thuyết. Chỉ số ở đây đo mức khớp với khoảng cách đồ thị tương ứng của mỗi thiết lập, tức là kiểm chứng trực tiếp mục tiêu nội tại của Isomap. Cài đặt còn có bước nối các thành phần liên thông bằng cạnh Euclidean ngắn nhất nếu đồ thị t -láng giềng bị rời; trong thí nghiệm này, đồ thị đã liên thông ở cả năm giá trị t nên bước đó không thay đổi các khoảng cách hoặc kết quả báo cáo.

4.5 Các đoạn cài đặt chính

Trong phần lý thuyết, mỗi mẫu là một cột của $\mathbf{X} \in \mathbb{R}^{N \times m}$ và $\mathbf{Y} \in \mathbb{R}^{k \times m}$. Trong code Python, theo quy ước NumPy, mỗi mẫu là một hàng: $\mathbf{X}.\text{shape} = (m, N)$ và $\mathbf{Y}.\text{shape} = (m, k)$. Do đó các phép nhân trong listing là chuyển vị tương đương của công thức lý thuyết.

Cài đặt PCA dưới đây sử dụng SVD trên dữ liệu đã trừ trung bình và cung cấp trực tiếp hàm tính lỗi tái tạo dùng trong Hình 5.

```

1 def _fit(self, X: np.ndarray) -> None:
2     max_components = min(X.shape)
3     if self.n_components > max_components:
4         raise ValueError(

```

```

5         f"n_components ({self.n_components}) must be <= min(n_samples,
n_features) "
6         f"({max_components})."
7     )
8
9     _, singular_values, components = np.linalg.svd(X, full_matrices=False)
10    denominator = max(X.shape[0] - 1, 1)
11    all_variance = (singular_values ** 2) / denominator
12    total_variance = float(np.sum(all_variance))
13
14    self.components_ = components[: self.n_components]
15    self.singular_values_ = singular_values[: self.n_components]
16    self.explained_variance_ = all_variance[: self.n_components]
17    if total_variance > 0.0:
18        self.explained_variance_ratio_ = self.explained_variance_ / total_variance
19    else:
20        self.explained_variance_ratio_ = np.zeros(self.n_components, dtype=float)
21
22    def _transform(self, X: np.ndarray) -> np.ndarray:
23        if self.components_ is None:
24            raise RuntimeError("PCA has not been fitted.")
25        return X @ self.components_.T
26
27    def _inverse_transform(self, Y: np.ndarray) -> np.ndarray:
28        if self.components_ is None:
29            raise RuntimeError("PCA has not been fitted.")
30        return Y @ self.components_
31
32    def reconstruction_error(self, X: np.ndarray) -> float:
33        """Return mean squared reconstruction error per sample."""
34        X = np.asarray(X, dtype=float)
35        reconstructed = self.inverse_transform(self.transform(X))
36        return float(np.mean(np.sum((X - reconstructed) ** 2, axis=1)))

```

Listing 1: Cài đặt lõi PCA và lõi tái tạo.

```

1    def _fit(self, X: np.ndarray) -> None:
2        if self.kernel == "precomputed":

```

```

3         if X.shape[0] != X.shape[1]:
4             raise ValueError("For kernel='precomputed', X must be a square
Gram matrix.")
5         K = np.asarray(X, dtype=float)
6         self.X_fit_ = None
7     else:
8         self.X_fit_ = X.copy()
9         K = self._kernel(X, X)
10
11     Kc = self._center_fit_kernel(K)
12     eigenvalues, eigenvectors = np.linalg.eigh(Kc)
13     order = np.argsort(eigenvalues)[::-1]
14     eigenvalues = eigenvalues[order]
15     eigenvectors = eigenvectors[:, order]
16
17     positive = eigenvalues > self.eigen_tol
18     if int(np.sum(positive)) < self.n_components:
19         raise ValueError(
20             f"KPCA found only {int(np.sum(positive))} positive eigenvalues;
"
21             f"need {self.n_components}."
22         )
23     eigenvalues = eigenvalues[positive][: self.n_components]
24     eigenvectors = eigenvectors[:, positive][:, : self.n_components]
25
26     self.eigenvalues_ = eigenvalues
27     self.eigenvectors_ = eigenvectors
28     self.alphas_ = eigenvectors / np.sqrt(eigenvalues)
29     self.embedding_ = eigenvectors * np.sqrt(eigenvalues)

```

Listing 2: KPCA: phân rã phổ trên Gram matrix đã căn giữa.

```

1     def _center_fit_kernel(self, K: np.ndarray) -> np.ndarray:
2         self.K_fit_rows_mean_ = K.mean(axis=0)
3         self.K_fit_all_mean_ = float(K.mean())
4         return K - K.mean(axis=1, keepdims=True) - self.K_fit_rows_mean_[None,
:] + self.K_fit_all_mean_
5

```

```

6     def _center_transform_kernel(self, K: np.ndarray) -> np.ndarray:
7         if self.K_fit_rows_mean_ is None or self.K_fit_all_mean_ is None:
8             raise RuntimeError("Missing fitted kernel centering statistics.")
9         return K - K.mean(axis=1, keepdims=True) - self.K_fit_rows_mean_[None,
: ] + self.K_fit_all_mean_
    
```

Listing 3: KPCA: căn giữa kernel cho tập huấn luyện và điểm mới.

```

1     distances = cdist(X, X, metric="euclidean")
2     graph = self._build_neighbor_graph(distances)
3     graph = self._connect_components(graph, distances)
4     geodesic = shortest_path(graph, directed=False, unweighted=False)
5     if not np.isfinite(geodesic).all():
6         raise ValueError(
7             "The Isomap neighbor graph is disconnected. Increase n_neighbors
8             "
9             "or use a smaller/cleaner sample."
10        )
11
12    K = self._double_center(geodesic ** 2)
13    eigenvalues, eigenvectors = np.linalg.eigh(K)
14    order = np.argsort(eigenvalues)[::-1]
15    eigenvalues = eigenvalues[order]
16    eigenvectors = eigenvectors[:, order]
17
18    positive = eigenvalues > self.eigen_tol
19    if int(np.sum(positive)) < self.n_components:
20        raise ValueError(
21            f"Isomap found only {int(np.sum(positive))} positive eigenvalues
22            ; "
23            f"need {self.n_components}."
24        )
25
26    self.eigenvalues_ = eigenvalues[positive][: self.n_components]
27    self.eigenvectors_ = eigenvectors[:, positive][:, : self.n_components]
28    self.embedding_ = self.eigenvectors_ * np.sqrt(self.eigenvalues_)
29    self.geodesic_distances_ = geodesic
    
```

```
28 self.kernel_ = K
```

Listing 4: Isomap: khoảng cách geodesic và phân rã phổ.

```
1 @staticmethod
2 def _connect_components(graph: sparse.csr_matrix, distances: np.ndarray) ->
sparse.csr_matrix:
3     n_components, labels = connected_components(graph, directed=False)
4     if n_components <= 1:
5         return graph
6
7     graph = graph.tolil(copy=True)
8     connected = {0}
9     remaining = set(range(1, n_components))
10
11     while remaining:
12         best: tuple[float, int, int, int] | None = None
13         connected_mask = np.isin(labels, list(connected))
14         connected_idx = np.flatnonzero(connected_mask)
15         for comp in remaining:
16             comp_idx = np.flatnonzero(labels == comp)
17             block = distances[np.ix_(connected_idx, comp_idx)]
18             local = int(np.argmin(block))
19             row, col = np.unravel_index(local, block.shape)
20             d = float(block[row, col])
21             if best is None or d < best[0]:
22                 best = (d, int(connected_idx[row]), int(comp_idx[col]), comp
23 )
24
25         if best is None:
26             break
27
28         d, i, j, comp = best
29         graph[i, j] = d
30         graph[j, i] = d
31         connected.add(comp)
32         remaining.remove(comp)
33
34     return graph.tocsr()
```

Listing 5: Isomap: nối các thành phần của đồ thị k-NN nếu cần.

```

1  @staticmethod
2  def _double_center(D2: np.ndarray) -> np.ndarray:
3      row_mean = D2.mean(axis=1, keepdims=True)
4      col_mean = D2.mean(axis=0, keepdims=True)
5      all_mean = D2.mean()
6      return -0.5 * (D2 - row_mean - col_mean + all_mean)
    
```

Listing 6: Isomap: phép double centering từ khoảng cách bình phương.

Tái tạo kết quả. Các hình và bảng trong phần này được sinh lại bằng lệnh:

```

1  uv run python code/experiments/report_pca_kpca_isomap.py
    
```

Các kiểm chứng mở rộng ngoài phạm vi ba thực nghiệm trọng tâm được lưu trong notebook `baseline.ipynb` ở thư mục `code/experiments`. Notebook này đánh giá thêm LLE và Laplacian Eigenmaps do nhóm cài đặt, cùng các wrapper t-SNE và UMAP, trên bốn tập dữ liệu; kết quả MNIST được tóm tắt tại Bảng 9. Đánh giá thực nghiệm cho Johnson–Lindenstrauss chưa được dùng làm căn cứ cho các kết luận trong phần này.

Chương 5 Nghiên cứu tiên tiến liên quan

5.1 Bài báo được khảo sát

Phần này khảo sát bài báo của Wang, Huang, Rudin và Shaposhnik, *Understanding How Dimension Reduction Tools Work: An Empirical Approach to Deciphering t-SNE, UMAP, TriMap, and PaCMAP for Data Visualization*, công bố trên *Journal of Machine Learning Research* [7]. Bài báo nghiên cứu các thuật toán giảm chiều phục vụ trực quan hóa, đặc biệt trong tình huống dữ liệu chiều cao được nhúng xuống hai chiều. Ngoài phân tích t-SNE, UMAP và TriMap, tác giả đề xuất thuật toán PaCMAP (*Pairwise Controlled Manifold Approximation Projection*).

Nội dung này nối tiếp với các phương pháp đã trình bày ở các chương trước. PCA cung cấp phép chiếu tuyến tính và thường là khởi tạo cho các thuật toán hiện đại; Isomap, Laplacian eigenmaps và LLE biểu diễn quan điểm dữ liệu nằm trên manifold thông qua quan hệ lân cận; KPCA cho thấy cách tạo embedding phi tuyến từ độ tương tự. Bài báo tiếp tục câu hỏi đó trong bối cảnh trực quan hóa: một embedding đẹp cần giữ thông tin lân cận nào và giữ bao nhiêu cấu trúc toàn cục.

5.2 Bài toán nghiên cứu

Một scatter plot hai chiều có thể khiến người đọc diễn giải khoảng cách giữa cụm, kích thước cụm hoặc các khoảng trống như cấu trúc thật của dữ liệu gốc. Tuy nhiên, khi giảm từ số chiều lớn xuống hai chiều, không thể bảo toàn đồng thời mọi khoảng cách. t-SNE và UMAP thường làm nổi bật láng giềng cục bộ, trong khi cấu trúc giữa các nhóm xa nhau có thể bị biến dạng. Ngược lại, một phương pháp quá ưu tiên cấu trúc toàn cục có thể làm mờ các cụm nhỏ có ý nghĩa.

Từ vấn đề này, bài báo đặt ra ba câu hỏi chính:

1. Vì sao các thuật toán phổ biến tạo ra những embedding khác nhau, dù cùng được dùng cho trực quan hóa?
2. Thành phần nào của hàm mất mát, đồ thị hoặc phép khởi tạo quyết định khả năng giữ cấu trúc cục bộ và toàn cục?
3. Có thể thiết kế một thuật toán cân bằng hai mục tiêu đó tốt hơn hay không?

5.3 Đóng góp chính của bài báo

Phân tích hàm mất mát bằng lực hút và lực đẩy. Các tác giả diễn giải thuật toán trực quan hóa thông qua lực hút giữa những điểm cần ở gần nhau và lực đẩy giữa những điểm không nên chồng lên nhau. Thay vì chỉ so sánh công thức, bài báo đưa ra biểu diễn “rainbow figure” để quan sát độ lớn gradient theo khoảng cách trong không gian gốc và không gian nhúng. Từ phân tích thực nghiệm này, tác giả tổng hợp sáu nguyên tắc cho một hàm mất mát có khả năng giữ cấu trúc cục bộ tốt; chẳng hạn điểm láng giềng bị đặt xa cần chịu lực hút đủ mạnh, còn điểm không lân cận đã ở xa không nên tiếp tục chi phối quá mức quá trình tối ưu [7].

Vai trò của đồ thị và phép khởi tạo. Bài báo chỉ ra rằng chỉ thu hút các láng giềng gần nhất và đẩy các điểm xa khi chúng va vào nhau chưa đủ để phục hồi cấu trúc toàn cục. Các cặp điểm ở khoảng cách trung gian cung cấp thông tin quan trọng về bố cục tổng thể. Ngoài ra, hiệu quả giữ cấu trúc toàn cục của TriMap phụ thuộc đáng kể vào khởi tạo PCA; điều này nhấn mạnh rằng kết quả embedding không chỉ do hàm mất mát, mà còn do trạng thái ban đầu và thang đo của khởi tạo.

Thuật toán PaCMAP. PaCMAP xây dựng ba loại cặp điểm:

- *neighbor pairs*: các cặp láng giềng dùng để duy trì cấu trúc cục bộ;
- *mid-near pairs*: các cặp ở khoảng cách trung gian giúp định hình cấu trúc toàn cục;
- *further pairs*: các cặp xa giúp tránh việc embedding co cụm không hợp lý.

Thuật toán tối ưu theo ba giai đoạn. Giai đoạn đầu đặt trọng số rất lớn cho *mid-near pairs* để dựng bố cục lớn; sau đó trọng số này giảm dần để cân bằng các loại cặp; giai đoạn cuối giảm vai trò của cặp trung gian và tinh chỉnh quan hệ lân cận. Theo các thí nghiệm trên dữ liệu ảnh, văn bản, dữ liệu sinh học và dữ liệu tổng hợp trong bài báo, PaCMAP đạt cân bằng tốt giữa đánh giá cục bộ và toàn cục, đồng thời có thời gian chạy cạnh tranh.

Bảng 7: Góc nhìn của Wang et al. về các thuật toán trực quan hóa giảm chiều.

Phương pháp	Thông tin ưu tiên	Nhận xét liên quan trong bài báo
t-SNE	Láng giềng cục bộ	Cho cụm cục bộ rõ, nhưng bố cục toàn cục không nên được diễn giải trực tiếp.
UMAP	Đồ thị lân cận mờ	Có dạng lực phù hợp với các nguyên tắc giữ cục bộ được phân tích.
TriMap	Quan hệ bộ ba	Khả năng giữ toàn cục chịu ảnh hưởng lớn từ khởi tạo PCA.
PaCMAP	Cặp gần, trung gian và xa	Dùng lịch trọng số theo giai đoạn để cân bằng cục bộ và toàn cục.

5.4 Liên hệ với lý thuyết giảm chiều đã trình bày

Bảng 8: Quan hệ giữa bài báo khảo sát và nội dung lý thuyết của báo cáo.

Nội dung chương	Liên hệ với Wang et al.
PCA	PCA là baseline tuyến tính giữ phương sai/toàn cục và còn được dùng làm khởi tạo cho một số embedding phi tuyến; vì vậy chất lượng khởi tạo có thể ảnh hưởng đến hình trực quan cuối cùng.
KPCA	KPCA và các thuật toán trong bài báo đều tạo embedding phi tuyến, nhưng KPCA tối ưu theo phổ của kernel, còn PaCMAP tối ưu lực trên các cặp điểm được lựa chọn; hai cách tiếp cận không bảo toàn cùng một loại hình học.
Isomap	Isomap giữ khoảng cách geodesic trên đồ thị để mô hình hóa hình học toàn cục của manifold. PaCMAP cũng dùng quan hệ láng giềng, nhưng bổ sung cặp trung gian và xa để phục vụ trực quan hóa cân bằng hơn.
Laplacian/LLE	Các phương pháp này nhấn mạnh cấu trúc địa phương trên đồ thị; phân tích của bài báo giải thích vì sao chỉ thông tin địa phương có thể làm mất bố cục toàn cục.
JL	Bổ đề JL đưa ra bảo đảm méo khoảng cách cho chiếu ngẫu nhiên ở số chiều đủ lớn; trái lại, bài toán trực quan hóa xuống đúng hai chiều chấp nhận biến dạng và phải chọn loại cấu trúc cần ưu tiên.

Như vậy, bài báo không thay thế các kết quả phổ hoặc bảo đảm toán học của chương, mà bổ sung một góc nhìn thiết kế thuật toán: khi mục đích là quan sát embedding hai chiều, việc kiểm soát cặp điểm và gradient quyết định cách đánh đổi giữa cấu trúc gần và bố cục xa.

5.5 [MỞ RỘNG] Đối chiếu với cài đặt của nhóm

Trong bài báo, PaCMAP sử dụng ba loại cặp: *neighbor*, *mid-near* và *further*. Một điểm *mid-near* được chọn bằng cách lấy điểm gần thứ hai trong sáu điểm lấy mẫu ngẫu nhiên; lực hút trên *mid-near* mạnh ở giai đoạn đầu rồi giảm dần, để dựng bố cục toàn cục trước khi tinh chỉnh láng giềng cục bộ [7]. Đồ án này khảo sát ý tưởng đó nhưng *không cài đặt PaCMAP*, vì vậy không tuyên bố tái tạo kết quả PaCMAP của bài báo.

Các artifact mở rộng hiện có gồm: lớp TSNE là wrapper cho `sklearn.manifold.TSNE`; lớp UMAP là wrapper cho thư viện `umap-learn`; và các lớp LLE, `LaplacianEigenmaps` là cài đặt của nhóm. Notebook `baseline.ipynb` chạy trên mẫu cố định gồm 10 000 ảnh MNIST với `SEED = 42`; nhân chỉ được dùng để đánh giá sau khi nhúng. Hai chỉ số được báo cáo là *trustworthiness@12* và độ

chính xác KNN năm láng giềng trên embedding hai chiều.

Bảng 9: Thử nghiệm mở rộng trên 10 000 mẫu MNIST trong `baseline.ipynb` (`SEED = 42`).

Phương pháp	Trustworthiness@12	KNN accuracy@5
t-SNE (wrapper, perplexity = 30)	0.9842	0.9454
UMAP (<code>umap-learn</code> wrapper)	0.9602	0.9429
Laplacian Eigenmaps (nhóm cài đặt)	0.8443	0.7414
LLE (nhóm cài đặt)	0.8286	0.7069

Các kết quả này chỉ là baseline của nhóm, không phải thí nghiệm PaCMAP. Chúng phù hợp với nhận xét định tính của Wang et al. rằng t-SNE và UMAP thường bảo toàn láng giềng cục bộ tốt; chúng không đủ để kết luận về bảo toàn cấu trúc toàn cục hay so sánh trực tiếp với PaCMAP khi thuật toán đó chưa được chạy trên cùng dữ liệu và cùng thước đo.

Ngoài ra, notebook `contrastive_learning.ipynb` là một mở rộng riêng: nó chạy phổ Neg-t-SNE trên mẫu nhanh 5 000 ảnh MNIST, dựa trên `cne.CNE`, rồi đối chiếu với wrapper t-SNE và UMAP. Thử nghiệm này liên quan đến kết nối hiện đại giữa t-SNE và UMAP, nhưng không phải hiện thực PaCMAP và không được dùng để xác nhận các kết quả của Wang et al.

5.6 Xu hướng, hạn chế và câu hỏi mở

Từ bài báo có thể nhận xét xu hướng nghiên cứu giảm chiều phục vụ trực quan hóa đang chuyển từ một tiêu chuẩn duy nhất, như phương sai của PCA hoặc khoảng cách geodesic của Isomap, sang thiết kế mục tiêu lai: cấu trúc cục bộ phải dễ quan sát nhưng bố cục toàn cục không được tùy tiện. Đồng thời, cộng đồng quan tâm hơn đến việc giải thích hàm mất mát, đánh giá bằng nhiều chỉ số và khảo sát độ nhạy tham số thay vì chỉ đưa ra một hình ảnh embedding.

Bài báo chủ yếu đưa ra lập luận thiết kế và bằng chứng thực nghiệm cho trực quan hai chiều; chất lượng hình thu được vẫn phụ thuộc tập dữ liệu, siêu tham số, khởi tạo và chỉ số đánh giá. Một hướng kiểm chứng tiếp theo cho đề án là cài đặt PaCMAP hoặc dùng hiện thực chuẩn, rồi so sánh trên cùng dữ liệu với PCA, Isomap, t-SNE và UMAP bằng cả thước đo cục bộ lẫn thước đo toàn cục như độ chính xác triplet mà Wang et al. sử dụng.

Chương 6 Tổng kết

6.1 Tổng kết

- **PCA** tìm chiều tuyến tính bậc k nhỏ nhất lỗi tái tạo Frobenius; nghiệm gắn với các vector riêng ứng với trị riêng lớn nhất của ma trận hiệp phương sai $\mathbf{C}$ (Định lý 3.1).
- **KPCA** làm việc với ma trận Gram $\mathbf{K}$, cho phép phi tuyến mà không cần Φ tường minh.
- **Isomap, Laplacian eigenmaps, LLE** xây kernel hoặc ma trận Laplacian từ đồ thị láng giềng; bảng 1 so sánh mức “toàn cục” hay “cục bộ” mà mỗi phương pháp ưu tiên giữ.
- **Johnson–Lindenstrauss** cho thấy chiều $k = O(\log m/\varepsilon^2)$ đủ để bảo toàn khoảng cách cặp dưới chiều ngẫu nhiên.

Kết quả thực nghiệm. Trên dữ liệu Wine đã chuẩn hóa, PCA với hai thành phần giữ lại khoảng 55.41% phương sai và lỗi tái tạo giảm về gần không khi dùng đủ 13 thành phần. Trên dữ liệu hai vòng tròn được mở rộng thành 10 chiều rồi giảm xuống 2 chiều, KPCA kernel tuyến tính khớp với PCA đến sai số số học; RBF-KPCA với $\gamma = 32$ đạt silhouette 0.3775, so với 0.1125 của PCA. Với Swiss roll, embedding hai chiều của Isomap đạt tương quan 0.9996 với khoảng cách geodesic tại $t = 12$, cao hơn đáng kể so với PCA (0.2806), và giảm khi tăng số láng giềng lên 20 hoặc 40.

Hạn chế cần nhớ khi áp dụng. Manifold lý tưởng (kiểu Swiss roll) hiếm khớp dữ liệu thật; $\mathbf{K}_{\text{Iso}}$ có thể không xác định dương bán trên mẫu hữu hạn; Laplacian và LLE nhạy với số láng giềng t , tham số σ và cách nối cạnh; PCA/KPCA tuyến tính (kernel đơn giản) không tự khắc phục cấu trúc cong phức tạp nếu không chọn kernel hoặc thuật toán phù hợp.

Tài liệu

- [1] Mikhail Belkin and Partha Niyogi. Laplacian eigenmaps for dimensionality reduction and data representation. *Neural Computation*, 15(6):1373–1396, 2003.
- [2] Sebastian Mika, Bernhard Schölkopf, Alexander J. Smola, Klaus-Robert Müller, Robert Fisher, and Gunnar Ratsch. Kernel PCA and de-noising in feature spaces. *Advances in Neural Information Processing Systems*, 12, 1999.
- [3] Mehryar Mohri, Afshin Rostamizadeh, and Ameet Talwalkar. *Foundations of Machine Learning*. MIT Press, 2nd edition, 2018.
- [4] Karl Pearson. On lines and planes of closest fit to systems of points in space. *The London, Edinburgh, and Dublin Philosophical Magazine and Journal of Science*, 2(11):559–572, 1901.
- [5] Sam T. Roweis and Lawrence K. Saul. Nonlinear dimensionality reduction by locally linear embedding. *Science*, 290(5500):2323–2326, 2000.
- [6] Joshua B. Tenenbaum, Vin de Silva, and John C. Langford. A global geometric framework for nonlinear dimensionality reduction. *Science*, 290(5500):2319–2323, 2000.
- [7] Yingfan Wang, Haiyang Huang, Cynthia Rudin, and Yaron Shaposhnik. Understanding how dimension reduction tools work: An empirical approach to deciphering t-SNE, UMAP, TriMap, and PaCMAP for data visualization. *Journal of Machine Learning Research*, 22(201):1–73, 2021.